

# Proyecto Inferencia II: Climbers

Santiago Robatto, Diego Da Rosa, Sofía Terra, Nahuel Bizoso

```
# A tibble: 2,076 x 24
  expedition_id member_id peak_id peak_name year season sex age
  <chr>         <fct>    <fct>    <fct>    <dbl> <fct> <fct> <dbl>
1 AMAD81101    AMAD81101-03 AMAD     Ama Dablam 1981 Spring M      28
2 AMAD81101    AMAD81101-04 AMAD     Ama Dablam 1981 Spring M      27
3 AMAD81101    AMAD81101-02 AMAD     Ama Dablam 1981 Spring M      35
4 AMAD81101    AMAD81101-05 AMAD     Ama Dablam 1981 Spring M      37
5 AMAD81101    AMAD81101-06 AMAD     Ama Dablam 1981 Spring M      43
6 AMAD81101    AMAD81101-07 AMAD     Ama Dablam 1981 Spring M      38
7 AMAD81101    AMAD81101-08 AMAD     Ama Dablam 1981 Spring M      23
8 AMAD81101    AMAD81101-01 AMAD     Ama Dablam 1981 Spring M      36
9 AMAD81101    AMAD81101-09 AMAD     Ama Dablam 1981 Spring M      48
10 AMAD81101    AMAD81101-11 AMAD     Ama Dablam 1981 Spring M      25
# i 2,066 more rows
# i 16 more variables: citizenship <fct>, expedition_role <fct>, hired <lgl>,
#   highpoint_metres <dbl>, success <lgl>, solo <lgl>, oxygen_used <lgl>,
#   died <lgl>, death_cause <fct>, death_height_metres <dbl>, injured <lgl>,
#   injury_type <fct>, injury_height_metres <dbl>, count <int>,
#   height_metres <dbl>, first_ascent_year <dbl>
```

## Introducción

- El dataset contiene información de interacciones comerciales cliente–propiedad en el mercado inmobiliario y cuenta con 24 variables y 2076 observaciones.
- Algunas variables refieren a las características sociodemográficas del lead/cliente, mientras que otras describen los atributos del inmueble visitado.
- La variable de interés es la decisión de compra (compra: 1 = compró el inmueble, 0 = no compró), la cual es binaria.
- La compra representa un evento de conversión comercial real, análogo a un cierre de venta.

- En el contexto original, el éxito se daba al alcanzar la cima del pico; en esta reconversión, el éxito se interpreta como que el cliente decidió adquirir la propiedad que visitó, lo cual nos lleva naturalmente a plantear un modelo de clasificación con enlace logístico para estimar probabilidades de conversión.
- Esto nos hace pensar en un modelo logístico (regresión logística) para explicar y/o predecir la compra.

Dado que queremos modelar un suceso de la realidad que es binario (compra o no compra de un inmueble), asumimos que la forma adecuada de representar la incertidumbre de cada lead es mediante una distribución Bernoulli, con probabilidad de compra individual  $\pi_i$  (probabilidad de conversión del lead  $i$  frente a la propiedad que visitó). Por lo tanto, nuestra variable de respuesta  $Y$  se distribuye:

$$Y_i \mid \pi_i \sim \text{Bern}(\pi_i)$$

con:

$$E(Y_i \mid \pi_i) = \pi_i$$

A su vez, a la hora de armar el modelo, utilizaremos las odds. Recordemos que las odds son una manera distinta de mirar las probabilidades, donde comparamos la probabilidad de éxito con opuesto:  $\text{odds} = \frac{\pi}{1-\pi}$

Entonces:

$$Y_i \mid \beta_0, \beta_1 \dots \beta_n \sim \text{Bern}(\pi_i) \text{ , con } \log\left(\frac{\pi_i}{1-\pi_i}\right) = \mathbf{x}_i^\top \beta.$$

Con:

$$\beta_0 \sim N(m_0, s_0^2) \beta_1 \sim N(m_1, s_1^2) : \beta_n \sim N(m_n, s_n^2)$$

Podemos despejar las probabilidad  $\pi_i$  en un modelo logístico de las siguientes maneras:

$$\frac{\pi_i}{1-\pi_i} = e^{\beta_0 + \beta_1 X_{i1}} \quad \text{o, despejando} \quad \pi_i = \frac{e^{\beta_0 + \beta_1 X_{i1}}}{1 + e^{\beta_0 + \beta_1 X_{i1}}}$$

En cambio, dado que queremos incorporar jerarquías, debemos hacer ciertos cambios sobre el modelo. Mas precisamente, queremos reflejar que los parámetros  $\beta_i$  dependen de cada grupo.

$$Y_{ij} \mid \pi_{ij} \sim \text{Bern}(\pi_{ij})$$

$$\text{con } \log\left(\frac{\pi_{ij}}{1-\pi_{ij}}\right) = \beta_{0j} + \sum_{k=1}^p \beta_k X_{ijk}$$

$$\beta_{0j} \mid \beta_0, \sigma_0 \stackrel{\text{ind}}{\sim} N(\beta_0, \sigma_0^2) \text{ representa la variabilidad entre grupos}$$

Las Priors globales son:

$$\beta_0 \sim N(m_0, s_0^2)$$

y

$$\beta_k \sim N(m_k, s_k^2) \quad \text{para } k = 1 \dots p$$

y el error es

$$\sigma_0 \sim \text{Exp}(\lambda)$$

De la misma manera podemos expresar los interceptos como:

$$\beta_{0j} = \beta_0 + b_{0j}$$

$$\text{por lo que} \quad \log\left(\frac{\pi_{ij}}{1 - \pi_{ij}}\right) = (\beta_0 + b_{0j}) + \beta_1 X_{ij1} + \beta_2 X_{ij2} + \dots + \beta_n X_{ijn}$$

En resumen,

Los interceptos específicos de cada grupo  $\beta_{0j}$  representan la tasa base de éxito (en log-odds) para cada grupo  $j$ . Esto permite diferenciar cada grupo entre si, donde por ejemplo algunos grupos tienen niveles de éxito más altos que otros.

Estos interceptos  $\beta_{0j}$  se modelan como distribuidos Normalmente alrededor de un intercepto global  $\beta_0$  con desviación estándar  $\sigma_0$ . El parámetro  $\beta_0$  refleja la tasa de éxito promedio entre todos los grupos. La cantidad  $\sigma_0$  mide la variabilidad entre grupos, es decir, cuánto difieren unos de otros.

De igual manera que en el resto de modelos, los interceptos  $\beta_1, \beta_2 \dots$  siguen describiendo las relaciones globales entre las variables.

### Info de las variables:

Table 1: Descripción de Variables del Dataset Inmobiliario (Conversión de Compra)

| Variable        | Tipo_dato | Descripción                                                              |
|-----------------|-----------|--------------------------------------------------------------------------|
| campana         | character | Identificador de la campaña o fuente de captación del lead               |
| cliente_id      | factor    | Identificador único del cliente potencial (lead)                         |
| propiedad_id    | factor    | Identificador único de la propiedad consultada o visitada                |
| propiedad       | factor    | Nombre o tipo de propiedad (casa, apartamento, etc.)                     |
| año_interaccion | numeric   | Año en que ocurrió la interacción cliente-propiedad                      |
| ciclo_mercado   | factor    | Ciclo de demanda del mercado inmobiliario (temporada del mercado)        |
| sexo            | character | Sexo del cliente                                                         |
| edad            | numeric   | Edad del cliente                                                         |
| origen          | factor    | País u origen del lead                                                   |
| rol_decision    | factor    | Rol del lead en la decisión de compra (titular, inversor, cónyuge, etc.) |
| partner_externo | logical   | Indica si el lead provino de un partner externo (TRUE = sí, FALSE = no)  |

|                     |         |                                                                                                 |
|---------------------|---------|-------------------------------------------------------------------------------------------------|
| interes_max         | numeric | Nivel máximo de interés mostrado en la visita (proxy comercial en metros observados/recorridos) |
| compra              | logical | Conversión de compra (TRUE = compra concretada, FALSE = no concretada)                          |
| decision_individual | logical | Indica si la decisión de compra fue individual (TRUE) o compartida/grupal (FALSE)               |
| premium             | logical | Indica si la propiedad es premium o tiene amenities diferenciales (TRUE = sí, FALSE = no)       |
| lead_fallo          | logical | Indica si el lead falló críticamente en el proceso de conversión (TRUE = sí, FALSE = no)        |
| motivo_fallo        | factor  | Motivo del fallo crítico de conversión (solo si lead_fallo = TRUE)                              |
| tam_fallo           | numeric | Tamaño de la propiedad al momento del fallo crítico (si aplica)                                 |
| friccion            | logical | Indica si hubo fricción o incidente en el proceso de compra (TRUE = sí, FALSE = no)             |
| tipo_incidente      | factor  | Tipo de incidente en la conversión (crédito rechazado, documentación, tasación baja, etc.)      |
| tam_incidente       | numeric | Tamaño de la propiedad al momento del incidente (si aplica)                                     |
| asesores            | numeric | Cantidad de asesores/vendedores que atendieron al lead                                          |
| tam_propiedad       | numeric | Metros cuadrados totales de la propiedad                                                        |
| año_primer_listing  | numeric | Año en que la propiedad salió al mercado por primera vez (proxy a antigüedad del listing)       |

# A tibble: 2,076 x 24

|    | expedition_id | member_id    | peak_id | peak_name  | year  | season | sex   | age   |
|----|---------------|--------------|---------|------------|-------|--------|-------|-------|
|    | <chr>         | <fct>        | <fct>   | <fct>      | <dbl> | <fct>  | <fct> | <dbl> |
| 1  | AMAD81101     | AMAD81101-03 | AMAD    | Ama Dablam | 1981  | Spring | M     | 28    |
| 2  | AMAD81101     | AMAD81101-04 | AMAD    | Ama Dablam | 1981  | Spring | M     | 27    |
| 3  | AMAD81101     | AMAD81101-02 | AMAD    | Ama Dablam | 1981  | Spring | M     | 35    |
| 4  | AMAD81101     | AMAD81101-05 | AMAD    | Ama Dablam | 1981  | Spring | M     | 37    |
| 5  | AMAD81101     | AMAD81101-06 | AMAD    | Ama Dablam | 1981  | Spring | M     | 43    |
| 6  | AMAD81101     | AMAD81101-07 | AMAD    | Ama Dablam | 1981  | Spring | M     | 38    |
| 7  | AMAD81101     | AMAD81101-08 | AMAD    | Ama Dablam | 1981  | Spring | M     | 23    |
| 8  | AMAD81101     | AMAD81101-01 | AMAD    | Ama Dablam | 1981  | Spring | M     | 36    |
| 9  | AMAD81101     | AMAD81101-09 | AMAD    | Ama Dablam | 1981  | Spring | M     | 48    |
| 10 | AMAD81101     | AMAD81101-11 | AMAD    | Ama Dablam | 1981  | Spring | M     | 25    |

# i 2,066 more rows

# i 16 more variables: citizenship <fct>, expedition\_role <fct>, hired <lgl>,  
# highpoint\_metres <dbl>, success <lgl>, solo <lgl>, oxygen\_used <lgl>,  
# died <lgl>, death\_cause <fct>, death\_height\_metres <dbl>, injured <lgl>,  
# injury\_type <fct>, injury\_height\_metres <dbl>, count <int>,  
# height\_metres <dbl>, first\_ascent\_year <dbl>

| Variable        | Min  | Q1   | Median | Mean       | Q3   | Max  |
|-----------------|------|------|--------|------------|------|------|
| año_interaccion | 1978 | 1996 | 2006   | 2002.87331 | 2011 | 2019 |
| edad            | 17   | 29   | 36     | 36.95713   | 43   | 76   |
| interes_max     | 4900 | 6750 | 7400   | 7554.86446 | 8850 | 8850 |
| tam_fallo       | 3400 | 6150 | 6600   | 6771.05263 | 7800 | 8650 |
| tam_incidente   | 3960 | 5575 | 6325   | 6406.42857 | 6950 | 8400 |
| asesores        | 5    | 8    | 11     | 13.88439   | 18   | 44   |
| tam_propiedad   | 5929 | 7138 | 8167   | 7989.03805 | 8850 | 8850 |

---

|                    |      |      |      |            |      |      |
|--------------------|------|------|------|------------|------|------|
| año_primer_listing | 1936 | 1953 | 1954 | 1959.22378 | 1961 | 2017 |
|--------------------|------|------|------|------------|------|------|

---

| Variable            | TRUEs | Total | Porcentaje_TRUE |
|---------------------|-------|-------|-----------------|
| partner_externo     | 485   | 2076  | 23.36           |
| compra              | 807   | 2076  | 38.87           |
| decision_individual | 2     | 2076  | 0.10            |
| premium             | 601   | 2076  | 28.95           |
| lead_fallo          | 19    | 2076  | 0.92            |
| friccion            | 24    | 2076  | 1.16            |