

Proyecto Inferencia II: Climbers

Santiago Robatto, Diego Da Rosa, Sofía Terra, Nahuel Bizoso

```
# A tibble: 2,076 x 24
  expedition_id member_id peak_id peak_name year season sex age
  <chr>          <fct>    <fct>  <fct>    <dbl> <fct> <fct> <dbl>
1 AMAD81101     AMAD81101-03 AMAD    Ama Dablam 1981 Spring M      28
2 AMAD81101     AMAD81101-04 AMAD    Ama Dablam 1981 Spring M      27
3 AMAD81101     AMAD81101-02 AMAD    Ama Dablam 1981 Spring M      35
4 AMAD81101     AMAD81101-05 AMAD    Ama Dablam 1981 Spring M      37
5 AMAD81101     AMAD81101-06 AMAD    Ama Dablam 1981 Spring M      43
6 AMAD81101     AMAD81101-07 AMAD    Ama Dablam 1981 Spring M      38
7 AMAD81101     AMAD81101-08 AMAD    Ama Dablam 1981 Spring M      23
8 AMAD81101     AMAD81101-01 AMAD    Ama Dablam 1981 Spring M      36
9 AMAD81101     AMAD81101-09 AMAD    Ama Dablam 1981 Spring M      48
10 AMAD81101    AMAD81101-11 AMAD    Ama Dablam 1981 Spring M      25
# i 2,066 more rows
# i 16 more variables: citizenship <fct>, expedition_role <fct>, hired <lgl>,
#   highpoint_metres <dbl>, success <lgl>, solo <lgl>, oxygen_used <lgl>,
#   died <lgl>, death_cause <fct>, death_height_metres <dbl>, injured <lgl>,
#   injury_type <fct>, injury_height_metres <dbl>, count <int>,
#   height_metres <dbl>, first_ascent_year <dbl>
```

Introducción

- El dataset contiene información de interacciones comerciales cliente–propiedad en el mercado inmobiliario y cuenta con 24 variables y 2076 observaciones.
- Algunas variables refieren a las características sociodemográficas del lead/cliente, mientras que otras describen los atributos del inmueble visitado.
- La variable de interés es la decisión de compra (compra: 1 = compró el inmueble, 0 = no compró), la cual es binaria.
- La compra representa un evento de conversión comercial real, análogo a un cierre de venta.

- En el contexto original, el éxito se daba al alcanzar la cima del pico; en esta reconversión, el éxito se interpreta como que el cliente decidió adquirir la propiedad que visitó, lo cual nos lleva naturalmente a plantear un modelo de clasificación con enlace logístico para estimar probabilidades de conversión.
- Esto nos hace pensar en un modelo logístico (regresión logística) para explicar y/o predecir la compra.

Dado que queremos modelar un suceso de la realidad que es binario (compra o no compra de un inmueble), asumimos que la forma adecuada de representar la incertidumbre de cada lead es mediante una distribución Bernoulli, con probabilidad de compra individual π_i (probabilidad de conversión del lead i frente a la propiedad que visitó). Por lo tanto, nuestra variable de respuesta Y se distribuye:

$$Y_i \mid \pi_i \sim \text{Bern}(\pi_i)$$

con:

$$E(Y_i \mid \pi_i) = \pi_i$$

A su vez, a la hora de armar el modelo, utilizaremos las odds. Recordemos que las odds son una manera distinta de mirar las probabilidades, donde comparamos la probabilidad de éxito con opuesto: $\text{odds} = \frac{\pi}{1-\pi}$

Entonces:

$$Y_i \mid \beta_0, \beta_1 \dots \beta_n \sim \text{Bern}(\pi_i) \text{ , con } \log\left(\frac{\pi_i}{1-\pi_i}\right) = \mathbf{x}_i^\top \beta.$$

Con:

$$\beta_0 \sim N(m_0, s_0^2) \beta_1 \sim N(m_1, s_1^2) : \beta_n \sim N(m_n, s_n^2)$$

Podemos despejar las probabilidad π_i en un modelo logístico de las siguientes maneras:

$$\frac{\pi_i}{1-\pi_i} = e^{\beta_0 + \beta_1 X_{i1}} \quad \text{o, despejando} \quad \pi_i = \frac{e^{\beta_0 + \beta_1 X_{i1}}}{1 + e^{\beta_0 + \beta_1 X_{i1}}}$$

En cambio, dado que queremos incorporar jerarquias, debemos hacer ciertos cambios sobre el modelo. Mas precisamente, queremos reflejar que los parametros β_i dependen de cada grupo.

$$Y_{ij} \mid \pi_{ij} \sim \text{Bern}(\pi_{ij})$$

$$\text{con } \log\left(\frac{\pi_{ij}}{1-\pi_{ij}}\right) = \beta_{0j} + \sum_{k=1}^p \beta_k X_{ijk}$$

$$\beta_{0j} \mid \beta_0, \sigma_0 \stackrel{\text{ind}}{\sim} N(\beta_0, \sigma_0^2) \text{ representa la variabilidad entre grupos}$$

Las Priors globales son:

$$\beta_0 \sim N(m_0, s_0^2)$$

y

$$\beta_k \sim N(m_k, s_k^2) \quad \text{para } k = 1 \dots p$$

y el error es

$$\sigma_0 \sim \text{Exp}(\lambda)$$

De la misma manera podemos expresar los interceptos como:

$$\beta_{0j} = \beta_0 + b_{0j}$$

$$\text{por lo que} \quad \log\left(\frac{\pi_{ij}}{1 - \pi_{ij}}\right) = (\beta_0 + b_{0j}) + \beta_1 X_{ij1} + \beta_2 X_{ij2} + \dots + \beta_n X_{ijn}$$

En resumen,

Los interceptos específicos de cada grupo β_{0j} representan la tasa base de éxito (en log-odds) para cada grupo j . Esto permite diferenciar cada grupo entre si, donde por ejemplo algunos grupos tienen niveles de éxito más altos que otros.

Estos interceptos β_{0j} se modelan como distribuidos Normalmente alrededor de un intercepto global β_0 con desviación estándar σ_0 . El parámetro β_0 refleja la tasa de éxito promedio entre todos los grupos. La cantidad σ_0 mide la variabilidad entre grupos, es decir, cuánto difieren unos de otros.

De igual manera que en el resto de modelos, los interceptos $\beta_1, \beta_2 \dots$ siguen describiendo las relaciones globales entre las variables.

Info de las variables:

Table 1: Descripción de Variables del Dataset Inmobiliario (Conversión de Compra)

Variable	Tipo_dato	Descripción
campana	character	Identificador de la campaña o fuente de captación del lead
cliente_id	factor	Identificador único del cliente potencial (lead)
propiedad_id	factor	Identificador único de la propiedad consultada o visitada
propiedad	factor	Nombre o tipo de propiedad (casa, apartamento, etc.)
año_interaccion	numeric	Año en que ocurrió la interacción cliente-propiedad
ciclo_mercado	factor	Ciclo de demanda del mercado inmobiliario (temporada del mercado)
sexo	character	Sexo del cliente
edad	numeric	Edad del cliente
origen	factor	País u origen del lead
rol_decision	factor	Rol del lead en la decisión de compra (titular, inversor, cónyuge, etc.)
partner_externo	logical	Indica si el lead provino de un partner externo (TRUE = sí, FALSE = no)

interes_max	numeric	Nivel máximo de interés mostrado en la visita (proxy comercial en metros observados/recorridos)
compra	logical	Conversión de compra (TRUE = compra concretada, FALSE = no concretada)
decision_individual	logical	Indica si la decisión de compra fue individual (TRUE) o compartida/grupal (FALSE)
premium	logical	Indica si la propiedad es premium o tiene amenities diferenciales (TRUE = sí, FALSE = no)
lead_fallo	logical	Indica si el lead falló críticamente en el proceso de conversión (TRUE = sí, FALSE = no)
motivo_fallo	factor	Motivo del fallo crítico de conversión (solo si lead_fallo = TRUE)
tam_fallo	numeric	Tamaño de la propiedad al momento del fallo crítico (si aplica)
friccion	logical	Indica si hubo fricción o incidente en el proceso de compra (TRUE = sí, FALSE = no)
tipo_incidente	factor	Tipo de incidente en la conversión (crédito rechazado, documentación, tasación baja, etc.)
tam_incidente	numeric	Tamaño de la propiedad al momento del incidente (si aplica)
asesores	numeric	Cantidad de asesores/vendedores que atendieron al lead
tam_propiedad	numeric	Metros cuadrados totales de la propiedad
año_primer_listing	numeric	Año en que la propiedad salió al mercado por primera vez (proxy a antigüedad del listing)

A tibble: 2,076 x 24

	expedition_id	member_id	peak_id	peak_name	year	season	sex	age
	<chr>	<fct>	<fct>	<fct>	<dbl>	<fct>	<fct>	<dbl>
1	AMAD81101	AMAD81101-03	AMAD	Ama Dablam	1981	Spring	M	28
2	AMAD81101	AMAD81101-04	AMAD	Ama Dablam	1981	Spring	M	27
3	AMAD81101	AMAD81101-02	AMAD	Ama Dablam	1981	Spring	M	35
4	AMAD81101	AMAD81101-05	AMAD	Ama Dablam	1981	Spring	M	37
5	AMAD81101	AMAD81101-06	AMAD	Ama Dablam	1981	Spring	M	43
6	AMAD81101	AMAD81101-07	AMAD	Ama Dablam	1981	Spring	M	38
7	AMAD81101	AMAD81101-08	AMAD	Ama Dablam	1981	Spring	M	23
8	AMAD81101	AMAD81101-01	AMAD	Ama Dablam	1981	Spring	M	36
9	AMAD81101	AMAD81101-09	AMAD	Ama Dablam	1981	Spring	M	48
10	AMAD81101	AMAD81101-11	AMAD	Ama Dablam	1981	Spring	M	25

i 2,066 more rows


i 16 more variables: citizenship <fct>, expedition_role <fct>, hired <lgl>,
highpoint_metres <dbl>, success <lgl>, solo <lgl>, oxygen_used <lgl>,
died <lgl>, death_cause <fct>, death_height_metres <dbl>, injured <lgl>,
injury_type <fct>, injury_height_metres <dbl>, count <int>,
height_metres <dbl>, first_ascent_year <dbl>

Variable	Min	Q1	Median	Mean	Q3	Max
año_interaccion	1978	1996	2006	2002.87331	2011	2019
edad	17	29	36	36.95713	43	76
interes_max	4900	6750	7400	7554.86446	8850	8850
tam_fallo	3400	6150	6600	6771.05263	7800	8650
tam_incidente	3960	5575	6325	6406.42857	6950	8400
asesores	5	8	11	13.88439	18	44
tam_propiedad	5929	7138	8167	7989.03805	8850	8850

año_primer_listing	1936	1953	1954	1959.22378	1961	2017
--------------------	------	------	------	------------	------	------

Variable	TRUEs	Total	Porcentaje_TRUE
partner_externo	485	2076	23.36
compra	807	2076	38.87
decision_individual	2	2076	0.10
premium	601	2076	28.95
lead_fallo	19	2076	0.92
friccion	24	2076	1.16

Matriz de Correlacion:



Nueva Variable


Mide cuántos años pasaron desde que la propiedad fue listada por primera vez hasta la interacción actual con el cliente. Refleja el tiempo de exposición del activo inmobiliario, lo cual puede influir en la probabilidad de compra:

Propiedades con mucha exposición pueden indicar sobreprecio, baja demanda o problemas no observados.

Propiedades nuevas en el mercado suelen generar más interés y conversiones rápidas.

También puede asociarse a estrategias de negocio como descuentos por tiempo de publicación, rotación de inventario y urgencia comercial.


Proporción de compra por tramo de antigüedad del listing




Distribución por sexo del lead




Distribución por tipo de





Antigüedad del listing (años)




Distribución de edad del lector






Análisis de Variables Numéricas (Contexto Inmobiliario)



Las cajas representan el rango intercuartílico (IQR)

Análisis de Variables Categóricas (Inmobiliario)

Probabilidad de compra según factores clave (proporciones)



Gráficos normalizados al 100%

gráfico barras apiladas por proporción. sexo y éxito. se observa que la proporción de éxito de hombre es apenas mayor, sin embargo, al tener tan pocas observaciones sobre mujeres escaladoras, se considera que no hay una relación fuerte como para definir sexo como predictora.

Definicion de los modelos

USAMOS MODELO DE REGRESION LOGISTICA: nuestra variable de respuesta “Y” es binaria. En este caso es 1 si hubo succes (si la persona llego a la cima de la montaña), y 0 si hubo fracaso. Este tipo de regresión es no lineal

$$Y_i \sim \text{Bern}(\pi_i)$$

$$\log\left(\frac{\pi_i}{1-\pi_i}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2$$

$Y_i \sim \text{Bern}(\pi_i)$ (aleatoria): tener succes con probabilidad de éxito π .

$\log(\frac{\pi}{1-\pi})$: es la transformación “log odds” que hacemos para poder expresar nuestras probabilidades. nuestro modelo de regresión lineal original nos da resultados en todo el mundo de los reales. sin embargo, cuando trabajamos con variables binarias, nuestro espacio de soluciones pasa a ser entre 0 y 1. tenemos que ajustar esto para poder trabajar nuevamente con los reales, por eso aplicamos la transformación. primero pasamos de “probabilidad” (π) a “odds” o “chances”, haciendo $\pi/(1-\pi)$. lo que queremos calcular es cuantas veces mas probable es

ganar que perder. por ejemplo, si $\pi=0.5$ entonces odds va a ser 1, lo que quiere decir que con probabilidad 50%, la chance de ganar es una vez mas probable que perder. finalmente, le aplicamos logaritmo a las odds, para que nuestro dominio sea todos los reales. por ejemplo, en el caso de odds=1, al aplicar logaritmo obtenemos 0, pero si nuestras odds fueran muy altas, el logaritmo seria un numero positivo grande, y si las odds fueran muy bajas, el logaritmo devuelve un numero negativo.

β_0 (intercepto): probabilidad de éxito cuando todas las variables X valen 0. “probabilidad base”.

β_1 (pendiente): cuanto aumenta (o disminuye) la probabilidad de éxito si aumentamos X_1 en una unidad. Si $\beta > 0$: Aumenta la probabilidad de éxito. Si $\beta < 0$: Disminuye la probabilidad.

MODELO DE REGRESION LOGISTICA JERARQUICO

POOLING: si los grupos comparten info entre si

ahora los datos tienen “estructura”. Los escaladores pertenecen a grupos (por ejemplo expedicion o montana).

complete pooling: Ignora la montana. Asume que todas son iguales. (se comparte toda la info)

No Pooling: Trata cada montana de forma independiente. (no se comparte nada de la info)

Jerárquico (Partial Pooling): cada montana es unica (β_{0j}), pero que todas pertenecen a una “familia de montanas”. Las montanas con pocos datos “toman datos” del promedio global. (se comparte algo de info)

$$\text{Nivel 1 (Datos): } \log \left(\frac{\pi_{ij}}{1 - \pi_{ij}} \right) = \beta_{0j} + \beta_1 X_{ij1}$$

$$\text{Nivel 2 (Grupos): } \beta_{0j} \sim N(\beta_0, \sigma^2)$$

β_{0j} (efecto aleatorio/intercepto variando): Cada grupo j (ej. cada montana o expedicion) tiene su propio “punto de partida”. β_0 (Efecto fijo/Hiperparametro de media): Es el promedio global de todas las montanas. σ (desviacion del grupo): Mide que tan diferentes son las montanas entre si. Si σ es bajo: Todas las montanas se parecen mucho (alto pooling). Si σ es alto: Las montanas son muy distintas entre si (pooling bajo).

OBS: DEFINIMOS PRIORIS POCO INFORMATIVAS por que? Normal (0,2.5): queremos evitar hacer overfitting cuando tenemos pocos datos (en nuestro caso “limpiamos” mucho nuestra base de datos original) en la escala logística, coeficientes mayores a 5 implican certeza prácticamente. nosotros nos queremos posicionar “en el medio” y dejar que los datos nos digan que paso. por otro lado, centramos en cero ya que queremos tener una postura neutral. asumimos a priori que las variables no tienen efecto sobre el éxito (por eso esta es 0). nuevamente

dejamos que los datos nos muestren que pasa. $\exp(1)$: varianza no puede ser negativa, solo trabajamos con valores positivos.

Modelo 1:

Definiremos el modelo 1 como el modelo con complete pooling con los siguientes predictores: oxígeno, season, y year_since_first_ascent. Es decir, asumimos que todos los escaladores distribuyen de igual manera.

OBS: no incluimos peak ya que no nos importa en que montaña estamos, tratamos a todas por igual. Si incluimos peak estamos diferenciando a las montañas. (“ignoramos los grupos y metemos a todos en la misma bolsa”).

OBS: este modelo es nuestro punto de partida

De esta manera:

$Y_i \beta_0, \beta_1, \beta_2, \beta_3 \sim \text{Bern}(\pi_i)$	(verosimilitud)
donde $\log\left(\frac{\pi_i}{1 - \pi_i}\right) = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3}$	
$\beta_0 \sim N(0, 2.5^2)$	(intercepto global)
$\beta_1, \beta_2, \beta_3 \stackrel{\text{ind}}{\sim} N(0, 2.5^2)$	(coeficientes fijos)

beta1, beta2 y beta 3 son nuestras predictoras (fijas)

variables:

Y_i : Éxito del escalador i . X_{i1} : Uso de oxígeno. X_{i2} : Estación del año. X_{i3} : Años desde el primer ascenso.

Modelo 2:

Partial pooling por **expedicion**. Agregamos jerarquía en la expedición j , tal como el libro.

$Y_{ij} \beta_{0j}, \beta_1, \beta_2, \beta_3 \sim \text{Bern}(\pi_{ij})$	(verosimilitud)
with $\log \left(\frac{\pi_{ij}}{1 - \pi_{ij}} \right) = \beta_{0j} + \beta_1 X_{ij1} + \beta_2 X_{ij2} + \beta_3 X_{ij3}$	
$\beta_{0j} \beta_{0c}, \sigma_{exp} \stackrel{ind}{\sim} N(\beta_{0c}, \sigma_{exp}^2)$	(variabilidad entre expediciones)
$\beta_{0c} \sim N(0, 2.5^2)$	(intercepto global)
$\beta_1, \beta_2, \beta_3 \stackrel{ind}{\sim} N(0, 2.5^2)$	(coeficientes fijos)
$\sigma_{exp} \sim \text{Exp}(1)$	(desvío est. entre expediciones)

beta0, beta1 ,beta2 y beta3 son nuestras predictoras (fijas)

variables:

$Y_{i,j}$: Éxito del escalador i en la expedición j. $X_{i,j,1}$: Uso de oxígeno. $X_{i,j,2}$: Estación del año. $X_{i,j,3}$: Años desde el primer ascenso.

Modelo 3

Partial Pooling por **peak** (agregamos jerarquía pico en vez de escalación, para mostrar lo que a priori es un mal modelo o mal conceptualmente hablando agrupar por pico). Hay individuos dentro del mismo grupo muy divergentes entre si.

$Y_{ik} \beta_{0k}, \beta_1, \beta_2, \beta_3 \sim \text{Bern}(\pi_{ik})$	(verosimilitud)
with $\log \left(\frac{\pi_{ik}}{1 - \pi_{ik}} \right) = \beta_{0k} + \beta_1 X_{ik1} + \beta_2 X_{ik2} + \beta_3 X_{ik3}$	
$\beta_{0k} \beta_{0c}, \sigma_{peak} \stackrel{ind}{\sim} N(\beta_{0c}, \sigma_{peak}^2)$	(variabilidad entre picos)
$\beta_{0c} \sim N(0, 2.5^2)$	(intercepto global)
$\beta_1, \beta_2, \beta_3 \stackrel{ind}{\sim} N(0, 2.5^2)$	(coeficientes fijos)
$\sigma_{peak} \sim \text{Exp}(1)$	(desvío est. entre picos)

beta1, beta2 y beta3 son nuestras predictoras

variables

$Y_{i,k}$: Éxito del escalador i en peak k. $X_{i,k,1}$: Uso de oxígeno. $X_{i,k,2}$: Estación del año. $X_{i,k,3}$: Años desde el primer ascenso.

Modelo 4

Jerarquía con Season.

$Y_{is} \beta_{0s}, \beta_1, \beta_2, \beta_3 \sim \text{Bern}(\pi_{is})$	(verosimilitud)
$\text{with } \log\left(\frac{\pi_{is}}{1 - \pi_{is}}\right) = \beta_{0s} + \beta_1 X_{is1} + \beta_2 X_{is2} + \beta_3 X_{is3}$	
$\beta_{0s} \beta_{0c}, \sigma_{peak} \stackrel{ind}{\sim} N(\beta_{0c}, \sigma_{peak}^2)$	(variabilidad entre picos)
$\beta_{0c} \sim N(0, 2.5^2)$	(intercepto global)
$\beta_1, \beta_2, \beta_3 \stackrel{ind}{\sim} N(0, 2.5^2)$	(coeficientes fijos)
$\sigma_{peak} \sim \text{Exp}(1)$	(desvío est. entre picos)


beta1, beta2 y beta3 son nuestras predictoras

variables

Y_i, s : Éxito del escalador i en season s. $X_{i,s,1}$: Uso de oxígeno. $X_{i,s,2}$: Estación del año. $X_{i,s,3}$: Años desde el primer ascenso.


Corrida de los modelos

#Modelo 1




La barra vertical es el éxito promedio del dataframe. El resto en celeste es la tasa de éxito en nuestros 100 dataframes simulados.

Modelo 2





Notamos que este modelo tiene una mejoría respecto al anterior, pero de igual forma pensamos que todavía se puede mejorar más

Modelo 3



Modelo 4




PP_Checks:

pp_check para los cuatro modelos (Inmobiliario)


Modelo 1

Sin jerarquía (Complete Pooling)




Modelo 2

Jerarquía por campaña




Modelo 3

Jerarquía por propiedad



Modelo 4

Jerarquía por ciclo de mercado



Se observa de forma visual que no existen diferencias sustanciales entre los modelos. Se podría decir que en principio no aporta una mejoría realizar agrupamiento.

MCMC diagnostics

Priors for model 'modsj'

Intercept (after predictors centered)

~ normal(location = 0, scale = 2.5)

Coefficients



Specified prior:


~ normal(location = [0,0,0,...], scale = [2.5,2.5,2.5,...])

Adjusted prior:

~ normal(location = [0,0,0,...], scale = [5.51, 5.05,15.14,...])

See `help('prior_summary.stanreg')` for more details





(Intercept)	premiumTRUE	ciclo_mercadoAutumn	ciclo_mercadoWinter
0.58335	0.50435	0.53050	0.58280
ciclo_mercadoSummer	años_desde_listing		
0.23065	0.55220		

Model Info:

```

function:    stan_glm
family:      binomial [logit]
formula:     compra ~ premium + ciclo_mercado + años_desde_listing
algorithm:   sampling
sample:      20000 (posterior sample size)
priors:       see help('prior_summary')
observations: 2069
predictors:  6

```

Estimates:

	mean	sd	10%	50%	90%
(Intercept)	-1.9	0.2	-2.1	-1.8	-1.6
premiumTRUE	3.3	0.2	3.1	3.3	3.5
ciclo_mercadoAutumn	0.9	0.1	0.7	0.9	1.0
ciclo_mercadoWinter	-0.2	0.4	-0.7	-0.2	0.3

ciclo_mercadoSummer	40.2	27.6	9.7	34.1	79.1
años_desde_listing	0.0	0.0	0.0	0.0	0.0

Fit Diagnostics:

	mean	sd	10%	50%	90%
mean_PPD	0.4	0.0	0.4	0.4	0.4

The mean_ppd is the sample average posterior predictive distribution of the outcome variable

MCMC diagnostics

	mcse	Rhat	n_eff
(Intercept)	0.0	1.0	11667
premiumTRUE	0.0	1.0	10087
ciclo_mercadoAutumn	0.0	1.0	10610
ciclo_mercadoWinter	0.0	1.0	11656
ciclo_mercadoSummer	0.4	1.0	4613
años_desde_listing	0.0	1.0	11044
mean_PPD	0.0	1.0	19701
log-posterior	0.0	1.0	6962

For each parameter, mcse is Monte Carlo standard error, n_eff is a crude measure of effective

Priors for model 'modjp'

Intercept (after predictors centered)

~ normal(location = 0, scale = 2.5)

Coefficients

Specified prior:

~ normal(location = [0,0,0,...], scale = [2.5,2.5,2.5,...])


Adjusted prior:


~ normal(location = [0,0,0,...], scale = [5.05,15.14,46.48,...])

Covariance

~ decov(reg. = 1, conc. = 1, shape = 1, scale = 1)

See help('prior_summary.stanreg') for more details





```

              (Intercept)
              0.16455
      seasonAutumn
              0.96650
      seasonWinter
              0.95340
      seasonSummer
              0.50360
      year_since_first_ascent
              0.64930
      oxygen_usedTRUE
              1.17345
      b[(Intercept) peak_name:Ama_Dablam]
              0.13055
      b[(Intercept) peak_name:Annapurna_I]
              0.57565
      b[(Intercept) peak_name:Annapurna_II]
              0.70435
      b[(Intercept) peak_name:Annapurna_III]
              0.70800
      b[(Intercept) peak_name:Annapurna_IV]
              0.64480
      b[(Intercept) peak_name:Baruntse]

```

```

0.14680
b[(Intercept) peak_name:Bhrikuti]
0.81745
b[(Intercept) peak_name:Chamlang]
0.23910
b[(Intercept) peak_name:Cho_Oyu]
0.13995
b[(Intercept) peak_name:Dhaulagiri_I]
0.19305
b[(Intercept) peak_name:Dhampus]
0.78560
b[(Intercept) peak_name:Dzanye_II]
0.53770
b[(Intercept) peak_name:Everest]
0.13990
b[(Intercept) peak_name:Fang]
0.69705
b[(Intercept) peak_name:Ganesh_III]
0.44625
b[(Intercept) peak_name:Gaurishankar]
0.79660
b[(Intercept) peak_name:Gurkarmo_Ri]
0.84190
b[(Intercept) peak_name:Gyajikang]
0.79535
b[(Intercept) peak_name:Himlung_Himal]
0.16590
b[(Intercept) peak_name:Jannu]
0.67590
b[(Intercept) peak_name:Jethi_Bahurani]
0.45255
b[(Intercept) peak_name:Kabru_Dome]
0.37095
b[(Intercept) peak_name:Kangchenjunga]
0.23360
b[(Intercept) peak_name:Kwangde]
0.57195
b[(Intercept) peak_name:Langtang_Lirung]
0.83385
b[(Intercept) peak_name:Leonpo_Gang_East]
0.77590
b[(Intercept) peak_name:Lhotse]
0.33590

```

```

      b[(Intercept) peak_name:Langju]
                        0.78845
b[(Intercept) peak_name:Lhotse_Shar]
                        0.36630
      b[(Intercept) peak_name:Makalu]
                        0.17245
b[(Intercept) peak_name:Manaslu]
                        0.14935
      b[(Intercept) peak_name:Nampa]
                        0.80655
b[(Intercept) peak_name:Nemjung]
                        0.76975
b[(Intercept) peak_name:Nilgiri_Central]
                        0.41625
      b[(Intercept) peak_name:Nuptse]
                        0.75845
b[(Intercept) peak_name:Ohmi_Kangri]
                        0.36585
      b[(Intercept) peak_name:Pumori]
                        0.21785
b[(Intercept) peak_name:Putha_Hiunchuli]
                        0.31725
      b[(Intercept) peak_name:Shalbachum]
                        0.80445
      b[(Intercept) peak_name:Sphinx]
                        0.45920
b[(Intercept) peak_name:Syaokang]
                        0.51030
      b[(Intercept) peak_name:Tawoche]
                        0.79750
b[(Intercept) peak_name:Tilicho]
                        0.18435
b[(Intercept) peak_name:Tengkangpoche]
                        0.74080
      b[(Intercept) peak_name:Tukuche]
                        0.18805
Sigma[peak_name:(Intercept),(Intercept)]
                        0.26125

```

Model Info:

function: stan_glmer

```

family:      binomial [logit]
formula:     success ~ season + year_since_first_ascent + +oxygen_used + (1 |
             peak_name)
algorithm:    sampling
sample:      20000 (posterior sample size)
priors:      see help('prior_summary')
observations: 2069
groups:      peak_name (45)

```

Estimates:

	mean	sd	10%	50%	90%
(Intercept)	-2.8	0.6	-3.6	-2.8	-2.1
seasonAutumn	0.4	0.2	0.2	0.4	0.7
seasonWinter	-1.2	0.7	-2.0	-1.2	-0.4
seasonSummer	42.5	27.0	12.8	36.8	80.4
year_since_first_ascent	0.0	0.0	0.0	0.0	0.0
oxygen_usedTRUE	4.1	0.2	3.8	4.1	4.3
b[(Intercept) peak_name:Ama_Dablam]	2.4	0.6	1.7	2.3	3.1
b[(Intercept) peak_name:Annapurna_I]	-3.6	1.8	-5.9	-3.3	-1.5
b[(Intercept) peak_name:Annapurna_II]	-3.1	1.9	-5.5	-2.8	-0.9
b[(Intercept) peak_name:Annapurna_III]	-2.7	2.0	-5.3	-2.4	-0.4
b[(Intercept) peak_name:Annapurna_IV]	-2.9	1.9	-5.4	-2.7	-0.8
b[(Intercept) peak_name:Baruntse]	0.8	0.6	0.0	0.8	1.6
b[(Intercept) peak_name:Bhrikuti]	-2.3	2.1	-5.0	-2.0	0.1
b[(Intercept) peak_name:Chamlang]	1.0	0.8	0.0	1.0	2.0
b[(Intercept) peak_name:Cho_Oyu]	0.5	0.6	-0.2	0.5	1.3
b[(Intercept) peak_name:Dhaulagiri_I]	-0.4	0.7	-1.3	-0.4	0.5
b[(Intercept) peak_name:Dhampus]	-2.4	2.0	-5.0	-2.1	-0.1
b[(Intercept) peak_name:Dzanye_II]	5.2	1.7	3.3	5.0	7.5
b[(Intercept) peak_name:Everest]	-0.3	0.6	-1.0	-0.3	0.5
b[(Intercept) peak_name:Fang]	-2.4	2.0	-5.1	-2.1	-0.1
b[(Intercept) peak_name:Ganesh_III]	4.3	1.1	2.9	4.2	5.7
b[(Intercept) peak_name:Gaurishankar]	-2.1	2.1	-4.9	-1.8	0.3
b[(Intercept) peak_name:Gurkarmo_Ri]	-2.3	2.0	-5.0	-2.0	0.0
b[(Intercept) peak_name:Gyajikang]	-2.0	2.2	-4.8	-1.7	0.6
b[(Intercept) peak_name:Himlung_Himal]	1.6	0.6	0.8	1.6	2.4
b[(Intercept) peak_name:Jannu]	-2.9	1.9	-5.4	-2.6	-0.7
b[(Intercept) peak_name:Jethi_Bahurani]	2.9	1.1	1.6	2.9	4.3
b[(Intercept) peak_name:Kabru_Dome]	2.9	1.0	1.7	2.9	4.1
b[(Intercept) peak_name:Kangchenjunga]	-0.5	0.8	-1.5	-0.5	0.4
b[(Intercept) peak_name:Kwangde]	6.3	1.7	4.3	6.1	8.4
b[(Intercept) peak_name:Langtang_Lirung]	-2.1	2.1	-4.9	-1.8	0.4
b[(Intercept) peak_name:Leonpo_Gang_East]	-2.5	2.0	-5.2	-2.2	-0.2

b[(Intercept) peak_name:Lhotse]	0.5	1.0	-0.7	0.5	1.8
b[(Intercept) peak_name:Langju]	-2.1	2.1	-4.8	-1.8	0.3
b[(Intercept) peak_name:Lhotse_Shar]	0.7	1.0	-0.5	0.8	2.0
b[(Intercept) peak_name:Makalu]	-0.2	0.7	-1.1	-0.2	0.7
b[(Intercept) peak_name:Manaslu]	0.4	0.6	-0.3	0.4	1.2
b[(Intercept) peak_name:Nampa]	-2.1	2.1	-4.9	-1.8	0.3
b[(Intercept) peak_name:Nemjung]	-2.5	2.0	-5.1	-2.2	-0.2
b[(Intercept) peak_name:Nilgiri_Central]	3.5	1.0	2.3	3.5	4.9
b[(Intercept) peak_name:Nuptse]	-1.9	2.1	-4.7	-1.7	0.6
b[(Intercept) peak_name:Ohmi_Kangri]	0.9	1.0	-0.4	0.9	2.1
b[(Intercept) peak_name:Pumori]	0.1	0.8	-0.9	0.1	1.1
b[(Intercept) peak_name:Putha_Hiunchuli]	-0.2	0.9	-1.4	-0.2	1.0
b[(Intercept) peak_name:Shalbachum]	-2.2	2.1	-4.9	-1.9	0.2
b[(Intercept) peak_name:Sphinx]	5.7	1.6	3.9	5.5	7.9
b[(Intercept) peak_name:Syaokang]	3.8	1.2	2.3	3.7	5.3
b[(Intercept) peak_name:Tawoche]	-1.8	2.2	-4.6	-1.5	0.7
b[(Intercept) peak_name:Tilicho]	0.5	0.7	-0.3	0.5	1.3
b[(Intercept) peak_name:Tengkangpoche]	-2.2	2.1	-4.9	-1.9	0.2
b[(Intercept) peak_name:Tukuche]	3.1	0.7	2.2	3.1	4.0
Sigma[peak_name:(Intercept),(Intercept)]	9.1	3.5	5.3	8.4	13.6

Fit Diagnostics:

	mean	sd	10%	50%	90%
mean_PPD	0.4	0.0	0.4	0.4	0.4

The mean_ppd is the sample average posterior predictive distribution of the outcome variable

MCMC diagnostics

	mcse	Rhat	n_eff
(Intercept)	0.0	1.0	3291
seasonAutumn	0.0	1.0	19330
seasonWinter	0.0	1.0	19068
seasonSummer	0.3	1.0	10072
year_since_first_ascent	0.0	1.0	12986
oxygen_usedTRUE	0.0	1.0	23469
b[(Intercept) peak_name:Ama_Dablam]	0.0	1.0	2611
b[(Intercept) peak_name:Annapurna_I]	0.0	1.0	11513
b[(Intercept) peak_name:Annapurna_II]	0.0	1.0	14087
b[(Intercept) peak_name:Annapurna_III]	0.0	1.0	14160
b[(Intercept) peak_name:Annapurna_IV]	0.0	1.0	12896
b[(Intercept) peak_name:Baruntse]	0.0	1.0	2936
b[(Intercept) peak_name:Bhrikuti]	0.0	1.0	16349
b[(Intercept) peak_name:Chamlang]	0.0	1.0	4782

b[(Intercept) peak_name:Cho_Oyu]	0.0	1.0	2799
b[(Intercept) peak_name:Dhaulagiri_I]	0.0	1.0	3861
b[(Intercept) peak_name:Dhampus]	0.0	1.0	15712
b[(Intercept) peak_name:Dzanye_II]	0.0	1.0	10754
b[(Intercept) peak_name:Everest]	0.0	1.0	2798
b[(Intercept) peak_name:Fang]	0.0	1.0	13941
b[(Intercept) peak_name:Ganesh_III]	0.0	1.0	8925
b[(Intercept) peak_name:Gaurishankar]	0.0	1.0	15932
b[(Intercept) peak_name:Gurkarpo_Ri]	0.0	1.0	16838
b[(Intercept) peak_name:Gyajikang]	0.0	1.0	15907
b[(Intercept) peak_name:Himlung_Himal]	0.0	1.0	3318
b[(Intercept) peak_name:Jannu]	0.0	1.0	13518
b[(Intercept) peak_name:Jethi_Bahurani]	0.0	1.0	9051
b[(Intercept) peak_name:Kabru_Dome]	0.0	1.0	7419
b[(Intercept) peak_name:Kangchenjunga]	0.0	1.0	4672
b[(Intercept) peak_name:Kwangde]	0.0	1.0	11439
b[(Intercept) peak_name:Langtang_Lirung]	0.0	1.0	16677
b[(Intercept) peak_name:Leonpo_Gang_East]	0.0	1.0	15518
b[(Intercept) peak_name:Lhotse]	0.0	1.0	6718
b[(Intercept) peak_name:Langju]	0.0	1.0	15769
b[(Intercept) peak_name:Lhotse_Shar]	0.0	1.0	7326
b[(Intercept) peak_name:Makalu]	0.0	1.0	3449
b[(Intercept) peak_name:Manaslu]	0.0	1.0	2987
b[(Intercept) peak_name:Nampa]	0.0	1.0	16131
b[(Intercept) peak_name:Nemjung]	0.0	1.0	15395
b[(Intercept) peak_name:Nilgiri_Central]	0.0	1.0	8325
b[(Intercept) peak_name:Nuptse]	0.0	1.0	15169
b[(Intercept) peak_name:Ohmi_Kangri]	0.0	1.0	7317
b[(Intercept) peak_name:Pumori]	0.0	1.0	4357
b[(Intercept) peak_name:Putha_Hiunchuli]	0.0	1.0	6345
b[(Intercept) peak_name:Shalbachum]	0.0	1.0	16089
b[(Intercept) peak_name:Sphinx]	0.0	1.0	9184
b[(Intercept) peak_name:Syaokang]	0.0	1.0	10206
b[(Intercept) peak_name:Tawoche]	0.0	1.0	15950
b[(Intercept) peak_name:Tilicho]	0.0	1.0	3687
b[(Intercept) peak_name:Teng Kangpoche]	0.0	1.0	14816
b[(Intercept) peak_name:Tukuche]	0.0	1.0	3761
Sigma[peak_name:(Intercept),(Intercept)]	0.0	1.0	5225
mean_PPD	0.0	1.0	19329
log-posterior	0.1	1.0	3952

For each parameter, mcse is Monte Carlo standard error, n_eff is a crude measure of effective

Priors for model 'modjs'

Intercept (after predictors centered)

~ normal(location = 0, scale = 2.5)

Coefficients

Specified prior:

~ normal(location = [0,0,0,...], scale = [2.5,2.5,2.5,...])


Adjusted prior:



~ normal(location = [0,0,0,...], scale = [5.51, 5.05,15.14,...])

Covariance

~ decov(reg. = 1, conc. = 1, shape = 1, scale = 1)

See `help('prior_summary.stanreg')` for more details





(Intercept)
0.24870
premiumTRUE

```

                                0.87620
                                ciclo_mercadoAutumn
                                0.26945
                                ciclo_mercadoWinter
                                0.24635
                                ciclo_mercadoSummer
                                0.37660
                                años_desde_listing
                                0.88870
                                b[(Intercept) ciclo_mercado:Spring]
                                0.23825
                                b[(Intercept) ciclo_mercado:Autumn]
                                0.30675
                                b[(Intercept) ciclo_mercado:Winter]
                                0.32580
                                b[(Intercept) ciclo_mercado:Summer]
                                0.65680
                                Sigma[ciclo_mercado:(Intercept),(Intercept)]
                                0.21905

```

Model Info:

```

function:      stan_glmer
family:        binomial [logit]
formula:       compra ~ premium + ciclo_mercado + años_desde_listing + (1 |
               ciclo_mercado)
algorithm:     sampling
sample:        20000 (posterior sample size)
priors:        see help('prior_summary')
observations:  2069
groups:        ciclo_mercado (4)

```

Estimates:

	mean	sd	10%	50%	90%
(Intercept)	-1.8	0.9	-2.7	-1.8	-0.8
premiumTRUE	3.3	0.2	3.1	3.3	3.5
ciclo_mercadoAutumn	0.8	1.2	-0.6	0.8	2.0
ciclo_mercadoWinter	-0.3	1.4	-1.7	-0.2	1.2
ciclo_mercadoSummer	39.8	27.4	9.6	34.1	78.4
años_desde_listing	0.0	0.0	0.0	0.0	0.0
b[(Intercept) ciclo_mercado:Spring]	-0.1	0.8	-1.0	0.0	0.8
b[(Intercept) ciclo_mercado:Autumn]	0.0	0.9	-0.9	0.0	0.9

b[(Intercept) ciclo_mercado:Winter]	0.0	1.0	-1.0	0.0	1.0
b[(Intercept) ciclo_mercado:Summer]	0.0	1.1	-1.0	0.0	1.0
Sigma[ciclo_mercado:(Intercept),(Intercept)]	1.1	2.1	0.0	0.3	3.0

Fit Diagnostics:

	mean	sd	10%	50%	90%
mean_PPD	0.4	0.0	0.4	0.4	0.4

The mean_ppd is the sample average posterior predictive distribution of the outcome variable

MCMC diagnostics

	mcse	Rhat	n_eff
(Intercept)	0.0	1.0	4974
premiumTRUE	0.0	1.0	17524
ciclo_mercadoAutumn	0.0	1.0	5389
ciclo_mercadoWinter	0.0	1.0	4927
ciclo_mercadoSummer	0.3	1.0	7532
años_desde_listing	0.0	1.0	17774
b[(Intercept) ciclo_mercado:Spring]	0.0	1.0	4765
b[(Intercept) ciclo_mercado:Autumn]	0.0	1.0	6135
b[(Intercept) ciclo_mercado:Winter]	0.0	1.0	6516
b[(Intercept) ciclo_mercado:Summer]	0.0	1.0	13136
Sigma[ciclo_mercado:(Intercept),(Intercept)]	0.0	1.0	4381
mean_PPD	0.0	1.0	20328
log-posterior	0.0	1.0	7794

For each parameter, mcse is Monte Carlo standard error, n_eff is a crude measure of effective