

Proyecto Inferencia II: Climbers

Santiago Robatto, Diego Da Rosa, Sofía Terra, Nahuel Bizoso

```
# A tibble: 2,076 x 24
  expedition_id member_id peak_id peak_name year season sex age
  <chr>         <fct>    <fct>    <fct>    <dbl> <fct> <fct> <dbl>
1 AMAD81101    AMAD81101-03 AMAD     Ama Dablam 1981 Spring M      28
2 AMAD81101    AMAD81101-04 AMAD     Ama Dablam 1981 Spring M      27
3 AMAD81101    AMAD81101-02 AMAD     Ama Dablam 1981 Spring M      35
4 AMAD81101    AMAD81101-05 AMAD     Ama Dablam 1981 Spring M      37
5 AMAD81101    AMAD81101-06 AMAD     Ama Dablam 1981 Spring M      43
6 AMAD81101    AMAD81101-07 AMAD     Ama Dablam 1981 Spring M      38
7 AMAD81101    AMAD81101-08 AMAD     Ama Dablam 1981 Spring M      23
8 AMAD81101    AMAD81101-01 AMAD     Ama Dablam 1981 Spring M      36
9 AMAD81101    AMAD81101-09 AMAD     Ama Dablam 1981 Spring M      48
10 AMAD81101    AMAD81101-11 AMAD     Ama Dablam 1981 Spring M      25
# i 2,066 more rows
# i 16 more variables: citizenship <fct>, expedition_role <fct>, hired <lgl>,
#   highpoint_metres <dbl>, success <lgl>, solo <lgl>, oxygen_used <lgl>,
#   died <lgl>, death_cause <fct>, death_height_metres <dbl>, injured <lgl>,
#   injury_type <fct>, injury_height_metres <dbl>, count <int>,
#   height_metres <dbl>, first_ascent_year <dbl>
```

Introducción

- El dataset contiene información de interacciones comerciales cliente–propiedad en el mercado inmobiliario y cuenta con 24 variables y 2076 observaciones.
- Algunas variables refieren a las características sociodemográficas del lead/cliente, mientras que otras describen los atributos del inmueble visitado.
- La variable de interés es la decisión de compra (compra: 1 = compró el inmueble, 0 = no compró), la cual es binaria.
- La compra representa un evento de conversión comercial real, análogo a un cierre de venta.

- En el contexto original, el éxito se daba al alcanzar la cima del pico; en esta reconversión, el éxito se interpreta como que el cliente decidió adquirir la propiedad que visitó, lo cual nos lleva naturalmente a plantear un modelo de clasificación con enlace logístico para estimar probabilidades de conversión.
- Esto nos hace pensar en un modelo logístico (regresión logística) para explicar y/o predecir la compra.

Dado que queremos modelar un suceso de la realidad que es binario (compra o no compra de un inmueble), asumimos que la forma adecuada de representar la incertidumbre de cada lead es mediante una distribución Bernoulli, con probabilidad de compra individual π_i (probabilidad de conversión del lead i frente a la propiedad que visitó). Por lo tanto, nuestra variable de respuesta Y se distribuye:

$$Y_i \mid \pi_i \sim \text{Bern}(\pi_i)$$

con:

$$E(Y_i \mid \pi_i) = \pi_i$$

A su vez, a la hora de armar el modelo, utilizaremos las odds. Recordemos que las odds son una manera distinta de mirar las probabilidades, donde comparamos la probabilidad de éxito con opuesto: $\text{odds} = \frac{\pi}{1-\pi}$

Entonces:

$$Y_i \mid \beta_0, \beta_1 \dots \beta_n \sim \text{Bern}(\pi_i) \text{ , con } \log\left(\frac{\pi_i}{1-\pi_i}\right) = \mathbf{x}_i^\top \beta.$$

Con:

$$\beta_0 \sim N(m_0, s_0^2) \beta_1 \sim N(m_1, s_1^2) : \beta_n \sim N(m_n, s_n^2)$$

Podemos despejar las probabilidad π_i en un modelo logístico de las siguientes maneras:

$$\frac{\pi_i}{1-\pi_i} = e^{\beta_0 + \beta_1 X_{i1}} \quad \text{o, despejando} \quad \pi_i = \frac{e^{\beta_0 + \beta_1 X_{i1}}}{1 + e^{\beta_0 + \beta_1 X_{i1}}}$$

En cambio, dado que queremos incorporar jerarquias, debemos hacer ciertos cambios sobre el modelo. Mas precisamente, queremos reflejar que los parametros β_i dependen de cada grupo.

$$Y_{ij} \mid \pi_{ij} \sim \text{Bern}(\pi_{ij})$$

$$\text{con } \log\left(\frac{\pi_{ij}}{1-\pi_{ij}}\right) = \beta_{0j} + \sum_{k=1}^p \beta_k X_{ijk}$$

$$\beta_{0j} \mid \beta_0, \sigma_0 \stackrel{\text{ind}}{\sim} N(\beta_0, \sigma_0^2) \text{ representa la variabilidad entre grupos}$$

Las Priors globales son:

$$\beta_0 \sim N(m_0, s_0^2)$$

y

$$\beta_k \sim N(m_k, s_k^2) \quad \text{para } k = 1 \dots p$$

y el error es

$$\sigma_0 \sim \text{Exp}(\lambda)$$

De la misma manera podemos expresar los interceptos como:

$$\beta_{0j} = \beta_0 + b_{0j}$$

$$\text{por lo que} \quad \log\left(\frac{\pi_{ij}}{1 - \pi_{ij}}\right) = (\beta_0 + b_{0j}) + \beta_1 X_{ij1} + \beta_2 X_{ij2} + \dots + \beta_n X_{ijn}$$

En resumen,

Los interceptos específicos de cada grupo β_{0j} representan la tasa base de éxito (en log-odds) para cada grupo j . Esto permite diferenciar cada grupo entre si, donde por ejemplo algunos grupos tienen niveles de éxito más altos que otros.

Estos interceptos β_{0j} se modelan como distribuidos Normalmente alrededor de un intercepto global β_0 con desviación estándar σ_0 . El parámetro β_0 refleja la tasa de éxito promedio entre todos los grupos. La cantidad σ_0 mide la variabilidad entre grupos, es decir, cuánto difieren unos de otros.

De igual manera que en el resto de modelos, los interceptos $\beta_1, \beta_2 \dots$ siguen describiendo las relaciones globales entre las variables.

Info de las variables:

Table 1: Descripción de Variables del Dataset Inmobiliario (Conversión de Compra)

Variable	Tipo_dato	Descripción
campana	character	Identificador de la campaña o fuente de captación del lead
cliente_id	factor	Identificador único del cliente potencial (lead)
propiedad_id	factor	Identificador único de la propiedad consultada o visitada
propiedad	factor	Nombre o tipo de propiedad (casa, apartamento, etc.)
año_interaccion	numeric	Año en que ocurrió la interacción cliente-propiedad
ciclo_mercado	factor	Ciclo de demanda del mercado inmobiliario (temporada del mercado)
sexo	character	Sexo del cliente
edad	numeric	Edad del cliente
origen	factor	País u origen del lead
rol_decision	factor	Rol del lead en la decisión de compra (titular, inversor, cónyuge, etc.)
partner_externo	logical	Indica si el lead provino de un partner externo (TRUE = sí, FALSE = no)

interes_max	numeric	Nivel máximo de interés mostrado en la visita (proxy comercial en metros observados/recorridos)
compra	logical	Conversión de compra (TRUE = compra concretada, FALSE = no concretada)
decision_individual	logical	Indica si la decisión de compra fue individual (TRUE) o compartida/grupal (FALSE)
premium	logical	Indica si la propiedad es premium o tiene amenities diferenciales (TRUE = sí, FALSE = no)
lead_fallo	logical	Indica si el lead falló críticamente en el proceso de conversión (TRUE = sí, FALSE = no)
motivo_fallo	factor	Motivo del fallo crítico de conversión (solo si lead_fallo = TRUE)
tam_fallo	numeric	Tamaño de la propiedad al momento del fallo crítico (si aplica)
friccion	logical	Indica si hubo fricción o incidente en el proceso de compra (TRUE = sí, FALSE = no)
tipo_incidente	factor	Tipo de incidente en la conversión (crédito rechazado, documentación, tasación baja, etc.)
tam_incidente	numeric	Tamaño de la propiedad al momento del incidente (si aplica)
asesores	numeric	Cantidad de asesores/vendedores que atendieron al lead
tam_propiedad	numeric	Metros cuadrados totales de la propiedad
año_primer_listing	numeric	Año en que la propiedad salió al mercado por primera vez (proxy a antigüedad del listing)

A tibble: 2,076 x 24

	expedition_id	member_id	peak_id	peak_name	year	season	sex	age
	<chr>	<fct>	<fct>	<fct>	<dbl>	<fct>	<fct>	<dbl>
1	AMAD81101	AMAD81101-03	AMAD	Ama Dablam	1981	Spring	M	28
2	AMAD81101	AMAD81101-04	AMAD	Ama Dablam	1981	Spring	M	27
3	AMAD81101	AMAD81101-02	AMAD	Ama Dablam	1981	Spring	M	35
4	AMAD81101	AMAD81101-05	AMAD	Ama Dablam	1981	Spring	M	37
5	AMAD81101	AMAD81101-06	AMAD	Ama Dablam	1981	Spring	M	43
6	AMAD81101	AMAD81101-07	AMAD	Ama Dablam	1981	Spring	M	38
7	AMAD81101	AMAD81101-08	AMAD	Ama Dablam	1981	Spring	M	23
8	AMAD81101	AMAD81101-01	AMAD	Ama Dablam	1981	Spring	M	36
9	AMAD81101	AMAD81101-09	AMAD	Ama Dablam	1981	Spring	M	48
10	AMAD81101	AMAD81101-11	AMAD	Ama Dablam	1981	Spring	M	25

i 2,066 more rows


i 16 more variables: citizenship <fct>, expedition_role <fct>, hired <lgl>,
highpoint_metres <dbl>, success <lgl>, solo <lgl>, oxygen_used <lgl>,
died <lgl>, death_cause <fct>, death_height_metres <dbl>, injured <lgl>,
injury_type <fct>, injury_height_metres <dbl>, count <int>,
height_metres <dbl>, first_ascent_year <dbl>

Variable	Min	Q1	Median	Mean	Q3	Max
año_interaccion	1978	1996	2006	2002.87331	2011	2019
edad	17	29	36	36.95713	43	76
interes_max	4900	6750	7400	7554.86446	8850	8850
tam_fallo	3400	6150	6600	6771.05263	7800	8650
tam_incidente	3960	5575	6325	6406.42857	6950	8400
asesores	5	8	11	13.88439	18	44
tam_propiedad	5929	7138	8167	7989.03805	8850	8850

año_primer_listing	1936	1953	1954	1959.22378	1961	2017
--------------------	------	------	------	------------	------	------

Variable	TRUEs	Total	Porcentaje_TRUE
partner_externo	485	2076	23.36
compra	807	2076	38.87
decision_individual	2	2076	0.10
premium	601	2076	28.95
lead_fallo	19	2076	0.92
friccion	24	2076	1.16

Matriz de Correlacion:







Nueva Variable



Mide cuántos años pasaron desde que la propiedad fue listada por primera vez hasta la interacción actual con el cliente. Refleja el tiempo de exposición del activo inmobiliario, lo cual puede influir en la probabilidad de compra:

Propiedades con mucha exposición pueden indicar sobreprecio, baja demanda o problemas no observados.


Propiedades nuevas en el mercado suelen generar más interés y conversiones rápidas.

También puede asociarse a estrategias de negocio como descuentos por tiempo de publicación, rotación de inventario y urgencia comercial.






Análisis de Variables Numéricas (Contexto Inmobiliario)



Las cajas representan el rango intercuartílico (IQR)

Análisis de Variables Categóricas (Inmobiliario)
Probabilidad de compra según factores clave (proporciones)



Gráficos normalizados al 100%