

Muestreo

```
library(ggplot2)
```

Warning: package 'ggplot2' was built under R version 4.4.3

```
data(diamonds)
diamonds
```

```
# A tibble: 53,940 x 10
```

	carat	cut	color	clarity	depth	table	price	x	y	z
	<dbl>	<ord>	<ord>	<ord>	<dbl>	<dbl>	<int>	<dbl>	<dbl>	<dbl>
1	0.23	Ideal	E	SI2	61.5	55	326	3.95	3.98	2.43
2	0.21	Premium	E	SI1	59.8	61	326	3.89	3.84	2.31
3	0.23	Good	E	VS1	56.9	65	327	4.05	4.07	2.31
4	0.29	Premium	I	VS2	62.4	58	334	4.2	4.23	2.63
5	0.31	Good	J	SI2	63.3	58	335	4.34	4.35	2.75
6	0.24	Very Good	J	VVS2	62.8	57	336	3.94	3.96	2.48
7	0.24	Very Good	I	VVS1	62.3	57	336	3.95	3.98	2.47
8	0.26	Very Good	H	SI1	61.9	55	337	4.07	4.11	2.53
9	0.22	Fair	E	VS2	65.1	61	337	3.87	3.78	2.49
10	0.23	Very Good	H	VS1	59.4	61	338	4	4.05	2.39

```
# i 53,930 more rows
```

Contiene datos sobre clientes de un banco (edad, trabajo, saldo, si aceptaron un préstamo).

```
library(tidyverse)
```

Warning: package 'tidyverse' was built under R version 4.4.3

Warning: package 'tibble' was built under R version 4.4.3

Warning: package 'tidyr' was built under R version 4.4.3

Warning: package 'readr' was built under R version 4.4.3

Warning: package 'purrr' was built under R version 4.4.3

Warning: package 'dplyr' was built under R version 4.4.3

Warning: package 'stringr' was built under R version 4.4.3

Warning: package 'forcats' was built under R version 4.4.3

Warning: package 'lubridate' was built under R version 4.4.3

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
```

```
v dplyr      1.1.4      v readr      2.1.5
```

```
v forcats    1.0.0      v stringr    1.5.1
```

```
v lubridate  1.9.4      v tibble     3.2.1
```

```
v purrr      1.0.4      v tidyr      1.3.1
```

```
-- Conflicts ----- tidyverse_conflicts() --
```

```
x dplyr::filter() masks stats::filter()
```

```
x dplyr::lag()     masks stats::lag()
```

```
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
# Carga de datos (puedes descargarlo o leerlo directamente si tienes el link)
url <- "https://archive.ics.uci.edu/ml/machine-learning-databases/00222/bank.zip"
temp <- tempfile()
download.file(url, temp)
bank_data <- read.table(unz(temp, "bank.csv"), sep = ";", header = TRUE)
unlink(temp)

# Ver la estructura
str(bank_data)
```

```
'data.frame':  4521 obs. of  17 variables:
```

```
$ age      : int  30 33 35 30 59 35 36 39 41 43 ...
```

```
$ job      : chr  "unemployed" "services" "management" "management" ...
```

```
$ marital  : chr  "married" "married" "single" "married" ...
```

```
$ education: chr  "primary" "secondary" "tertiary" "tertiary" ...
```

```
$ default  : chr  "no" "no" "no" "no" ...
```

```

$ balance : int 1787 4789 1350 1476 0 747 307 147 221 -88 ...
$ housing : chr "no" "yes" "yes" "yes" ...
$ loan : chr "no" "yes" "no" "yes" ...
$ contact : chr "cellular" "cellular" "cellular" "unknown" ...
$ day : int 19 11 16 3 5 23 14 6 14 17 ...
$ month : chr "oct" "may" "apr" "jun" ...
$ duration : int 79 220 185 199 226 141 341 151 57 313 ...
$ campaign : int 1 1 1 4 1 2 1 2 2 1 ...
$ pdays : int -1 339 330 -1 -1 176 330 -1 -1 147 ...
$ previous : int 0 4 1 0 0 3 2 0 0 2 ...
$ poutcome : chr "unknown" "failure" "failure" "unknown" ...
$ y : chr "no" "no" "no" "no" ...

```

```
#bank_data
```

```
sum(is.na(bank_data))
```

```
[1] 0
```

```
# Resumen estadístico
```

```
summary(bank_data$balance)
```

```

      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
-3313      69      444    1423    1480    71188

```

```
# Visualización de la distribución
```


```
library(ggplot2)
```

```
ggplot(bank_data, aes(x = balance)) +
```


```
  geom_histogram(bins = 50, fill = "steelblue", color = "white") +
```

```
  theme_minimal() +
```

```
  labs(title = "Distribución del Saldo Bancario", x = "Saldo", y = "Frecuencia")
```



```
ggplot(bank_data, aes(x = job, y = balance, fill = job)) +  
  geom_boxplot() +  
  coord_flip() + # Para leer mejor los nombres de los trabajos  
  theme_minimal() +  
  theme(legend.position = "none") +  
  labs(title = "Saldo por Tipo de Trabajo")
```



```
# 1. Real
media_real <- mean(bank_data$balance)
```

```
# 2. MAS (Simple)
set.seed(123) # Para que tus resultados sean reproducibles
muestra_simple <- bank_data %>% sample_frac(0.05)
media_mas <- mean(muestra_simple$balance)
```

```
# 3. Estratificado (por job)
muestra_estrat <- bank_data %>%
  group_by(job) %>%
  sample_frac(0.05) %>%
  ungroup()
media_estrat <- mean(muestra_estrat$balance)
```

```
# Definimos la probabilidad de inclusión (ej. 5%)
prob_inclusion <- 0.05

set.seed(123)
# Cada fila tiene su propio "lanzamiento de moneda"
muestra_bernoulli <- bank_data %>%
  filter(rbinom(n(), 1, prob_inclusion) == 1)
```

```
# ¿Cuántos clientes terminaron en la muestra?
nrow(muestra_bernoulli)
```

```
[1] 216
```

```
# Estimador del Total de saldos (Horvitz-Thompson)
total_est_ht <- sum(muestra_bernoulli$balance / prob_inclusion)

# Estimador de la Media (Hajek)
media_est_bernoulli <- sum(muestra_bernoulli$balance / prob_inclusion) /
  sum(1 / prob_inclusion)

# Comparar con la real
media_real <- mean(bank_data$balance)
print(paste("Real:", media_real, "| Bernoulli:", media_est_bernoulli))
```

```
[1] "Real: 1422.65781906658 | Bernoulli: 286870"
```

```
# Comparación rápida
data.frame(Metodo = c("Real", "Simple", "Estratificado"),
  Media = c(media_real, media_mas, media_estrat))
```

	Metodo	Media
1	Real	1422.658
2	Simple	1541.482
3	Estratificado	1472.569

```
set.seed(123)
simulaciones <- 1000
resultados <- data.frame(metodo = character(), media = numeric())

for(i in 1:simulaciones) {
  # MAS (Tamaño fijo)
  m_mas <- bank_data %>% sample_n(226)
  resultados <- rbind(resultados, data.frame(metodo = "MAS", media = mean(m_mas$balance)))


  # Bernoulli (Tamaño aleatorio)
  m_bern <- bank_data %>% filter(rbinom(n(), 1, 0.05) == 1)
  # Usamos la media de Hajek para mayor precisión
```

```

media_h <- sum(m_bern$balance / 0.05) / sum(1 / 0.05)
resultados <- rbind(resultados, data.frame(metodo = "Bernoulli", media = media_h))
}

# Visualización
ggplot(resultados, aes(x = media, fill = metodo)) +
  geom_density(alpha = 0.5) +
  geom_vline(xintercept = media_real, linetype = "dashed", color = "red") +
  theme_minimal() +
  labs(title = "Distribución de Medias: MAS vs Bernoulli",
       subtitle = "La línea roja es la media poblacional real",
       x = "Saldo Promedio Estimado", y = "Densidad")

```



```

library(tidyverse)

# Asumiendo que ya tienes el dataframe 'resultados' de la simulación anterior
# con las columnas 'metodo' y 'media'

media_real <- mean(bank_data$balance)

metricas <- resultados %>%
  group_by(metodo) %>%

```

```

summarise(
  Media_Estimadores = mean(media),
  Sesgo = mean(media) - media_real,
  Varianza = var(media),
  MSE = mean((media - media_real)^2),
  RMSE = sqrt(MSE),
  CV = (sd(media) / mean(media)) * 100
)

print(metrics)

```

```

# A tibble: 2 x 7
  metodo      Media_Estimadores      Sesgo      Varianza      MSE      RMSE      CV
  <chr>          <dbl>      <dbl>      <dbl>      <dbl>      <dbl> <dbl>
1 Bernoulli      317694.  316271.  2340660053. 102365794619. 319947.  15.2
2 MAS             1426.    3.77    35167.      35146.      187.   13.1

```

```

ggplot(resultados, aes(x = media, color = metodo, fill = metodo)) +
  geom_density(alpha = 0.2) +
  geom_vline(xintercept = media_real, linetype = "dashed", size = 1) +
  labs(
    title = "Distribución de los Estimadores vs. Valor Real",
    subtitle = "La cercanía al centro es el Sesgo; la anchura es la Varianza",
    x = "Estimación del Saldo Promedio",
    y = "Densidad"
  ) +
  theme_minimal()

```

Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
 i Please use `linewidth` instead.



```
library(tidyverse)

# 1. Definimos probabilidades desiguales
# Clientes con hipoteca: 10% de prob. | Sin hipoteca: 5% de prob.
bank_data <- bank_data %>%
  mutate(pi_i = ifelse(housing == "yes", 0.10, 0.05))

# 2. Extraemos la muestra basada en esas probabilidades (Bernoulli Desigual)
set.seed(456)
muestra_ht <- bank_data %>%
  filter(runif(n()) <= pi_i)

# 3. Aplicamos el Estimador de Horvitz-Thompson para el TOTAL del Balance
total_poblacional_real <- sum(bank_data$balance)

total_est_ht <- sum(muestra_ht$balance / muestra_ht$pi_i)

# 4. Estimador de la MEDIA (Hajek)
# El estimador HT para la media usa el tamaño poblacional N
N <- nrow(bank_data)
media_est_ht <- total_est_ht / N


# Comparación
```

```
data.frame(
  Concepto = c("Total", "Media"),
  Real = c(total_poblacional_real, mean(bank_data$balance)),
  Estimado_HT = c(total_est_ht, media_est_ht)
)
```

	Concepto	Real	Estimado_HT
1	Total	6431836.000	6100930.000
2	Media	1422.658	1349.465


```
muestra_ht <- muestra_ht %>%
  mutate(peso = 1 / pi_i)

ggplot(muestra_ht, aes(x = balance, y = peso, color = housing)) +
  geom_point(alpha = 0.5) +
  labs(title = "Relación entre Balance y Peso de Expansión",
       subtitle = "Los clientes con pi=0.05 tienen un peso de 20; con pi=0.10 tienen un peso",
       x = "Saldo (y_i)", y = "Peso (1/pi_i)") +
  theme_minimal()
```



```
# Probabilidad de seleccion
# Visualizando la relación inversa
ejemplo_pesos <- data.frame(
  Probabilidad = seq(0.01, 0.5, by = 0.01)
) %>%
  mutate(Peso_Expansion = 1 / Probabilidad)

ggplot(ejemplo_pesos, aes(x = Probabilidad, y = Peso_Expansion)) +
  geom_line(color = "firebrick", size = 1) +
  labs(title = "Relación entre Probabilidad de Selección y Peso (Incluso)",
       x = "Probabilidad (Pi)", y = "Factor de Expansión (W)") +
  theme_minimal()
```



SIR y Con reemplazo (Simple)

```
n_muestra <- 500

# MAS Sin Reemplazo (Por defecto en R)
set.seed(123)
muestra_sin <- bank_data[sample(nrow(bank_data), n_muestra, replace = FALSE), ]

# MAS Con Reemplazo
set.seed(123)
```

```
muestra_con <- bank_data[sample(nrow(bank_data), n_muestra, replace = TRUE), ]

# ¿Hubo repetidos en la muestra con reemplazo?
anyDuplicated(muestra_con) # Si devuelve > 0, hay filas repetidas
```

```
[1] 59
```

```
sim_varianza <- replicate(1000, {
  m_sin <- bank_data$balance[sample(nrow(bank_data), 200, replace = FALSE)]
  m_con <- bank_data$balance[sample(nrow(bank_data), 200, replace = TRUE)]
  c(media_sin = mean(m_sin), media_con = mean(m_con))
})

# Convertir a data frame y comparar desviaciones estándar
sim_res <- as.data.frame(t(sim_varianza))
sd(sim_res$media_sin) # Debería ser ligeramente menor
```

```
[1] 207.0137
```

```
sd(sim_res$media_con)
```

```
[1] 209.4216
```

estimador pwr

```
library(tidyverse)

# 1. Definir probabilidades de selección (p_i)
# Deben sumar 1 en toda la población
bank_data <- bank_data %>%
  mutate(prioridad = case_when(
    education == "tertiary" ~ 3,
    education == "secondary" ~ 2,
    TRUE ~ 1
  )) %>%
  mutate(p_i = prioridad / sum(prioridad))

# 2. Realizar el muestreo CON reemplazo (n = 500)
n_muestras <- 500
```

```

set.seed(789)
indices_pwr <- sample(1:nrow(bank_data), size = n_muestras, replace = TRUE, prob = bank_data$balance)
muestra_pwr <- bank_data[indices_pwr, ]

# 3. Calcular el Estimador pwr para el TOTAL
# Aplicamos la fórmula: (1/n) * suma(y_i / p_i)
total_pwr <- (1 / n_muestras) * sum(muestra_pwr$balance / muestra_pwr$p_i)

# 4. Calcular la MEDIA estimada
media_pwr <- total_pwr / nrow(bank_data)

# Comparación
media_real <- mean(bank_data$balance)
print(paste("Media Real:", round(media_real, 2)))

```

```
[1] "Media Real: 1422.66"
```

```
print(paste("Media Estimador pwr:", round(media_pwr, 2)))
```

```
[1] "Media Estimador pwr: 1218.67"
```

```

# Cálculo de la varianza del total en R
valores_expandidos <- muestra_pwr$balance / muestra_pwr$p_i
var_total_pwr <- (1 / (n_muestras * (n_muestras - 1))) * sum((valores_expandidos - total_pwr)^2)

# Error estándar de la media
se_media_pwr <- sqrt(var_total_pwr) / nrow(bank_data)

```

Efecto Diseño (deff)

```

# Instalación y carga
if(!require(survey)) install.packages("survey")

```

Cargando paquete requerido: survey

Warning: package 'survey' was built under R version 4.4.3

Cargando paquete requerido: grid

Cargando paquete requerido: Matrix

Adjuntando el paquete: 'Matrix'

The following objects are masked from 'package:tidyr':

expand, pack, unpack

Cargando paquete requerido: survival

Adjuntando el paquete: 'survey'

The following object is masked from 'package:graphics':

dotchart

```
library(survey)

# 1. Definir el diseño de muestreo (ej. Estratificado por Educación)
# Usamos 'fpc' para indicar que es sin reemplazo
diseno_estrat <- svydesign(
  id = ~1,
  strata = ~education,
  data = bank_data,
  fpc = rep(nrow(bank_data), nrow(bank_data))
)

# 2. Calcular la media y pedir el DEFF
resultado <- svymean(~balance, diseno_estrat, deff = TRUE)

# Ver el resultado
print(resultado)
```

	mean	SE	DEff
balance	1521.257	66.297	2.6068

```
deff_valor <- deff(resultado)
print(paste("El Efecto de Diseño es:", round(deff_valor, 4)))
```

```
[1] "El Efecto de Diseño es: 2.6068"
```

Estimacion por dominios

```
library(survey)

# 1. Definimos el diseño completo primero (importante)
diseno_completo <- svydesign(
  id = ~1,
  data = bank_data,
  fpc = rep(nrow(bank_data), nrow(bank_data))
)

# 2. Creamos el dominio (subpoblación de interés)
# Ejemplo: Queremos estimar el balance solo para personas con educación 'tertiary'
diseno_dominio <- subset(diseno_completo, education == "tertiary")

# 3. Estimación
estimacion_dom <- svymean(~balance, diseno_dominio)
print(estimacion_dom)
```

```
      mean SE
balance 1775.4 0
```

```
# 4. Comparación: ¿Cómo cambia el error si el dominio es pequeño?
# Intentemos con un dominio más específico (ej. 'entrepreneur' con deuda)
diseno_pequeno <- subset(diseno_completo, job == "entrepreneur" & loan == "yes")
svymean(~balance, diseno_pequeno)
```

```
      mean SE
balance 1143.3 0
```

```
# Estimación del total en el dominio
svytotal(~balance, diseno_dominio)
```

```
      total SE
balance 2396822 0
```

Diseño Sistemático

```
# 1. Parámetros
N <- nrow(bank_data)
n <- 500
k <- floor(N / n)

# 2. Arranque aleatorio
set.seed(123)
arranque <- sample(1:k, 1)

# 3. Selección de índices
indices_sist <- seq(from = arranque, to = N, by = k)

# 4. Crear la muestra
muestra_sistemica <- bank_data[indices_sist, ]

# Verificación
nrow(muestra_sistemica)
```

```
[1] 503
```

```
library(survey)

# Definimos el diseño sistemático en 'survey'
# Se suele aproximar como MAS si no hay periodicidad
diseno_sist <- svydesign(
  id = ~1,
  data = muestra_sistemica,
  fpc = rep(N, nrow(muestra_sistemica))
)

svymean(~balance, diseno_sist)
```

```
      mean      SE
balance 1263.4 111.69
```