

Muestreo

Diego Da Rosa

El Muestreo es la parte de la estadística que selecciona muestras de la población objetivo, observa las características de las unidades de muestreo seleccionadas y luego usar esas observaciones para hacer inferencias sobre toda la población objetivo.

En nuestro caso tenemos una población objetivo que son todos los clientes actuales de un banco, nuestra población objetivo tiene un tamaño de $N = 45,211$ observaciones. En nuestro dataset tenemos datos sobre clientes de un banco (edad, tipo de trabajo, saldo, si aceptaron un préstamo).

Nuestro Marco Muestral (Sampling Frame) es la base de datos bank.csv.

La Unidad de Muestreo es el cliente individual.

```
library(tidyverse)
```

```
Warning: package 'tidyverse' was built under R version 4.4.3
```

```
Warning: package 'ggplot2' was built under R version 4.4.3
```

```
Warning: package 'tibble' was built under R version 4.4.3
```

```
Warning: package 'tidyr' was built under R version 4.4.3
```

```
Warning: package 'readr' was built under R version 4.4.3
```

```
Warning: package 'purrr' was built under R version 4.4.3
```

```
Warning: package 'dplyr' was built under R version 4.4.3
```

```
Warning: package 'stringr' was built under R version 4.4.3
```

Warning: package 'forcats' was built under R version 4.4.3

Warning: package 'lubridate' was built under R version 4.4.3

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.1.4      v readr      2.1.5
v forcats    1.0.0      v stringr    1.5.1
v ggplot2    4.0.0      v tibble     3.2.1
v lubridate  1.9.4      v tidyr      1.3.1
v purrr      1.0.4
```

```
-- Conflicts ----- tidyverse_conflicts() --
```

```
x dplyr::filter() masks stats::filter()
```

```
x dplyr::lag()     masks stats::lag()
```

```
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
# Carga de datos (puedes descargarlo o leerlo directamente si tienes el link)
url <- "https://archive.ics.uci.edu/ml/machine-learning-databases/00222/bank.zip"
temp <- tempfile()
download.file(url, temp)
bank_data <- read.table(unz(temp, "bank.csv"), sep = ";", header = TRUE)
unlink(temp)
```

```
# Ver la estructura
```

```
str(bank_data)
```

```
'data.frame':  4521 obs. of  17 variables:
 $ age      : int  30 33 35 30 59 35 36 39 41 43 ...
 $ job      : chr   "unemployed" "services" "management" "management" ...
 $ marital  : chr   "married" "married" "single" "married" ...
 $ education: chr   "primary" "secondary" "tertiary" "tertiary" ...
 $ default  : chr   "no" "no" "no" "no" ...
 $ balance  : int  1787 4789 1350 1476 0 747 307 147 221 -88 ...
 $ housing  : chr   "no" "yes" "yes" "yes" ...
 $ loan     : chr   "no" "yes" "no" "yes" ...
 $ contact  : chr   "cellular" "cellular" "cellular" "unknown" ...
 $ day      : int  19 11 16 3 5 23 14 6 14 17 ...
 $ month    : chr   "oct" "may" "apr" "jun" ...
 $ duration : int  79 220 185 199 226 141 341 151 57 313 ...
 $ campaign : int  1 1 1 4 1 2 1 2 2 1 ...
 $ pdays   : int  -1 339 330 -1 -1 176 330 -1 -1 147 ...
 $ previous : int  0 4 1 0 0 3 2 0 0 2 ...
```

```
$ poutcome : chr  "unknown" "failure" "failure" "unknown" ...
$ y         : chr  "no" "no" "no" "no" ...
```

```
#bank_data
```

```
sum(is.na(bank_data))
```

```
[1] 0
```

```
colnames(bank_data)
```

```
[1] "age"      "job"      "marital"  "education" "default"  "balance"
[7] "housing"  "loan"     "contact"  "day"       "month"    "duration"
[13] "campaign" "pdays"   "previous" "poutcome"  "y"
```

En muestreo lo que hacemos es obtener una muestra para realizar una estimación del promedio de una variable de interés, en nuestro caso nuestra variable de interés es “balance” que representa el dinero que tiene un usuario del banco y nos interesa estimar el promedio de esta variable (que en realidad el promedio es estimar el total y dividir esa estimación entre el tamaño de la población si es conocido o entre el tamaño de la muestra) que es una variable continua con alta asimetría y valores atípicos, lo cual nos influirá al querer obtener una estimación del promedio de esta variable.

Luego contamos con variables auxiliares, que son todas las demás variables del set de datos, como job, education, marital, age, etc que puede o no tener una correlación con nuestra variables de interés que es balance, cuanto más correlación haya entre alguna de estas variables auxiliares y balance, mejores serán las estimaciones. Estas variables también nos servirán para diversos métodos que veremos más adelante como Estratificación, Raking, Post-estratificación.


Los datos provienen de una base de datos institucional. Dado que los recursos para realizar encuestas a profundidad son limitados, se requiere un diseño muestral que capture la variabilidad del balance sin sesgar los resultados hacia grupos sobre-representados (como clientes con empleos administrativos).

Si empezamos explorando la distribución de nuestra variable de interés balance

```
# Resumen estadístico
summary(bank_data$balance)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-3313	69	444	1423	1480	71188

```
# Visualización de la distribución
library(ggplot2)
ggplot(bank_data, aes(x = balance)) +
  geom_histogram(bins = 50, fill = "steelblue", color = "white") +
  theme_minimal() +
  labs(title = "Distribución del Saldo Bancario", x = "Saldo", y = "Frecuencia")
```



Vemos que tenemos asimetría extrema con un sesgo a la derecha.


La gráfica muestra una concentración masiva de clientes en saldos bajos, cercanos a 0, y una cola muy larga hacia la derecha. Esta asimetría nos causara problemas mas adelante los cuales resolveremos.

Si hacemos un Muestreo Aleatorio Simple (MAS), tienes una probabilidad altísima de no seleccionar a ninguno de los clientes con saldos altos (los que están en la cola derecha). Esto causaría una subestimación sistemática del saldo promedio del banco.

Ahora en cuanto a las distintas profesiones

```
ggplot(bank_data, aes(x = job, y = balance, fill = job)) +
  geom_boxplot() +
  coord_flip() + # Para leer mejor los nombres de los trabajos
  theme_minimal() +
```

```
theme(legend.position = "none") +
labs(title = "Saldo por Tipo de Trabajo")
```



Observamos los valores atípicos que pueden generar problemas al usar esta covariable para explicar a nuestra variable de interés balance, además vemos que hay grupos como retired (jubilados) o management que tienen cajas más anchas y bigotes más largos (más variabilidad), y hay otros grupos más uniformes como services o blue-collar. Además la variabilidad cambia según el trabajo, por lo que sería bueno que el diseño muestral a usar considere el empleo como variable de control, porque uno que no lo haga será ineficiente.

Para obtener la media real (de nuestra población) usamos el siguiente código y obtenemos el valor de 1422.658

```
# 1. Real
media_real <- mean(bank_data$balance)
media_real
```

```
[1] 1422.658
```

Muestreo Aleatorio Simple sin Reemplazo

Todos los clientes de tu base de datos tienen exactamente la misma probabilidad de ser seleccionados, la cual es $\pi_i = \frac{n}{N}$, es decir, la probabilidad de seleccionar al individuo i es el tamaño

de la muestra dividido el tamaño de la población, por ejemplo si nuestra población tuviera 1000 datos y sacamos una muestra de 100 personas, la probabilidad de que cualquier persona de la muestra sea seleccionado es $100/1000 = 0.1$. Este diseño cumple el supuesto de Independencia, el cual dice que la selección de un cliente con saldo alto no afecta la probabilidad de seleccionar a otro con saldo bajo. Este diseño considera que el tamaño de la muestra es fijo, que no varía y nosotros podemos obtener una muestra de un tamaño que nos interese. En este MAS asumimos que no hay reemplazo, cuando sale un elemento de la muestra, entonces no puede volver a salir de vuelta.

Realizamos una estimación de la media poblacional usando una muestra de tamaño 500, obteniendo el valor de 1458.8

```
# 2. MAS (Simple)

# Selección de una muestra aleatoria simple
n <- 500
muestra_mas <- bank_data[sample(nrow(bank_data), n), ]

# Definición del diseño en el paquete survey
library(survey)
```

Warning: package 'survey' was built under R version 4.4.3

Cargando paquete requerido: grid

Cargando paquete requerido: Matrix

Adjuntando el paquete: 'Matrix'

The following objects are masked from 'package:tidyr':

expand, pack, unpack

Cargando paquete requerido: survival

Adjuntando el paquete: 'survey'

The following object is masked from 'package:graphics':

dotchart

```
diseno_mas <- svydesign(id = ~1, data = muestra_mas, fpc = rep(nrow(bank_data), nrow(muestra_mas))  
res_mas <- svymean(~balance, diseno_mas, deff = TRUE) # MAS SI  
#res_mas  
  
print(paste("Media Real:", round(media_real, 2)))
```

```
[1] "Media Real: 1422.66"
```

```
print(paste("Media MAS sin Reemplazo:", round(res_mas, 2)))
```

```
[1] "Media MAS sin Reemplazo: 1487.66"
```

Ahora el problema que tenemos con este diseño es que como vimos en el histograma de saldos, el MAS sera ineficiente porque hay mucha variabilidad y una asimetría extrema, esto causa que la muestra aleatoria simple no incluya suficientes individuos de la “cola derecha”, los usuarios de saldos altos, lo que resultaría en una estimación sesgada y errónea del promedio de la riqueza de los usuarios del banco. En nuestro caso vemos que la estimación del promedio hecha con la muestra esta considerablemente alejada de la media real.

Diseño Bernoulli

Este Diseño asume que cada unidad de la población del banco tiene una probabilidad de inclusión independiente e idéntica (π). A diferencia del Muestreo Aleatorio Simple (MAS), donde el tamaño de la muestra (n) es fijo, en el diseño Bernoulli el tamaño de la muestra es aleatorio, varia segun la extracción que hagamos, no siempre es el mismo. Se puede probar matematicamente que el número final de clientes seleccionados sigue una distribución Binomial $B(N, \pi)$ y en promedio tendremos $N \times \pi$ clientes, pero el número exacto variará cada vez que ejecutemos el proceso.

Este Diseño sigue cumpliendo la Independencia, donde la selección de un cliente no afecta en absoluto la probabilidad de seleccionar a otro.

```

library(survey)

# 1. Definir la probabilidad de inclusión (pi)
pi <- 0.05
N <- nrow(bank_data)

# 2. Ejecutar el muestreo Bernoulli
# Generamos una variable indicadora (0 o 1) para cada registro
set.seed(123)
seleccion <- rbinom(N, 1, pi)
muestra_bernoulli <- bank_data[seleccion == 1, ]

# 3. Definir el diseño en el paquete survey
# En el diseño Bernoulli, la probabilidad de inclusión es constante
diseno_bernoulli <- svydesign(
  id = ~1,
  prob = ~rep(pi, nrow(muestra_bernoulli)),
  data = muestra_bernoulli
)

# 4. Estimar la media de la variable 'balance'
estimacion_media <- svymean(~balance, diseno_bernoulli, deff = TRUE) # bernoulli

# 5. Mostrar resultados e Intervalo de Confianza
print(estimacion_media)

```

```

      mean      SE  DEff
balance 1328.10 158.66 1.0526

```

```

confint(estimacion_media)

```

```

      2.5 % 97.5 %
balance 1017.134 1639.07

```

```

# Ver el tamaño de muestra obtenido
cat("Tamaño de muestra esperado:", N * pi, "\n")

```


Tamaño de muestra esperado: 226.05

```
cat("Tamaño de muestra obtenido:", nrow(muestra_bernoulli), "\n")
```

Tamaño de muestra obtenido: 216

```
print(paste("Media Real:", round(media_real, 2)))
```

```
[1] "Media Real: 1422.66"
```

```
print(paste("Media Bernoulli:", round(estimacion_media, 2)))
```

```
[1] "Media Bernoulli: 1328.1"
```

Vemos que la estimacion esta bastante alejada de el valor poblacional de la media, esto se debe a que el diseño Bernoulli tambien se ve afectado por la asimetría observada en el histograma de saldos, donde la variable balance tiene una cola derecha muy larga. En un diseño Bernoulli con una π baja, hay un alto riesgo de que el tamaño de muestra efectivo sea pequeño en los sectores de saldos altos, lo que sube el error estándar. Ademas la varianza en el diseño Bernoulli es mayor por la incertidumbre adicional sobre cuántos sujetos terminarán en la muestra.

Si queremos hacer una tabla comparativa:

```
# Comparación rápida
data.frame(Metodo = c("Real", "Simple", "Bernoulli"),
           Media = c(media_real, res_mas[1], estimacion_media))
```

	Metodo	Media
1	Real	1422.658
2	Simple	1487.662
3	Bernoulli	1328.102

Ahora debemos tener cuidado con las interpretaciones ya que estas estimaciones se hicieron con una UNICA muestra, generalmente los estimadores, que son funciones de los datos muestrales se evaluan en multiples muestras, para las cuales los estimadores tomaran valores distintos, obteniendo asi una distribucion de probabilidad para estos estimadores. Probaremos esto usando 1000 muestras para evaluar el rendimiento del MAS contra el Bernoulli.

```

set.seed(123)
iteraciones <- 1000
N <- nrow(bank_data)
pi_prob <- 0.05
n_fijo <- round(N * pi_prob)

# Crear contenedor para los resultados
simulacion <- data.frame(
  MAS = numeric(iteraciones),
  Bernoulli = numeric(iteraciones)
)

for(i in 1:iteraciones) {
  # 1. Simulación MAS (n fijo)
  muestra_mas <- bank_data[sample(N, n_fijo), ]
  simulacion$MAS[i] <- mean(muestra_mas$balance)

  # 2. Simulación Bernoulli (n aleatorio)
  # Seleccionamos con probabilidad pi_prob cada fila
  seleccion_bern <- rbinom(N, 1, pi_prob)
  muestra_bern <- bank_data[seleccion_bern == 1, ]

  # Estimador de Horvitz-Thompson para la media en Bernoulli:
  # (Suma de valores observados) / (N * pi)
  simulacion$Bernoulli[i] <- sum(muestra_bern$balance) / (N * pi_prob)
}


# 3. Preparar datos para ggplot (usando tidyr en lugar de reshape2 para evitar avisos)
library(tidyr)
sim_long <- pivot_longer(simulacion, cols = everything(), names_to = "Diseno", values_to = "Media")

# 4. Graficar comparativa corregida
library(ggplot2)
ggplot(sim_long, aes(x = Media, fill = Diseno)) +
  geom_density(alpha = 0.4) +
  # CORRECCIÓN: xintercept en lugar de x_intercept
  geom_vline(xintercept = mean(bank_data$balance), linetype = "dashed", color = "black", size = 1) +
  labs(title = "Distribución de los Estimadores: MAS vs Bernoulli",
        subtitle = paste("Comparación de 1,000 muestras del Saldo Bancario (n aprox =", n_fijo, ")",
                          "x = \"Saldo Promedio Estimado ($)\"",
                          "y = \"Densidad\"",
                          "fill = \"Diseño de Muestreo\"") +

```

```
theme_minimal()
```

Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
i Please use `linewidth` instead.



Vemos en el gráfico de Densidad de los Estimadores, que si bien ambos diseños son insesgados, es decir, en promedio tienden a estimar bien el valor promedio real, y esto se observa en que las curvas de los estimadores se centran correctamente en la media real de 1422.658, la curva azul del MAS es notablemente más estrecha y alta. Esto demuestra que el MAS es un diseño más preciso para este banco. La mayor dispersión de la curva roja de Bernoulli se debe a que, en ese diseño, el tamaño de la muestra es aleatorio; esa incertidumbre sobre cuántos clientes terminan siendo encuestados añade variabilidad que sube el error. Aunque seguimos teniendo los problemas mencionados de asimetría, alta variabilidad, y no consideración de usuarios bancarios con alto ingreso.

Al tener los estimadores distribucino de probabilidad, podemos calcular distintos estadisticos como

El sesgo es la comparacion entre la media obtenida con los estimadores usando las multiples muestra extraidas y la media poblacional, el sesgo mide la exactitud de nuestras estimaciones. Un sesgo cercano a cero indica que tu diseño no tiene preferencias ni errores sistemáticos, no está inflado ni subestimado.

La Varianza mide la precisión o estabilidad, vimos que el saldo bancario es muy volátil (con clientes de \$0 y otros de \$60,000), una varianza alta hace que con cada muestra extraída el resultado pueda cambiar mucho.

El MSE (Error Cuadrático Medio) indica el error total, es la suma del sesgo elevado al cuadrado y de la varianza. Esta métrica sirve para decidir qué diseño es mejor, a menor MSE, más eficiente es el muestreo.

El RMSE da el error promedio en las mismas unidades que el saldo (que esta en dolares), si el RMSE es de \$200, significa que, en promedio, las estimaciones se desvían \$200 del valor real.

El CV (Coeficiente de Variación) da la incertidumbre como un porcentaje. Un CV menor al 5% o 10% indica que el error es pequeño en relación con la magnitud de los saldos que estamos midiendo.

Si hacemos la tabla comparativa del MAS y el Bernoulli

```
library(tidyverse)

# Asumiendo que ya tienes el dataframe 'resultados' de la simulación anterior
# con las columnas 'metodo' y 'media'

# Calculamos la media poblacional real como parámetro de referencia
media_real <- mean(bank_data$balance)

# Transformamos los resultados de la simulación para el análisis
metricas <- sim_long %>%
  group_by(Disenos) %>%
  summarise(
    Media_Estimadores = mean(Media),
    Sesgo = mean(Media) - media_real,
    Varianza = var(Media),
    MSE = mean((Media - media_real)^2),
    RMSE = sqrt(MSE),
    # Coeficiente de Variación del estimador (mide precisión relativa)
    CV = (sd(Media) / mean(Media)) * 100
  )

print(metricas)
```

```
# A tibble: 2 x 7
  Disenos Media_Estimadores Sesgo Varianza MSE RMSE CV
  <chr>          <dbl>   <dbl>   <dbl> <dbl> <dbl> <dbl>
```

1 Bernoulli	1405.	-17.2	45807.	46058.	215.	15.2
2 MAS	1426.	3.77	35167.	35146.	187.	13.1

Podemos decir en general que el MAS es mejor que el Bernoulli aunque a gran escala tenemos el problema de asimetría y selección sesgada dada la poca presencia de clientes con mucho dinero en el banco.

Muestreo Aleatorio Simple con Reemplazo

El Muestreo Aleatorio Simple con Reemplazo (SIR) es una variante del MAS donde cada vez que seleccionas a un cliente de la población para ponerlo en la muestra, este puede aparecer dos o más veces en la muestra final. La varianza del estimador bajo posibilidad de reemplazo suele ser mayor que si no hubiera posibilidad de reemplazo, porque al permitir repeticiones, la muestra es menos informativa, tenemos menos individuos únicos para representar a la población.

```
# 1. Definir parámetros
n <- 500
N <- nrow(bank_data)

# 2. Extraer la muestra SIR (con reemplazo)
set.seed(123)
indices_sir <- sample(1:N, size = n, replace = TRUE)
muestra_sir <- bank_data[indices_sir, ]

# 3. Verificar si hay duplicados
n_unicos <- length(unique(indices_sir))
cat("Individuos únicos seleccionados:", n_unicos, "de", n, "\n")
```

Individuos únicos seleccionados: 476 de 500

```
# 4. Definir el diseño en el paquete survey
# Para SIR, no se incluye el argumento 'fpc'
diseno_sir <- svydesign(
  id = ~1,
  weights = ~rep(N/n, n),
  data = muestra_sir
)
```

```
# 5. Estimar la media del balance
res_sir <- svymean(~balance, diseno_sir, deff = TRUE) # MAS con reemplazo

print(paste("Media Real:", round(media_real, 2)))
```

```
[1] "Media Real: 1422.66"
```

```
print(paste("Media MAS con Reemplazo:", round(res_sir, 2)))
```

```
[1] "Media MAS con Reemplazo: 1402.6"
```

En media, tanto reemplazo como no reemplazo son insesgados (muy cerca del valor real). En Varianza y RMSE, con reemplazo es mayor debido a la reducción de la diversidad de la muestra. En CV (Coeficiente de Variación), con reemplazo tendrá una precisión menor.

Hasta ahora la lógica detrás de todas las estimaciones se basaba en expandir la muestra y estábamos usando el estimador Horvitz-Thompson (HT). Con la fórmula

$$\hat{Y}_{HT} = \sum_{i \in s} \frac{y_i}{\pi_i} = \sum_{i \in s} y_i \cdot w_i$$

Lo que hace es para todos los individuos de la muestra, dividirlos entre su probabilidad de selección. Este estimador siempre es insesgado, pero se usa solo para diseños sin reemplazo. Para el caso de diseños con reemplazo, usamos el estimador Hansen-Hurwitz (pwr).

$$\hat{Y}_{pwr} = \frac{1}{n} \sum \frac{y_i}{p_i}$$

Estimador pwr

```
library(tidyverse)

# 1. Definir probabilidades de selección (p_i)
# Deben sumar 1 en toda la población
bank_data <- bank_data %>%
  mutate(prioridad = case_when(
    education == "tertiary" ~ 3,
```

```

    education == "secondary" ~ 2,
    TRUE ~ 1
  )) %>%
  mutate(p_i = prioridad / sum(prioridad))

# 2. Realizar el muestreo CON reemplazo (n = 500)
n_muestras <- 500
set.seed(789)
indices_pwr <- sample(1:nrow(bank_data), size = n_muestras, replace = TRUE, prob = bank_data$balance)
muestra_pwr <- bank_data[indices_pwr, ]

# 3. Calcular el Estimador pwr para el TOTAL
# Aplicamos la fórmula: (1/n) * suma(y_i / p_i)
total_pwr <- (1 / n_muestras) * sum(muestra_pwr$balance / muestra_pwr$p_i)

# 4. Calcular la MEDIA estimada
media_pwr <- total_pwr / nrow(bank_data)

# Comparación
media_real <- mean(bank_data$balance)
print(paste("Media Real:", round(media_real, 2)))

```

```
[1] "Media Real: 1422.66"
```

```
print(paste("Media Estimador pwr:", round(media_pwr, 2)))
```

```
[1] "Media Estimador pwr: 1218.67"
```

Si comparamos ambos usando un diseño simple (sin reemplazo para el HT y con reemplazo para el pwr) vemos que las estimaciones de pwr se aleja mas de la media real que es 1422.658, mientras que HT se acerca bastante

Esto se debe a que el diseño PWR (Hansen-Hurwitz) usa el saldo como medida de probabilidad. Este estimador es muy sensible a la relación entre el saldo y su peso. Si la mayoría de los clientes tienen saldos bajos (como se ve en el histograma), el PWR tiende a estabilizarse en esos valores. Al asignar probabilidades altas a los saldos grandes, el diseño selecciona repetidamente a los mismos clientes extremos (recuerda que es con reemplazo), la varianza del estimador se dispara

Para el HT, la media vale 1735.6, es más alta porque, en un muestreo aleatorio simple, si atrapamos por azar a uno de los pocos clientes con \$60,000, ese valor empuja el promedio

hacia arriba sin ninguna ponderación que lo suavice. Aunque conceptualmente tiene mas sentido usar un diseño sin reemplazo porque repetir los ingresos de los usuarios del banco tiende a ser informacion redundante.

```
library(survey)
library(dplyr)
library(tidyr)

# 1. Limpieza rigurosa: Solo saldos positivos y sin NAs
bank_clean <- bank_data %>%
  filter(balance > 0) %>%
  drop_na(balance)

N_pob <- nrow(bank_clean)
n_muest <- 500

# 2. Definir Probabilidades de Selección (p_i) por extracción
# Estas deben sumar exactamente 1
p_pob <- bank_clean$balance / sum(bank_clean$balance)

# 3. Muestreo con Reemplazo (PPS)
set.seed(123)
indices <- sample(1:N_pob, size = n_muest, replace = TRUE, prob = p_pob)
muestra_final <- bank_clean[indices, ]

# Extraemos las probabilidades específicas de los elementos seleccionados
p_muest <- p_pob[indices]

# -----
# A. DISEÑO PWR (Hansen-Hurwitz)
# -----
# Usamos 'probs' para las probabilidades de selección en cada extracción
diseno_pwr <- svydesign(
  id = ~1,
  probs = ~p_muest,
  data = muestra_final
)

# -----
# B. DISEÑO HT (Muestreo Aleatorio Simple como base)
# -----
# Para comparar, extraemos una muestra MAS de la misma población limpia
set.seed(123)
```



```

muestra_mas <- bank_clean[sample(N_pob, n_muest, replace = FALSE), ]
diseno_ht <- svydesign(
  id = ~1,
  fpc = rep(N_pob, n_muest),
  data = muestra_mas
)

# 4. Cálculo de Métricas Comparativas
res_pwr <- svymean(~balance, diseno_pwr)
res_ht <- svymean(~balance, diseno_ht)

# print(res_pwr)
# print(res_ht)

print(paste("Media Estimador HT:", round(res_pwr, 2)))

```

```
[1] "Media Estimador HT: 1599.81"
```

```
print(paste("Media Estimador pwr:", round(res_ht, 2)))
```

```
[1] "Media Estimador pwr: 1702.63"
```

```
cat("\n")
```

```

# Extraer las varianzas directamente de los objetos de estimación
var_pwr <- vcov(res_pwr)[1,1]
var_ht <- vcov(res_ht)[1,1]

# Calcular la Eficiencia Relativa
eficiencia_relativa <- var_ht / var_pwr

cat("Varianza HT (MAS):", var_ht, "\n")

```

```
Varianza HT (MAS): 21545.08
```

```
cat("Varianza PWR (PPS):", var_pwr, "\n")
```

```
Varianza PWR (PPS): 33192.43
```

```
cat("Eficiencia Relativa (HT/PWR):", eficiencia_relativa, "\n")
```

Eficiencia Relativa (HT/PWR): 0.6490962

Por los factores que mencionamos relacionados a que la varianza de diseños con reemplazo es mas alta que diseños sin reemplazo, vemos que en este caso se cumple, siendo la varianza del pwr casi 6 veces mas grande que la varianza del HT.

Diseño Estratificado

El Muestreo Estratificado es una técnica de diseño donde la población se divide en grupos mutuamente excluyentes llamados estratos, y luego se selecciona una muestra independiente dentro de cada uno de ellos. Nosotros decidimos la estructura de la muestra para asegurar que todos los sectores importantes del banco estén representados.

Como vimos en el boxplot, los estratos los podemos hacer con las categorías de empleo del banco, esto debido a:

- Homogeneidad Interna: En el boxplot, los saldos de los “estudiantes” se parecen mucho entre sí, pero son muy diferentes a los de los “jubilados”. Al estratificar, el error estándar solo depende de la variación dentro de cada grupo, eliminando la gran diferencia que hay entre grupos.
- Protección contra “Malas Muestras”: En el MAS, existe el riesgo de que tu muestra no incluya a nadie de una categoría pequeña pero importante (como los desempleados). En el estratificado, garantizas una cuota mínima para cada profesión.
- Mayor Precisión (Menor Varianza): Matemáticamente, si los estratos están bien elegidos (es decir, si la profesión realmente influye en el saldo), la varianza del estimador estratificado siempre será menor o igual a la del muestreo aleatorio simple.

En cada estrato podemos aplicar el diseño que querramos, simple, bernoulli, etc.

```
library(tidyverse)
library(sampling)
```

Warning: package 'sampling' was built under R version 4.4.3

Adjuntando el paquete: 'sampling'

The following objects are masked from 'package:survival':

cluster, strata

```
# 1. Preparar los datos (ordenar por estrato es buena práctica)
bank_data <- bank_data %>% arrange(job)
N <- nrow(bank_data)
n_total <- 500

# 2. Calcular tamaños de estrato en la población (Nh)
estratos_info <- bank_data %>%
  group_by(job) %>%
  summarise(Nh = n(), Sh = sd(balance)) %>%
  mutate(wh = Nh / N) # Pesos poblacionales

# 3. Afijación Proporcional (nh)
estratos_info <- estratos_info %>%
  mutate(n_prop = round(n_total * wh))

# 4. Extraer la muestra estratificada (Proporcional)
set.seed(123)
muestra_estrat <- strata(bank_data,
  stratanames = "job",
  size = estratos_info$n_prop,
  method = "srswor") # Sin reemplazo dentro del estrato

# 5. Recuperar los datos de la muestra
datos_muestra_estrat <- getdata(bank_data, muestra_estrat)
datos_muestra_estrat
```

	age	marital	education	default	balance	housing	loan	contact	day	month
7	56	married	secondary	no	16873	no	no	cellular	7	oct
14	31	divorced	secondary	no	1890	yes	no	cellular	21	jul
23	40	single	secondary	no	462	yes	yes	cellular	6	apr
26	44	married	secondary	no	5181	yes	yes	cellular	31	jul
32	34	single	secondary	no	1	yes	no	cellular	22	jul
43	37	married	secondary	no	121	no	no	cellular	22	jul
78	50	married	secondary	no	231	yes	no	cellular	21	nov
81	55	married	primary	no	343	yes	no	cellular	14	jul

90	51	divorced	secondary	no	340	yes	no	unknown	8	may
91	41	married	secondary	no	2993	yes	no	cellular	22	jul
109	38	married	tertiary	no	1988	no	no	cellular	27	mar
118	36	single	secondary	no	0	no	no	cellular	20	apr
135	34	single	secondary	no	852	no	no	cellular	14	apr
137	27	married	secondary	no	710	yes	yes	cellular	6	may
143	24	married	secondary	no	299	yes	no	cellular	6	may
153	33	married	tertiary	no	69	no	yes	cellular	4	may
166	47	married	secondary	no	104	yes	yes	cellular	14	jul
179	46	married	secondary	no	70	yes	no	cellular	27	mar
195	46	married	secondary	no	4958	yes	no	cellular	17	nov
197	32	single	tertiary	no	-59	no	yes	unknown	4	jul
211	38	single	secondary	no	-23	no	no	cellular	20	nov
217	53	married	secondary	no	263	no	yes	cellular	18	jul
224	40	single	secondary	no	-1	no	no	cellular	7	jul
229	35	divorced	secondary	no	148	no	yes	cellular	8	jul
244	41	married	secondary	no	8238	yes	yes	unknown	30	may
254	57	married	secondary	no	3927	no	no	cellular	13	oct
256	28	single	secondary	no	1323	yes	no	unknown	3	jun
263	32	married	secondary	no	0	no	no	cellular	30	jan
299	49	married	primary	no	169	yes	no	cellular	15	may
306	26	married	tertiary	no	2855	no	no	cellular	30	mar
309	45	married	secondary	no	-388	yes	no	cellular	14	jul
328	58	married	secondary	no	1142	no	no	telephone	4	feb
330	48	married	secondary	no	191	yes	no	cellular	5	feb
332	38	divorced	secondary	no	156	yes	no	unknown	17	jun
348	33	married	tertiary	no	79	yes	no	cellular	22	oct
355	27	married	secondary	no	897	no	no	cellular	5	jun
359	34	married	secondary	no	645	yes	no	unknown	19	may
373	36	married	secondary	no	4280	no	no	unknown	19	jun
374	42	married	secondary	no	4209	yes	no	unknown	5	jun
393	41	married	secondary	no	4539	no	no	unknown	30	may
411	39	married	secondary	no	607	yes	no	cellular	12	may
415	37	married	secondary	no	-107	yes	no	unknown	28	may
420	30	single	secondary	no	3809	yes	no	unknown	3	jun
425	28	married	secondary	no	934	yes	no	unknown	4	jul
426	34	single	tertiary	no	18	yes	yes	cellular	30	apr
432	30	married	tertiary	no	0	yes	no	cellular	24	jul
433	41	married	secondary	no	21515	yes	no	unknown	5	jun
441	57	married	secondary	no	2137	no	no	telephone	8	jul
457	26	single	secondary	no	3529	no	yes	cellular	7	sep
463	32	married	secondary	no	0	yes	yes	cellular	17	nov
473	39	single	secondary	no	163	yes	no	cellular	30	jan

475	58	married	secondary	no	3496	yes	no	unknown	2	jun
477	32	single	secondary	no	620	yes	no	unknown	26	may
483	32	married	secondary	no	2089	yes	no	cellular	14	nov
491	41	divorced	secondary	no	174	yes	no	cellular	14	may
512	32	single	secondary	no	1143	yes	yes	cellular	10	jul
517	30	married	secondary	no	975	yes	no	cellular	13	may
519	49	married	primary	no	365	no	no	unknown	26	may
529	35	single	tertiary	no	0	yes	no	cellular	21	jul
542	30	married	primary	no	1317	yes	no	unknown	21	may
545	47	married	primary	no	214	yes	yes	unknown	9	jun
547	36	single	secondary	no	219	yes	yes	cellular	11	may
550	49	married	secondary	no	2039	yes	no	cellular	18	nov
552	39	married	primary	no	3705	yes	no	unknown	16	jun
563	34	single	secondary	no	186	no	no	cellular	2	feb
567	36	married	primary	no	973	yes	yes	unknown	23	may
568	32	married	secondary	no	2366	yes	no	unknown	20	may
588	29	married	secondary	no	15	no	no	cellular	3	jun
591	35	married	primary	no	0	yes	no	cellular	24	jul
594	41	married	secondary	yes	720	no	yes	cellular	24	jul
599	50	married	primary	no	12519	yes	no	cellular	17	apr
605	32	single	secondary	no	-84	yes	no	cellular	11	may
619	40	married	secondary	no	498	yes	no	cellular	8	may
629	24	single	primary	no	111	yes	yes	unknown	27	may
631	33	married	secondary	no	1134	yes	no	unknown	23	may
633	59	married	primary	no	179	yes	no	unknown	5	may
636	37	divorced	primary	no	511	yes	no	telephone	11	may
637	29	single	secondary	no	908	yes	no	unknown	20	jun
638	30	single	secondary	no	445	yes	no	cellular	16	apr
643	32	single	primary	no	882	no	yes	cellular	29	jul
656	35	married	primary	no	793	yes	no	cellular	17	apr
687	36	married	secondary	no	439	yes	no	unknown	21	may
690	36	married	secondary	no	2357	yes	no	unknown	17	jun
701	33	married	secondary	no	661	yes	no	cellular	18	jul
714	55	married	unknown	no	23	no	no	cellular	13	aug
716	34	married	secondary	no	1897	yes	yes	cellular	19	nov
721	30	married	secondary	no	6	yes	no	cellular	28	jan
755	27	married	secondary	yes	-584	yes	no	cellular	7	may
756	39	married	primary	no	1564	no	no	unknown	17	jun
758	58	married	primary	no	781	yes	no	cellular	15	may
764	40	married	primary	no	-335	yes	no	unknown	27	may
768	31	married	secondary	no	631	yes	no	unknown	23	may
769	29	married	secondary	no	912	yes	no	cellular	13	may
772	31	married	secondary	no	0	yes	no	unknown	5	may

786	29	single	secondary	no	9	yes	no	cellular	11	may
788	39	married	secondary	no	0	yes	no	cellular	7	may
794	35	single	unknown	no	871	yes	no	unknown	6	jun
804	43	married	primary	no	7727	yes	no	unknown	15	may
808	50	married	secondary	no	372	yes	no	telephone	11	may
817	41	single	unknown	no	4684	no	no	unknown	20	jun
840	33	married	secondary	no	-346	yes	yes	unknown	23	may
852	45	married	primary	no	97	yes	no	unknown	7	may
869	31	single	primary	no	2488	yes	no	cellular	20	apr
887	45	married	secondary	no	4365	no	yes	cellular	9	feb
902	45	married	secondary	no	2926	yes	yes	cellular	19	nov
904	36	married	secondary	no	-73	yes	yes	cellular	18	may
909	28	married	primary	no	702	yes	no	unknown	26	jun
934	54	married	primary	no	781	yes	no	unknown	9	may
941	43	married	primary	no	255	yes	no	cellular	17	jul
955	48	single	secondary	no	-552	no	yes	cellular	21	nov
958	45	married	primary	no	2433	no	no	cellular	6	aug
961	44	married	primary	no	-11	yes	no	unknown	9	may
994	34	married	secondary	no	2542	yes	no	cellular	14	may
1006	44	married	secondary	no	1071	yes	no	cellular	11	may
1015	35	divorced	primary	no	-587	yes	no	unknown	26	may
1045	34	married	secondary	no	8309	yes	yes	cellular	19	nov
1053	42	married	secondary	no	2157	yes	no	cellular	13	may
1059	44	married	secondary	no	1910	yes	no	unknown	5	jun
1066	27	married	secondary	no	818	yes	no	unknown	3	jun
1076	46	married	secondary	no	123	no	no	cellular	20	aug
1084	33	divorced	secondary	no	-131	yes	no	unknown	16	may
1088	32	married	secondary	no	1787	yes	no	cellular	12	may
1092	46	married	secondary	no	4855	yes	no	cellular	10	aug
1097	29	married	secondary	no	125	yes	no	unknown	13	may
1126	57	married	primary	yes	195	no	yes	telephone	30	jul
1141	54	married	primary	no	2281	yes	no	unknown	20	jun
1144	30	married	primary	no	-518	yes	yes	unknown	28	may
1149	32	single	secondary	no	2285	yes	no	unknown	14	may
1164	36	married	secondary	no	4438	yes	no	unknown	20	may
1189	37	married	unknown	no	897	yes	no	cellular	13	apr
1200	40	married	secondary	no	6767	yes	no	cellular	20	nov
1204	38	divorced	secondary	no	889	no	yes	unknown	18	jun
1222	46	married	secondary	no	-1400	yes	no	telephone	6	may
1225	30	single	secondary	yes	447	no	no	unknown	14	may
1230	33	married	primary	no	1209	yes	no	cellular	16	apr
1233	34	married	primary	no	428	yes	no	cellular	18	may
1242	42	married	secondary	no	179	yes	no	cellular	17	nov

1245	37	married	primary	no	543	yes	no	unknown	21	may
1252	32	married	secondary	no	119	no	no	cellular	4	may
1262	36	divorced	secondary	no	-11	no	no	unknown	5	jun
1263	26	single	secondary	no	396	yes	no	unknown	28	may
1267	53	married	secondary	no	483	yes	no	cellular	3	feb
1270	52	married	secondary	no	161	yes	no	unknown	13	may
1278	48	married	secondary	no	425	yes	no	telephone	9	jul
1292	24	married	secondary	no	0	no	no	unknown	28	may
1296	35	married	secondary	no	243	yes	no	cellular	20	apr
1300	44	married	primary	no	887	yes	no	cellular	12	may
1321	45	married	primary	no	0	no	no	unknown	23	may
1325	47	married	secondary	no	0	yes	no	cellular	21	jul
1332	47	divorced	primary	no	126	yes	no	unknown	3	jun
1337	43	married	primary	no	483	yes	no	cellular	12	may
1340	42	married	primary	no	969	yes	no	cellular	13	may
1343	34	divorced	secondary	no	-566	yes	no	unknown	26	may
1358	45	divorced	primary	no	0	yes	no	cellular	21	jul
1366	47	divorced	primary	no	1279	yes	no	cellular	6	feb
1371	33	single	primary	no	1	yes	no	cellular	20	apr
1373	32	married	secondary	no	-32	yes	no	cellular	12	may
1398	52	married	primary	no	-133	no	no	unknown	5	jun
1425	41	married	tertiary	no	221	yes	no	unknown	14	may
1440	39	married	tertiary	no	2	yes	no	cellular	17	nov
1444	28	married	unknown	no	1034	no	no	cellular	29	jan
1446	26	single	tertiary	no	81	no	no	cellular	21	jul
1454	48	married	tertiary	no	810	no	no	unknown	6	jun
1463	50	divorced	tertiary	no	1790	no	yes	cellular	6	feb
1466	42	married	primary	no	198	yes	no	unknown	8	may
1472	44	married	tertiary	no	3463	yes	yes	cellular	28	aug
1476	54	married	secondary	no	653	yes	no	unknown	15	may
1478	47	married	unknown	no	209	yes	no	unknown	6	may
1501	46	married	secondary	no	757	no	no	unknown	16	jun
1507	47	married	primary	no	668	no	no	cellular	12	may
1512	34	married	tertiary	no	4343	no	no	unknown	9	jun
1517	39	married	tertiary	no	2644	yes	no	unknown	20	may
1518	43	married	tertiary	no	13342	yes	no	cellular	18	nov
1528	53	married	tertiary	no	2289	yes	yes	cellular	17	nov
1532	47	married	tertiary	no	459	yes	no	cellular	29	jul
1535	57	divorced	secondary	yes	25	yes	no	cellular	11	may
1561	38	married	tertiary	no	6704	yes	no	unknown	21	may
1600	58	married	tertiary	no	497	no	no	unknown	11	jun
1603	50	married	secondary	no	7317	yes	no	cellular	13	may
1638	57	married	tertiary	no	3	no	no	cellular	4	aug

1647	62	married	secondary	no	565	no	no	cellular	4	sep
1651	58	married	primary	no	0	yes	no	telephone	9	jul
1658	51	divorced	secondary	no	9228	no	no	cellular	18	jul
1662	47	married	secondary	no	3940	yes	no	cellular	9	nov
1664	40	married	secondary	no	4610	no	no	cellular	14	aug
1669	56	married	tertiary	no	1922	yes	no	cellular	24	jul
1676	42	single	primary	no	5774	yes	no	unknown	15	may
1677	34	married	tertiary	no	0	no	no	cellular	26	may
1699	42	divorced	tertiary	no	364	no	no	cellular	18	nov
1730	46	divorced	tertiary	no	25	no	no	unknown	17	jun
1744	30	single	tertiary	no	1372	no	no	cellular	20	nov
1758	47	married	tertiary	no	3681	no	no	cellular	14	aug
1759	29	married	tertiary	no	451	no	no	cellular	28	jan
1761	35	married	tertiary	no	4286	yes	no	unknown	9	may
1808	54	married	tertiary	no	55	yes	no	cellular	2	jun
1821	45	married	tertiary	no	1529	no	no	cellular	30	jun
1829	29	married	tertiary	no	361	yes	yes	cellular	28	jul
1833	31	single	secondary	no	36	no	no	cellular	27	aug
1838	33	divorced	tertiary	yes	280	no	yes	cellular	18	nov
1856	31	married	tertiary	no	1010	yes	no	cellular	15	may
1864	48	married	tertiary	no	1167	yes	yes	cellular	1	jun
1867	57	married	primary	no	1052	yes	no	unknown	13	may
1889	33	married	tertiary	no	148	no	no	unknown	20	may
1890	36	married	secondary	no	-148	no	no	cellular	18	nov
1904	33	married	secondary	no	4040	yes	no	cellular	20	apr
1909	34	married	tertiary	no	0	yes	no	cellular	7	aug
1921	56	divorced	tertiary	no	1016	yes	no	unknown	9	jun
1922	42	single	tertiary	no	525	no	no	cellular	13	aug
1926	41	married	tertiary	no	10758	yes	no	cellular	1	jun
1929	53	married	tertiary	no	4	no	no	unknown	20	jun
1939	32	married	tertiary	no	1390	no	no	cellular	7	aug
1942	30	single	tertiary	no	726	yes	no	cellular	16	apr
1954	36	single	tertiary	no	243	yes	no	cellular	7	may
1956	41	divorced	tertiary	no	4567	yes	yes	cellular	16	jul
1969	37	married	tertiary	no	5106	no	no	cellular	30	apr
1974	61	married	tertiary	no	6016	no	no	cellular	2	feb
1983	41	divorced	tertiary	no	5037	no	no	cellular	23	apr
1993	32	single	tertiary	no	151	yes	no	unknown	6	may
2013	48	divorced	tertiary	no	507	yes	no	cellular	9	apr
2034	51	married	tertiary	no	2934	yes	no	cellular	18	nov
2041	37	single	tertiary	no	815	yes	no	cellular	7	may
2050	32	divorced	tertiary	no	1	yes	no	unknown	8	may
2051	39	married	tertiary	no	12	yes	no	unknown	23	may

2061	54	married	tertiary	no	2960	yes	no	cellular	20	nov
2085	47	married	tertiary	no	286	no	no	cellular	22	aug
2093	34	married	tertiary	no	180	no	no	cellular	16	jun
2094	31	married	tertiary	no	156	no	no	cellular	13	aug
2095	50	married	tertiary	no	4374	yes	no	cellular	21	nov
2102	48	divorced	tertiary	no	541	yes	no	cellular	14	may
2113	49	married	tertiary	no	87	no	no	cellular	29	jan
2117	59	divorced	tertiary	no	7813	yes	no	cellular	21	nov
2119	32	married	secondary	no	350	yes	no	unknown	28	may
2125	40	single	tertiary	no	0	no	no	cellular	26	aug
2132	44	married	primary	no	4758	yes	no	cellular	22	jul
2133	58	divorced	tertiary	no	1573	yes	yes	cellular	17	nov
2151	36	single	tertiary	no	2806	yes	no	unknown	30	may
2161	52	married	tertiary	no	6922	no	no	cellular	20	nov
2162	35	single	tertiary	no	633	yes	no	cellular	17	apr
2172	60	married	tertiary	no	3387	no	no	cellular	14	aug
2177	48	married	tertiary	no	363	no	no	cellular	18	nov
2202	47	divorced	tertiary	no	2515	no	no	unknown	20	jun
2213	38	married	tertiary	no	223	no	no	cellular	28	jan
2220	56	divorced	tertiary	no	659	no	yes	cellular	2	jun
2223	26	single	tertiary	no	122	no	yes	cellular	8	jul
2226	31	married	tertiary	no	1343	yes	yes	unknown	21	may
2232	62	married	tertiary	no	0	no	no	cellular	13	oct
2241	32	married	tertiary	no	1667	yes	no	cellular	18	nov
2242	30	married	tertiary	no	931	no	no	cellular	17	jul
2243	34	married	tertiary	no	-73	yes	no	cellular	11	jul
2249	30	married	tertiary	no	1882	yes	no	cellular	11	aug
2257	31	married	tertiary	no	4148	yes	no	cellular	21	nov
2261	34	single	tertiary	no	184	no	no	cellular	22	jul
2268	60	married	primary	no	4895	no	no	unknown	9	jun
2277	57	married	unknown	no	0	no	no	cellular	30	sep
2282	50	married	tertiary	no	1240	no	no	cellular	12	aug
2301	33	married	tertiary	no	287	yes	no	cellular	15	may
2321	36	married	tertiary	no	1582	no	no	telephone	3	feb
2322	37	married	tertiary	no	489	yes	no	cellular	7	aug
2331	36	married	tertiary	no	0	yes	yes	unknown	3	jun
2350	36	married	tertiary	no	254	no	no	unknown	6	jun
2352	44	divorced	tertiary	no	-710	yes	no	cellular	10	jul
2361	48	married	unknown	no	0	yes	no	cellular	8	may
2362	35	married	tertiary	no	0	no	no	cellular	11	jul
2364	38	single	tertiary	no	16957	yes	no	telephone	29	jan
2370	43	single	tertiary	no	1696	yes	no	cellular	26	aug
2375	46	married	tertiary	no	523	yes	no	cellular	6	may

2376	35	single	tertiary	no	0	no	yes	cellular	14	aug
2377	39	married	secondary	no	0	yes	no	cellular	27	aug
2386	53	married	tertiary	no	37	no	no	cellular	28	aug
2392	60	married	tertiary	no	759	no	no	cellular	14	aug
2402	39	single	tertiary	no	3797	no	no	cellular	2	jun
2415	58	married	tertiary	no	16264	no	no	telephone	17	nov
2428	34	divorced	tertiary	no	13204	yes	yes	cellular	20	nov
2431	34	married	secondary	no	293	yes	no	unknown	21	may
2461	47	married	tertiary	no	2306	no	no	telephone	6	aug
2469	33	single	tertiary	no	335	no	no	cellular	29	aug
2479	31	married	tertiary	no	1384	yes	no	cellular	30	jan
2483	30	single	tertiary	no	149	yes	no	unknown	3	jun
2498	30	single	tertiary	no	2	no	no	cellular	16	jun
2501	30	single	tertiary	yes	35	no	no	cellular	30	jul
2508	44	married	secondary	yes	0	yes	no	cellular	11	jul
2525	61	married	tertiary	no	997	no	no	cellular	10	mar
2535	28	single	tertiary	no	5549	no	no	cellular	28	jul
2565	40	married	tertiary	no	51	no	no	cellular	19	aug
2579	42	divorced	tertiary	no	0	no	no	unknown	19	may
2582	51	married	tertiary	no	176	yes	yes	unknown	1	jun
2585	26	single	secondary	no	565	yes	no	unknown	6	jun
2604	57	married	tertiary	no	1341	yes	no	unknown	8	may
2607	31	single	tertiary	no	1130	yes	no	cellular	17	apr
2623	42	married	secondary	no	1331	no	no	cellular	23	jul
2624	29	single	tertiary	no	5980	yes	no	unknown	28	may
2634	48	married	tertiary	no	263	yes	no	unknown	5	may
2640	30	married	tertiary	no	42	no	no	cellular	25	aug
2648	43	married	tertiary	no	3529	yes	no	cellular	4	aug
2649	30	single	tertiary	no	7845	yes	no	unknown	3	jun
2662	38	single	tertiary	no	623	no	no	cellular	28	jun
2675	68	divorced	secondary	no	4189	no	no	telephone	14	jul
2686	56	married	secondary	no	1333	no	no	cellular	28	aug
2697	75	divorced	tertiary	no	3810	yes	no	cellular	16	nov
2726	43	married	secondary	no	520	yes	no	unknown	20	may
2736	59	married	secondary	no	1173	no	no	unknown	9	jun
2749	59	single	secondary	no	351	yes	no	unknown	27	may
2766	86	married	secondary	no	1503	no	no	telephone	18	mar
2779	57	married	secondary	yes	32	yes	no	cellular	15	may
2794	58	married	primary	no	4007	no	no	cellular	30	nov
2803	73	married	secondary	no	19	no	no	cellular	5	nov
2814	80	married	secondary	no	462	no	no	cellular	7	dec
2818	58	married	secondary	no	413	no	no	cellular	27	aug
2838	59	divorced	secondary	no	1026	no	no	unknown	5	nov

2843	69	married	secondary	no	745	no	no	telephone	9	sep
2850	58	married	primary	no	565	no	no	telephone	7	jul
2862	60	married	primary	no	71188	no	no	cellular	6	oct
2864	52	married	secondary	no	424	no	no	cellular	19	nov
2868	74	married	secondary	no	921	no	no	telephone	17	apr
2871	57	married	secondary	no	49	yes	yes	cellular	25	aug
2872	57	married	primary	no	-464	yes	no	cellular	4	feb
2883	69	single	tertiary	no	2144	no	no	cellular	29	jul
2885	57	married	unknown	no	1621	yes	no	unknown	19	jun
2894	73	married	unknown	no	519	no	no	telephone	16	oct
2895	60	married	tertiary	no	225	no	no	cellular	19	aug
2899	83	divorced	primary	no	1097	no	no	telephone	5	mar
2925	39	married	secondary	no	167	yes	yes	cellular	17	jul
2926	31	married	tertiary	no	259	yes	no	cellular	7	may
2934	26	single	tertiary	no	211	no	no	cellular	29	jan
2938	45	married	tertiary	no	334	no	no	unknown	5	jun
2939	41	married	tertiary	no	231	no	no	cellular	7	aug
2942	31	married	secondary	no	33	no	no	cellular	6	aug
2944	50	divorced	tertiary	no	59	yes	no	unknown	28	may
2951	31	single	secondary	no	203	no	yes	cellular	19	nov
2964	58	married	secondary	no	1407	yes	no	unknown	30	may
2967	27	single	secondary	no	49	yes	no	cellular	30	jan
2970	53	married	tertiary	no	2627	yes	yes	unknown	16	jun
2976	35	married	tertiary	no	8647	no	no	cellular	19	nov
2983	55	married	secondary	no	203	yes	no	telephone	14	may
2990	50	married	unknown	no	-84	yes	no	unknown	6	may
3014	35	married	tertiary	no	560	yes	no	cellular	2	apr
3015	41	married	primary	no	340	no	no	unknown	6	jun
3025	57	married	secondary	no	35	no	yes	unknown	26	jun
3040	39	married	tertiary	no	1047	no	no	unknown	6	jun
3069	43	single	tertiary	no	0	no	no	unknown	19	jun
3082	42	married	tertiary	no	0	no	no	cellular	8	aug
3097	27	single	secondary	no	-195	yes	no	cellular	18	may
3112	53	married	secondary	no	4994	no	no	cellular	18	aug
3116	38	married	secondary	no	-140	no	no	unknown	25	jun
3117	30	single	secondary	no	0	yes	no	cellular	18	may
3119	37	married	secondary	no	1328	yes	no	telephone	13	may
3125	55	divorced	secondary	yes	-404	yes	no	cellular	22	jul
3162	40	married	secondary	no	-342	yes	no	unknown	26	may
3167	53	divorced	secondary	no	-905	yes	no	unknown	28	may
3169	52	married	primary	no	14	no	yes	cellular	28	jul
3179	27	married	secondary	no	54	yes	no	cellular	18	may
3180	33	married	secondary	no	90	yes	no	cellular	28	jul

3182	37	single	secondary	no	1050	yes	no	cellular	3	feb
3192	31	married	secondary	no	413	yes	no	unknown	13	may
3193	55	divorced	primary	no	2923	yes	no	unknown	15	may
3199	38	single	secondary	no	2253	yes	no	cellular	13	may
3201	29	married	secondary	no	3748	no	no	cellular	28	may
3211	32	single	unknown	no	6145	yes	no	cellular	14	may
3227	47	married	tertiary	no	871	no	no	cellular	22	aug
3234	40	married	unknown	no	4075	yes	no	unknown	16	jun
3251	42	divorced	secondary	no	257	yes	no	cellular	12	may
3256	31	married	secondary	no	-331	yes	no	unknown	23	may
3261	39	married	secondary	no	1970	yes	no	unknown	8	jun
3288	24	married	tertiary	no	0	yes	no	unknown	27	may
3295	35	married	secondary	no	195	yes	no	cellular	17	apr
3303	28	single	secondary	no	229	yes	no	unknown	9	may
3316	54	married	secondary	no	812	no	no	cellular	31	jul
3318	47	divorced	secondary	no	4906	yes	no	unknown	14	may
3323	29	married	secondary	no	11417	yes	no	unknown	28	may
3329	49	married	secondary	no	1114	no	no	cellular	17	nov
3363	30	single	secondary	no	334	no	no	cellular	29	jan
3377	38	married	secondary	no	-314	yes	no	unknown	28	may
3385	44	single	secondary	no	5045	yes	no	cellular	21	nov
3409	38	married	secondary	no	-762	yes	yes	unknown	30	may
3424	32	single	secondary	no	152	yes	no	cellular	25	may
3434	50	married	secondary	no	961	no	yes	cellular	14	aug
3436	29	single	secondary	no	209	yes	no	cellular	28	jul
3440	32	married	secondary	no	162	yes	no	unknown	14	may
3444	34	married	secondary	no	-315	yes	no	unknown	8	may
3450	40	married	secondary	no	9374	yes	no	cellular	21	nov
3460	29	single	unknown	no	33	no	no	unknown	1	jul
3461	35	divorced	secondary	no	221	yes	no	cellular	14	may
3463	33	married	secondary	no	210	yes	yes	unknown	20	may
3478	40	married	tertiary	no	35	no	no	cellular	3	jul
3479	36	married	secondary	no	895	yes	yes	unknown	4	jun
3481	37	married	secondary	no	0	yes	yes	cellular	31	jul
3482	49	married	tertiary	no	306	yes	no	cellular	18	aug
3519	29	single	unknown	no	2929	no	no	cellular	11	aug
3525	23	single	secondary	no	8494	no	no	cellular	25	aug
3531	22	single	unknown	no	47	no	no	cellular	3	jul
3536	25	single	unknown	no	10788	no	no	cellular	23	dec
3539	28	single	tertiary	no	0	no	no	cellular	28	sep
3552	22	single	secondary	no	2488	no	no	cellular	8	nov
3553	38	single	tertiary	no	807	no	no	cellular	27	feb
3572	35	single	unknown	no	0	no	no	telephone	28	jan

3577	24	single	secondary	no	1847	no	no	cellular	9	dec
3595	37	single	secondary	no	228	yes	no	cellular	20	aug
3597	34	married	tertiary	no	1539	yes	no	cellular	15	jun
3606	45	single	secondary	no	586	no	yes	cellular	28	jul
3611	35	divorced	secondary	no	308	no	no	cellular	22	aug
3623	42	married	secondary	no	2030	yes	yes	cellular	9	jul
3624	29	married	secondary	no	1599	yes	no	cellular	8	jul
3635	43	married	secondary	no	0	no	yes	cellular	8	may
3642	38	single	tertiary	no	0	no	no	cellular	28	aug
3661	26	married	tertiary	no	3825	yes	no	unknown	13	may
3687	31	married	secondary	no	660	no	no	cellular	22	jun
3692	30	married	tertiary	no	1570	yes	no	cellular	26	may
3695	36	married	secondary	no	146	yes	yes	unknown	15	may
3706	31	married	secondary	no	251	no	yes	cellular	29	aug
3709	55	single	secondary	no	3339	yes	no	unknown	2	jun
3757	33	divorced	secondary	no	9	no	no	cellular	21	aug
3762	41	married	secondary	no	1066	no	no	cellular	11	feb
3767	37	single	secondary	no	5436	yes	no	cellular	6	may
3791	42	single	tertiary	no	-411	yes	no	cellular	12	may
3796	35	divorced	secondary	no	56	no	no	cellular	29	aug
3806	34	single	secondary	no	201	no	no	cellular	22	jul
3827	40	married	secondary	no	169	yes	no	cellular	18	aug
3828	53	divorced	secondary	no	751	yes	no	unknown	16	may
3831	39	married	secondary	no	9121	no	no	unknown	5	jun
3846	38	single	tertiary	no	0	yes	no	cellular	1	jun
3848	59	married	secondary	no	259	no	no	cellular	15	jun
3849	38	single	tertiary	no	744	yes	no	cellular	14	may
3854	41	married	secondary	no	351	yes	no	cellular	9	jul
3865	32	single	secondary	no	2979	no	no	cellular	25	may
3867	29	single	tertiary	no	406	yes	no	cellular	17	jul
3869	32	married	secondary	no	84	no	yes	cellular	29	jul
3876	23	single	secondary	no	-306	yes	no	unknown	4	jun
3888	34	married	tertiary	no	197	no	no	cellular	20	aug
3890	38	married	secondary	no	226	yes	no	unknown	30	may
3891	35	married	secondary	no	0	yes	no	cellular	9	nov
3893	45	married	secondary	no	1415	yes	no	cellular	24	jul
3896	45	married	secondary	no	1477	yes	no	cellular	8	jul
3902	33	divorced	secondary	yes	10	yes	yes	cellular	18	nov
3913	34	single	secondary	no	1386	yes	yes	unknown	28	may
3918	46	married	secondary	no	499	yes	no	cellular	31	jul
3935	30	single	secondary	no	4787	yes	no	unknown	4	jun
3939	41	married	tertiary	no	0	no	no	unknown	20	jun
3960	51	married	primary	no	260	no	no	cellular	19	aug

3965	30	married	secondary	no	371	no	no	cellular	7	aug
3971	42	divorced	secondary	no	-280	yes	no	unknown	26	may
3975	34	married	secondary	no	1	yes	no	cellular	19	nov
3982	34	single	secondary	no	943	no	no	cellular	29	aug
3986	45	single	tertiary	no	2087	no	no	cellular	29	aug
3989	35	married	secondary	no	13	no	no	cellular	22	aug
3990	28	single	secondary	no	769	yes	no	cellular	15	may
4009	51	married	secondary	no	117	no	no	cellular	24	aug
4024	43	single	tertiary	yes	0	no	no	cellular	29	aug
4039	30	married	secondary	no	616	yes	no	cellular	6	may
4050	32	married	secondary	no	687	no	no	cellular	20	aug
4051	45	married	primary	no	-322	no	no	unknown	9	jun
4055	37	single	secondary	no	61	yes	no	unknown	19	may
4077	38	married	secondary	no	1960	yes	no	cellular	21	aug
4081	32	single	tertiary	no	1625	no	no	cellular	22	may
4111	37	divorced	secondary	no	2610	yes	no	cellular	13	may
4128	47	married	primary	no	187	yes	no	unknown	9	may
4136	57	married	secondary	no	6164	no	no	cellular	19	nov
4146	48	married	secondary	no	5	no	no	unknown	9	jun
4149	33	single	secondary	no	1279	yes	no	cellular	18	may
4153	27	single	tertiary	no	808	yes	no	cellular	15	may
4165	30	single	tertiary	no	1922	yes	no	cellular	18	may
4166	48	married	secondary	no	178	yes	no	unknown	17	jun
4172	34	single	secondary	no	0	yes	yes	unknown	16	may
4199	36	married	tertiary	no	0	no	no	cellular	22	aug
4202	49	married	secondary	no	2718	no	no	unknown	19	may
4209	31	single	secondary	no	691	yes	no	cellular	8	may
4213	27	single	secondary	no	235	yes	no	cellular	12	may
4219	43	married	secondary	no	3285	yes	no	unknown	13	may
4233	25	single	secondary	no	2157	yes	no	cellular	21	jul
4236	32	married	secondary	yes	4	yes	yes	cellular	25	aug
4252	36	single	secondary	yes	12	no	no	cellular	12	aug
4254	42	married	secondary	no	613	yes	no	cellular	11	may
4258	41	divorced	secondary	no	52	no	no	cellular	20	aug
4266	41	married	secondary	no	1602	yes	no	cellular	2	jun
4273	47	married	secondary	no	2246	yes	no	cellular	10	jul
4283	40	married	secondary	no	257	yes	no	unknown	16	may
4310	47	married	unknown	no	2106	yes	no	unknown	6	may
4333	57	married	secondary	no	16063	yes	no	unknown	30	may
4335	30	married	tertiary	no	101	yes	yes	cellular	7	jul
4348	33	married	secondary	no	4790	yes	no	cellular	20	apr
4349	31	married	secondary	no	119	yes	no	cellular	4	feb
4351	28	single	tertiary	no	0	yes	no	unknown	4	jun

4364	28	single	secondary	no	16	no	no	cellular	12	aug
4366	26	single	secondary	no	1064	no	no	unknown	31	may
4385	35	married	secondary	no	977	yes	no	cellular	4	may
4389	36	married	secondary	no	-129	yes	no	cellular	29	jul
4398	28	married	secondary	no	655	yes	no	unknown	4	jun
4403	43	married	primary	no	960	yes	yes	unknown	15	may
4410	31	single	secondary	no	-186	yes	no	unknown	26	may
4415	48	married	secondary	no	817	no	no	cellular	14	jan
4416	38	married	primary	no	-363	no	no	unknown	12	jun
4417	49	divorced	tertiary	no	780	no	no	cellular	8	nov
4429	46	married	secondary	no	3533	yes	no	cellular	12	aug
4435	26	single	secondary	no	461	no	no	cellular	28	jan
4470	45	married	primary	no	180	yes	yes	unknown	27	may
4474	37	married	secondary	no	1978	no	no	cellular	9	sep
4489	54	married	secondary	no	2206	no	no	cellular	12	nov
4497	43	single	unknown	no	181	no	no	telephone	28	jan
4503	53	married	primary	no	732	no	no	cellular	27	oct
4521	45	married	primary	no	44	no	no	unknown	11	jun
	duration	campaign	pdays	previous	poutcome	y	prioridad	p_i		
7	223	1	-1	0	unknown	no	2	0.0002099297		
14	588	1	-1	0	unknown	no	2	0.0002099297		
23	272	1	335	4	other	no	2	0.0002099297		
26	18	7	-1	0	unknown	no	2	0.0002099297		
32	483	7	-1	0	unknown	no	2	0.0002099297		
43	22	6	-1	0	unknown	no	2	0.0002099297		
78	397	2	-1	0	unknown	no	2	0.0002099297		
81	276	3	-1	0	unknown	no	1	0.0001049648		
90	186	1	-1	0	unknown	no	2	0.0002099297		
91	24	12	-1	0	unknown	no	2	0.0002099297		
109	164	2	130	2	failure	yes	3	0.0003148945		
118	637	1	-1	0	unknown	no	2	0.0002099297		
135	108	2	-1	0	unknown	no	2	0.0002099297		
137	653	1	334	2	success	yes	2	0.0002099297		
143	209	1	321	1	failure	no	2	0.0002099297		
153	77	2	-1	0	unknown	no	3	0.0003148945		
166	77	2	-1	0	unknown	no	2	0.0002099297		
179	229	2	-1	0	unknown	yes	2	0.0002099297		
195	64	3	150	5	other	no	2	0.0002099297		
197	192	1	-1	0	unknown	no	3	0.0003148945		
211	48	2	-1	0	unknown	no	2	0.0002099297		
217	143	7	-1	0	unknown	no	2	0.0002099297		
224	173	1	-1	0	unknown	no	2	0.0002099297		
229	199	1	-1	0	unknown	no	2	0.0002099297		

244	124	4	-1	0	unknown	no	2	0.0002099297
254	61	1	-1	0	unknown	no	2	0.0002099297
256	361	1	-1	0	unknown	no	2	0.0002099297
263	119	3	-1	0	unknown	no	2	0.0002099297
299	82	3	-1	0	unknown	no	1	0.0001049648
306	52	3	-1	0	unknown	no	3	0.0003148945
309	175	2	-1	0	unknown	no	2	0.0002099297
328	82	3	-1	0	unknown	no	2	0.0002099297
330	238	3	-1	0	unknown	no	2	0.0002099297
332	544	3	-1	0	unknown	no	2	0.0002099297
348	249	2	335	2	failure	yes	3	0.0003148945
355	397	1	-1	0	unknown	yes	2	0.0002099297
359	420	1	-1	0	unknown	no	2	0.0002099297
373	227	6	-1	0	unknown	no	2	0.0002099297
374	57	6	-1	0	unknown	no	2	0.0002099297
393	298	3	-1	0	unknown	no	2	0.0002099297
411	454	2	364	3	failure	yes	2	0.0002099297
415	158	2	-1	0	unknown	no	2	0.0002099297
420	159	4	-1	0	unknown	no	2	0.0002099297
425	53	2	-1	0	unknown	no	2	0.0002099297
426	359	1	-1	0	unknown	yes	3	0.0003148945
432	209	2	-1	0	unknown	no	3	0.0003148945
433	87	1	-1	0	unknown	no	2	0.0002099297
441	132	7	-1	0	unknown	no	2	0.0002099297
457	57	2	-1	0	unknown	no	2	0.0002099297
463	159	2	195	2	failure	no	2	0.0002099297
473	107	2	-1	0	unknown	no	2	0.0002099297
475	111	4	-1	0	unknown	no	2	0.0002099297
477	1234	3	-1	0	unknown	yes	2	0.0002099297
483	132	1	-1	0	unknown	yes	2	0.0002099297
491	367	2	297	1	other	no	2	0.0002099297
512	412	1	-1	0	unknown	no	2	0.0002099297
517	256	2	351	2	failure	no	2	0.0002099297
519	59	2	-1	0	unknown	no	1	0.0001049648
529	262	4	-1	0	unknown	no	3	0.0003148945
542	395	2	-1	0	unknown	no	1	0.0001049648
545	168	1	-1	0	unknown	no	1	0.0001049648
547	270	2	347	1	failure	no	2	0.0002099297
550	283	2	-1	0	unknown	no	2	0.0002099297
552	77	1	-1	0	unknown	no	1	0.0001049648
563	342	1	-1	0	unknown	no	2	0.0002099297
567	293	1	-1	0	unknown	no	1	0.0001049648
568	127	2	-1	0	unknown	no	2	0.0002099297

588	136	1	-1	0	unknown	no	2	0.0002099297
591	90	6	-1	0	unknown	no	1	0.0001049648
594	651	1	-1	0	unknown	yes	2	0.0002099297
599	146	2	147	4	success	no	1	0.0001049648
605	426	1	-1	0	unknown	no	2	0.0002099297
619	55	2	298	4	failure	no	2	0.0002099297
629	42	4	-1	0	unknown	no	1	0.0001049648
631	304	2	-1	0	unknown	no	2	0.0002099297
633	55	3	-1	0	unknown	no	1	0.0001049648
636	42	1	-1	0	unknown	no	1	0.0001049648
637	1663	1	-1	0	unknown	yes	2	0.0002099297
638	218	1	330	2	failure	no	2	0.0002099297
643	80	8	-1	0	unknown	no	1	0.0001049648
656	106	1	-1	0	unknown	no	1	0.0001049648
687	260	5	-1	0	unknown	no	2	0.0002099297
690	228	2	-1	0	unknown	no	2	0.0002099297
701	968	1	-1	0	unknown	yes	2	0.0002099297
714	123	2	-1	0	unknown	no	1	0.0001049648
716	441	1	-1	0	unknown	no	2	0.0002099297
721	241	3	-1	0	unknown	no	2	0.0002099297
755	411	2	-1	0	unknown	no	2	0.0002099297
756	57	1	-1	0	unknown	no	1	0.0001049648
758	74	2	-1	0	unknown	no	1	0.0001049648
764	260	1	-1	0	unknown	no	1	0.0001049648
768	248	4	-1	0	unknown	no	2	0.0002099297
769	785	1	-1	0	unknown	no	2	0.0002099297
772	143	1	-1	0	unknown	no	2	0.0002099297
786	262	3	-1	0	unknown	no	2	0.0002099297
788	502	1	7	2	failure	no	2	0.0002099297
794	216	3	-1	0	unknown	no	1	0.0001049648
804	302	8	-1	0	unknown	no	1	0.0001049648
808	21	1	-1	0	unknown	no	2	0.0002099297
817	30	6	-1	0	unknown	no	1	0.0001049648
840	29	3	-1	0	unknown	no	2	0.0002099297
852	923	3	-1	0	unknown	no	1	0.0001049648
869	14	1	-1	0	unknown	no	1	0.0001049648
887	45	2	-1	0	unknown	no	2	0.0002099297
902	482	3	120	2	failure	no	2	0.0002099297
904	15	8	-1	0	unknown	no	2	0.0002099297
909	318	2	-1	0	unknown	no	1	0.0001049648
934	103	2	-1	0	unknown	no	1	0.0001049648
941	180	1	-1	0	unknown	no	1	0.0001049648
955	150	2	-1	0	unknown	no	2	0.0002099297

958	133	2	-1	0	unknown	no	1	0.0001049648
961	13	1	-1	0	unknown	no	1	0.0001049648
994	228	1	-1	0	unknown	no	2	0.0002099297
1006	143	3	357	1	failure	no	2	0.0002099297
1015	111	1	-1	0	unknown	no	1	0.0001049648
1045	50	1	-1	0	unknown	no	2	0.0002099297
1053	149	1	364	2	failure	no	2	0.0002099297
1059	41	1	-1	0	unknown	no	2	0.0002099297
1066	188	5	-1	0	unknown	no	2	0.0002099297
1076	381	3	-1	0	unknown	no	2	0.0002099297
1084	145	1	-1	0	unknown	no	2	0.0002099297
1088	87	4	357	4	failure	no	2	0.0002099297
1092	1529	1	397	1	failure	no	2	0.0002099297
1097	50	1	-1	0	unknown	no	2	0.0002099297
1126	185	4	-1	0	unknown	no	1	0.0001049648
1141	158	1	-1	0	unknown	no	1	0.0001049648
1144	244	6	-1	0	unknown	no	1	0.0001049648
1149	413	2	-1	0	unknown	no	2	0.0002099297
1164	446	1	-1	0	unknown	yes	2	0.0002099297
1189	119	2	280	2	failure	no	1	0.0001049648
1200	97	2	-1	0	unknown	no	2	0.0002099297
1204	362	1	-1	0	unknown	no	2	0.0002099297
1222	309	3	355	4	failure	no	2	0.0002099297
1225	103	6	-1	0	unknown	no	2	0.0002099297
1230	700	1	-1	0	unknown	no	1	0.0001049648
1233	59	2	-1	0	unknown	no	1	0.0001049648
1242	96	1	-1	0	unknown	no	2	0.0002099297
1245	281	1	-1	0	unknown	no	1	0.0001049648
1252	20	5	-1	0	unknown	no	2	0.0002099297
1262	152	2	-1	0	unknown	no	2	0.0002099297
1263	302	1	-1	0	unknown	no	2	0.0002099297
1267	288	3	-1	0	unknown	no	2	0.0002099297
1270	274	2	-1	0	unknown	no	2	0.0002099297
1278	693	2	-1	0	unknown	no	2	0.0002099297
1292	94	1	-1	0	unknown	no	2	0.0002099297
1296	41	3	-1	0	unknown	no	2	0.0002099297
1300	165	2	363	1	failure	no	1	0.0001049648
1321	574	5	-1	0	unknown	no	1	0.0001049648
1325	676	1	-1	0	unknown	no	2	0.0002099297
1332	2456	2	-1	0	unknown	yes	1	0.0001049648
1337	225	3	-1	0	unknown	no	1	0.0001049648
1340	721	1	-1	0	unknown	no	1	0.0001049648
1343	248	2	-1	0	unknown	no	2	0.0002099297

1358	211	2	-1	0	unknown	no	1	0.0001049648
1366	479	2	-1	0	unknown	no	1	0.0001049648
1371	257	1	-1	0	unknown	no	1	0.0001049648
1373	145	1	-1	0	unknown	no	2	0.0002099297
1398	96	2	-1	0	unknown	no	1	0.0001049648
1425	57	2	-1	0	unknown	no	3	0.0003148945
1440	180	1	-1	0	unknown	no	3	0.0003148945
1444	113	1	-1	0	unknown	no	1	0.0001049648
1446	262	3	-1	0	unknown	no	3	0.0003148945
1454	383	1	-1	0	unknown	no	3	0.0003148945
1463	748	3	-1	0	unknown	no	3	0.0003148945
1466	314	1	-1	0	unknown	no	1	0.0001049648
1472	210	3	-1	0	unknown	no	3	0.0003148945
1476	352	1	-1	0	unknown	no	2	0.0002099297
1478	135	2	-1	0	unknown	no	1	0.0001049648
1501	382	3	-1	0	unknown	no	2	0.0002099297
1507	908	1	-1	0	unknown	no	1	0.0001049648
1512	85	4	-1	0	unknown	no	3	0.0003148945
1517	253	1	-1	0	unknown	no	3	0.0003148945
1518	465	1	-1	0	unknown	no	3	0.0003148945
1528	183	1	-1	0	unknown	no	3	0.0003148945
1532	189	4	-1	0	unknown	no	3	0.0003148945
1535	652	1	370	4	other	no	2	0.0002099297
1561	205	2	-1	0	unknown	no	3	0.0003148945
1600	138	5	-1	0	unknown	no	3	0.0003148945
1603	172	1	370	1	failure	no	2	0.0002099297
1638	142	2	-1	0	unknown	no	3	0.0003148945
1647	123	3	-1	0	unknown	no	2	0.0002099297
1651	148	1	-1	0	unknown	no	1	0.0001049648
1658	655	4	-1	0	unknown	yes	2	0.0002099297
1662	171	2	96	5	success	no	2	0.0002099297
1664	154	2	-1	0	unknown	no	2	0.0002099297
1669	247	2	-1	0	unknown	no	3	0.0003148945
1676	54	2	-1	0	unknown	no	1	0.0001049648
1677	141	1	188	1	failure	no	3	0.0003148945
1699	52	1	-1	0	unknown	no	3	0.0003148945
1730	564	2	-1	0	unknown	no	3	0.0003148945
1744	240	2	-1	0	unknown	no	3	0.0003148945
1758	101	2	-1	0	unknown	no	3	0.0003148945
1759	451	1	-1	0	unknown	no	3	0.0003148945
1761	357	1	-1	0	unknown	no	3	0.0003148945
1808	112	2	-1	0	unknown	no	3	0.0003148945
1821	160	1	-1	0	unknown	no	3	0.0003148945

1829	819	3	-1	0	unknown	no	3	0.0003148945
1833	105	2	-1	0	unknown	no	2	0.0002099297
1838	155	1	-1	0	unknown	no	3	0.0003148945
1856	385	3	364	9	other	no	3	0.0003148945
1864	264	1	-1	0	unknown	yes	3	0.0003148945
1867	227	4	-1	0	unknown	no	1	0.0001049648
1889	717	1	-1	0	unknown	no	3	0.0003148945
1890	144	2	-1	0	unknown	no	2	0.0002099297
1904	132	2	-1	0	unknown	no	2	0.0002099297
1909	262	1	99	2	success	yes	3	0.0003148945
1921	184	5	-1	0	unknown	no	3	0.0003148945
1922	127	2	-1	0	unknown	no	3	0.0003148945
1926	288	1	-1	0	unknown	no	3	0.0003148945
1929	19	6	-1	0	unknown	no	3	0.0003148945
1939	116	2	-1	0	unknown	no	3	0.0003148945
1942	39	1	342	3	failure	no	3	0.0003148945
1954	160	2	360	3	failure	no	3	0.0003148945
1956	106	1	-1	0	unknown	no	3	0.0003148945
1969	244	1	-1	0	unknown	yes	3	0.0003148945
1974	670	3	-1	0	unknown	yes	3	0.0003148945
1983	252	9	185	5	other	yes	3	0.0003148945
1993	118	1	-1	0	unknown	no	3	0.0003148945
2013	528	1	-1	0	unknown	no	3	0.0003148945
2034	727	4	-1	0	unknown	no	3	0.0003148945
2041	77	1	-1	0	unknown	no	3	0.0003148945
2050	399	4	-1	0	unknown	no	3	0.0003148945
2051	130	1	-1	0	unknown	no	3	0.0003148945
2061	83	1	-1	0	unknown	no	3	0.0003148945
2085	557	7	-1	0	unknown	no	3	0.0003148945
2093	298	3	-1	0	unknown	no	3	0.0003148945
2094	657	7	-1	0	unknown	yes	3	0.0003148945
2095	163	2	113	3	failure	no	3	0.0003148945
2102	72	1	363	2	other	no	3	0.0003148945
2113	165	1	-1	0	unknown	no	3	0.0003148945
2117	75	1	-1	0	unknown	no	3	0.0003148945
2119	110	2	-1	0	unknown	no	2	0.0002099297
2125	58	7	-1	0	unknown	no	3	0.0003148945
2132	712	6	-1	0	unknown	yes	1	0.0001049648
2133	279	1	-1	0	unknown	no	3	0.0003148945
2151	358	4	-1	0	unknown	no	3	0.0003148945
2161	371	1	-1	0	unknown	no	3	0.0003148945
2162	128	3	-1	0	unknown	no	3	0.0003148945
2172	636	2	-1	0	unknown	no	3	0.0003148945

2177	67	1	-1	0	unknown	no	3	0.0003148945
2202	40	3	-1	0	unknown	no	3	0.0003148945
2213	63	1	-1	0	unknown	no	3	0.0003148945
2220	56	1	-1	0	unknown	no	3	0.0003148945
2223	160	1	-1	0	unknown	no	3	0.0003148945
2226	85	1	-1	0	unknown	no	3	0.0003148945
2232	78	3	-1	0	unknown	no	3	0.0003148945
2241	164	2	179	3	failure	no	3	0.0003148945
2242	1183	1	-1	0	unknown	no	3	0.0003148945
2243	90	1	-1	0	unknown	no	3	0.0003148945
2249	249	5	-1	0	unknown	no	3	0.0003148945
2257	316	3	99	9	other	yes	3	0.0003148945
2261	203	4	-1	0	unknown	no	3	0.0003148945
2268	313	1	-1	0	unknown	no	1	0.0001049648
2277	585	1	-1	0	unknown	no	1	0.0001049648
2282	474	2	-1	0	unknown	no	3	0.0003148945
2301	199	2	274	3	other	no	3	0.0003148945
2321	26	2	197	1	failure	no	3	0.0003148945
2322	205	5	-1	0	unknown	no	3	0.0003148945
2331	599	3	-1	0	unknown	no	3	0.0003148945
2350	161	3	-1	0	unknown	no	3	0.0003148945
2352	183	1	-1	0	unknown	no	3	0.0003148945
2361	612	1	344	1	other	no	1	0.0001049648
2362	89	1	-1	0	unknown	no	3	0.0003148945
2364	208	1	247	2	failure	no	3	0.0003148945
2370	257	1	474	3	failure	yes	3	0.0003148945
2375	105	4	366	2	failure	no	3	0.0003148945
2376	370	4	-1	0	unknown	no	3	0.0003148945
2377	63	3	-1	0	unknown	no	2	0.0002099297
2386	51	9	-1	0	unknown	no	3	0.0003148945
2392	136	2	-1	0	unknown	no	3	0.0003148945
2402	96	2	-1	0	unknown	no	3	0.0003148945
2415	215	3	-1	0	unknown	no	3	0.0003148945
2428	197	2	-1	0	unknown	no	3	0.0003148945
2431	162	3	-1	0	unknown	no	2	0.0002099297
2461	239	4	-1	0	unknown	yes	3	0.0003148945
2469	130	4	-1	0	unknown	no	3	0.0003148945
2479	203	2	2	3	other	no	3	0.0003148945
2483	220	2	-1	0	unknown	no	3	0.0003148945
2498	102	1	85	1	failure	no	3	0.0003148945
2501	185	4	-1	0	unknown	no	3	0.0003148945
2508	96	2	-1	0	unknown	no	2	0.0002099297
2525	106	1	-1	0	unknown	yes	3	0.0003148945

2535	383	6	-1	0	unknown	no	3	0.0003148945
2565	164	2	-1	0	unknown	no	3	0.0003148945
2579	131	2	-1	0	unknown	no	3	0.0003148945
2582	8	1	687	2	failure	no	3	0.0003148945
2585	582	11	-1	0	unknown	no	2	0.0002099297
2604	339	2	-1	0	unknown	no	3	0.0003148945
2607	224	3	74	4	failure	no	3	0.0003148945
2623	698	2	-1	0	unknown	no	2	0.0002099297
2624	317	1	-1	0	unknown	no	3	0.0003148945
2634	350	2	-1	0	unknown	no	3	0.0003148945
2640	115	6	-1	0	unknown	no	3	0.0003148945
2648	190	3	-1	0	unknown	no	3	0.0003148945
2649	59	1	-1	0	unknown	no	3	0.0003148945
2662	297	4	144	4	other	yes	3	0.0003148945
2675	897	2	-1	0	unknown	yes	2	0.0002099297
2686	17	14	-1	0	unknown	no	2	0.0002099297
2697	262	1	183	1	failure	yes	3	0.0003148945
2726	15	13	-1	0	unknown	no	2	0.0002099297
2736	77	2	-1	0	unknown	no	2	0.0002099297
2749	1063	5	-1	0	unknown	yes	2	0.0002099297
2766	165	3	101	1	other	no	2	0.0002099297
2779	476	3	-1	0	unknown	no	2	0.0002099297
2794	598	4	-1	0	unknown	no	1	0.0001049648
2803	509	2	-1	0	unknown	no	2	0.0002099297
2814	127	2	-1	0	unknown	no	2	0.0002099297
2818	104	5	-1	0	unknown	no	2	0.0002099297
2838	669	1	-1	0	unknown	yes	2	0.0002099297
2843	595	1	-1	0	unknown	no	2	0.0002099297
2850	876	1	-1	0	unknown	yes	1	0.0001049648
2862	205	1	-1	0	unknown	no	1	0.0001049648
2864	143	1	154	3	failure	no	2	0.0002099297
2868	394	2	-1	0	unknown	yes	2	0.0002099297
2871	93	4	-1	0	unknown	no	2	0.0002099297
2872	75	1	190	6	failure	no	1	0.0001049648
2883	417	1	184	4	success	yes	3	0.0003148945
2885	108	1	-1	0	unknown	no	1	0.0001049648
2894	434	1	57	1	failure	yes	1	0.0001049648
2895	54	2	-1	0	unknown	no	3	0.0003148945
2899	181	1	-1	0	unknown	yes	1	0.0001049648
2925	330	1	-1	0	unknown	no	2	0.0002099297
2926	47	1	-1	0	unknown	no	3	0.0003148945
2934	168	3	-1	0	unknown	no	3	0.0003148945
2938	87	2	-1	0	unknown	no	3	0.0003148945

2939	352	2	-1	0	unknown	yes	3	0.0003148945
2942	165	4	-1	0	unknown	no	2	0.0002099297
2944	67	2	-1	0	unknown	no	3	0.0003148945
2951	177	1	-1	0	unknown	no	2	0.0002099297
2964	58	1	-1	0	unknown	no	2	0.0002099297
2967	208	2	-1	0	unknown	no	2	0.0002099297
2970	18	30	-1	0	unknown	no	3	0.0003148945
2976	140	2	-1	0	unknown	no	3	0.0003148945
2983	9	5	174	12	other	no	2	0.0002099297
2990	101	1	-1	0	unknown	no	1	0.0001049648
3014	58	1	136	1	failure	no	3	0.0003148945
3015	37	3	-1	0	unknown	no	1	0.0001049648
3025	215	3	-1	0	unknown	no	2	0.0002099297
3040	554	1	-1	0	unknown	yes	3	0.0003148945
3069	147	1	-1	0	unknown	no	3	0.0003148945
3082	118	6	-1	0	unknown	no	3	0.0003148945
3097	391	1	-1	0	unknown	yes	2	0.0002099297
3112	62	6	-1	0	unknown	no	2	0.0002099297
3116	456	3	-1	0	unknown	no	2	0.0002099297
3117	131	6	363	9	failure	no	2	0.0002099297
3119	121	2	341	4	failure	no	2	0.0002099297
3125	502	3	-1	0	unknown	no	2	0.0002099297
3162	754	1	-1	0	unknown	no	2	0.0002099297
3167	213	1	-1	0	unknown	no	2	0.0002099297
3169	55	5	-1	0	unknown	no	1	0.0001049648
3179	97	1	370	1	failure	no	2	0.0002099297
3180	263	2	-1	0	unknown	no	2	0.0002099297
3182	586	3	-1	0	unknown	no	2	0.0002099297
3192	65	1	-1	0	unknown	no	2	0.0002099297
3193	104	2	-1	0	unknown	no	1	0.0001049648
3199	937	3	-1	0	unknown	yes	2	0.0002099297
3201	322	3	-1	0	unknown	no	2	0.0002099297
3211	362	1	287	13	failure	no	1	0.0001049648
3227	602	9	-1	0	unknown	no	3	0.0003148945
3234	162	3	-1	0	unknown	no	1	0.0001049648
3251	955	2	-1	0	unknown	yes	2	0.0002099297
3256	203	5	-1	0	unknown	no	2	0.0002099297
3261	30	1	404	2	success	no	2	0.0002099297
3288	299	1	-1	0	unknown	no	3	0.0003148945
3295	203	1	-1	0	unknown	no	2	0.0002099297
3303	322	1	-1	0	unknown	no	2	0.0002099297
3316	113	6	-1	0	unknown	no	2	0.0002099297
3318	389	1	-1	0	unknown	no	2	0.0002099297

3323	272	2	-1	0	unknown	no	2	0.0002099297
3329	283	1	-1	0	unknown	no	2	0.0002099297
3363	389	2	-1	0	unknown	no	2	0.0002099297
3377	66	2	-1	0	unknown	no	2	0.0002099297
3385	20	6	175	15	other	no	2	0.0002099297
3409	408	2	-1	0	unknown	no	2	0.0002099297
3424	158	2	-1	0	unknown	yes	2	0.0002099297
3434	757	4	-1	0	unknown	no	2	0.0002099297
3436	487	7	-1	0	unknown	no	2	0.0002099297
3440	297	2	-1	0	unknown	no	2	0.0002099297
3444	56	2	-1	0	unknown	no	2	0.0002099297
3450	7	8	185	1	failure	no	2	0.0002099297
3460	161	1	-1	0	unknown	no	1	0.0001049648
3461	150	1	360	1	failure	no	2	0.0002099297
3463	201	1	-1	0	unknown	no	2	0.0002099297
3478	318	4	317	3	failure	no	3	0.0003148945
3479	622	1	-1	0	unknown	no	2	0.0002099297
3481	187	2	-1	0	unknown	no	2	0.0002099297
3482	285	7	-1	0	unknown	no	3	0.0003148945
3519	91	1	-1	0	unknown	no	1	0.0001049648
3525	158	2	-1	0	unknown	no	2	0.0002099297
3531	69	3	-1	0	unknown	no	1	0.0001049648
3536	102	2	210	2	other	no	1	0.0001049648
3539	294	2	105	7	other	yes	3	0.0003148945
3552	449	2	38	10	other	yes	2	0.0002099297
3553	74	2	-1	0	unknown	no	3	0.0003148945
3572	122	3	-1	0	unknown	no	1	0.0001049648
3577	390	1	-1	0	unknown	no	2	0.0002099297
3595	1740	2	-1	0	unknown	no	2	0.0002099297
3597	441	1	56	1	other	yes	3	0.0003148945
3606	32	3	-1	0	unknown	no	2	0.0002099297
3611	77	2	-1	0	unknown	no	2	0.0002099297
3623	196	1	-1	0	unknown	no	2	0.0002099297
3624	115	1	61	1	failure	no	2	0.0002099297
3635	9	2	172	5	failure	no	2	0.0002099297
3642	247	2	-1	0	unknown	no	3	0.0003148945
3661	107	1	-1	0	unknown	no	3	0.0003148945
3687	115	1	-1	0	unknown	no	2	0.0002099297
3692	260	1	-1	0	unknown	no	3	0.0003148945
3695	284	2	-1	0	unknown	no	2	0.0002099297
3706	156	2	-1	0	unknown	no	2	0.0002099297
3709	63	1	-1	0	unknown	no	2	0.0002099297
3757	91	2	-1	0	unknown	no	2	0.0002099297

3762	109	3	-1	0	unknown	yes	2	0.0002099297
3767	7	11	351	1	failure	no	2	0.0002099297
3791	78	5	292	3	failure	no	3	0.0003148945
3796	24	12	-1	0	unknown	no	2	0.0002099297
3806	257	2	-1	0	unknown	no	2	0.0002099297
3827	43	4	-1	0	unknown	no	2	0.0002099297
3828	343	4	-1	0	unknown	no	2	0.0002099297
3831	147	1	-1	0	unknown	no	2	0.0002099297
3846	71	1	-1	0	unknown	no	3	0.0003148945
3848	415	1	89	1	success	yes	2	0.0002099297
3849	283	1	288	12	other	no	3	0.0003148945
3854	175	1	-1	0	unknown	no	2	0.0002099297
3865	156	1	-1	0	unknown	no	2	0.0002099297
3867	119	1	-1	0	unknown	no	3	0.0003148945
3869	403	3	-1	0	unknown	no	2	0.0002099297
3876	217	2	-1	0	unknown	no	2	0.0002099297
3888	78	3	-1	0	unknown	yes	3	0.0003148945
3890	762	3	-1	0	unknown	yes	2	0.0002099297
3891	524	1	96	5	success	yes	2	0.0002099297
3893	311	1	-1	0	unknown	no	2	0.0002099297
3896	355	1	-1	0	unknown	no	2	0.0002099297
3902	167	5	-1	0	unknown	no	2	0.0002099297
3913	185	6	-1	0	unknown	no	2	0.0002099297
3918	37	10	-1	0	unknown	no	2	0.0002099297
3935	99	2	-1	0	unknown	no	2	0.0002099297
3939	95	1	-1	0	unknown	no	3	0.0003148945
3960	137	2	-1	0	unknown	no	1	0.0001049648
3965	124	2	-1	0	unknown	no	2	0.0002099297
3971	258	1	-1	0	unknown	no	2	0.0002099297
3975	108	1	-1	0	unknown	no	2	0.0002099297
3982	96	4	-1	0	unknown	no	2	0.0002099297
3986	29	14	-1	0	unknown	no	3	0.0003148945
3989	94	2	-1	0	unknown	no	2	0.0002099297
3990	153	1	371	2	failure	no	2	0.0002099297
4009	467	2	88	4	other	yes	2	0.0002099297
4024	73	4	-1	0	unknown	no	3	0.0003148945
4039	19	1	-1	0	unknown	no	2	0.0002099297
4050	161	4	-1	0	unknown	no	2	0.0002099297
4051	225	2	-1	0	unknown	no	1	0.0001049648
4055	182	8	-1	0	unknown	no	2	0.0002099297
4077	161	2	-1	0	unknown	no	2	0.0002099297
4081	796	1	109	1	failure	yes	3	0.0003148945
4111	53	1	-1	0	unknown	no	2	0.0002099297

4128	165	1	-1	0	unknown	no	1	0.0001049648
4136	161	2	-1	0	unknown	no	2	0.0002099297
4146	65	6	-1	0	unknown	no	2	0.0002099297
4149	239	2	349	3	success	no	2	0.0002099297
4153	578	1	364	1	other	no	3	0.0003148945
4165	546	1	-1	0	unknown	no	3	0.0003148945
4166	320	4	-1	0	unknown	no	2	0.0002099297
4172	214	1	-1	0	unknown	no	2	0.0002099297
4199	147	2	-1	0	unknown	no	3	0.0003148945
4202	114	2	-1	0	unknown	no	2	0.0002099297
4209	198	1	-1	0	unknown	no	2	0.0002099297
4213	13	5	-1	0	unknown	no	2	0.0002099297
4219	1721	2	-1	0	unknown	yes	2	0.0002099297
4233	339	1	-1	0	unknown	no	2	0.0002099297
4236	132	8	-1	0	unknown	no	2	0.0002099297
4252	587	2	-1	0	unknown	yes	2	0.0002099297
4254	432	2	-1	0	unknown	no	2	0.0002099297
4258	261	2	-1	0	unknown	no	2	0.0002099297
4266	142	1	-1	0	unknown	no	2	0.0002099297
4273	330	1	-1	0	unknown	no	2	0.0002099297
4283	731	4	-1	0	unknown	no	2	0.0002099297
4310	168	1	-1	0	unknown	no	1	0.0001049648
4333	352	3	-1	0	unknown	no	2	0.0002099297
4335	187	3	-1	0	unknown	no	3	0.0003148945
4348	137	1	272	2	failure	no	2	0.0002099297
4349	380	1	-1	0	unknown	no	2	0.0002099297
4351	205	6	-1	0	unknown	no	3	0.0003148945
4364	119	4	-1	0	unknown	no	2	0.0002099297
4366	113	1	-1	0	unknown	no	2	0.0002099297
4385	52	4	91	1	other	no	2	0.0002099297
4389	121	3	-1	0	unknown	no	2	0.0002099297
4398	606	2	-1	0	unknown	no	2	0.0002099297
4403	241	2	-1	0	unknown	no	1	0.0001049648
4410	172	3	-1	0	unknown	no	2	0.0002099297
4415	517	1	282	4	success	yes	2	0.0002099297
4416	340	2	-1	0	unknown	no	1	0.0001049648
4417	148	1	871	2	failure	no	3	0.0003148945
4429	235	2	-1	0	unknown	no	2	0.0002099297
4435	214	1	-1	0	unknown	no	2	0.0002099297
4470	62	2	-1	0	unknown	no	1	0.0001049648
4474	404	1	182	1	success	yes	2	0.0002099297
4489	104	1	99	2	other	yes	2	0.0002099297
4497	41	1	-1	0	unknown	no	1	0.0001049648

4503	759	2	-1	0	unknown	yes	1	0.0001049648
4521	81	1	-1	0	unknown	no	1	0.0001049648
	job	ID_unit		Prob	Stratum			
7	admin.	7	0.1108787			1		
14	admin.	14	0.1108787			1		
23	admin.	23	0.1108787			1		
26	admin.	26	0.1108787			1		
32	admin.	32	0.1108787			1		
43	admin.	43	0.1108787			1		
78	admin.	78	0.1108787			1		
81	admin.	81	0.1108787			1		
90	admin.	90	0.1108787			1		
91	admin.	91	0.1108787			1		
109	admin.	109	0.1108787			1		
118	admin.	118	0.1108787			1		
135	admin.	135	0.1108787			1		
137	admin.	137	0.1108787			1		
143	admin.	143	0.1108787			1		
153	admin.	153	0.1108787			1		
166	admin.	166	0.1108787			1		
179	admin.	179	0.1108787			1		
195	admin.	195	0.1108787			1		
197	admin.	197	0.1108787			1		
211	admin.	211	0.1108787			1		
217	admin.	217	0.1108787			1		
224	admin.	224	0.1108787			1		
229	admin.	229	0.1108787			1		
244	admin.	244	0.1108787			1		
254	admin.	254	0.1108787			1		
256	admin.	256	0.1108787			1		
263	admin.	263	0.1108787			1		
299	admin.	299	0.1108787			1		
306	admin.	306	0.1108787			1		
309	admin.	309	0.1108787			1		
328	admin.	328	0.1108787			1		
330	admin.	330	0.1108787			1		
332	admin.	332	0.1108787			1		
348	admin.	348	0.1108787			1		
355	admin.	355	0.1108787			1		
359	admin.	359	0.1108787			1		
373	admin.	373	0.1108787			1		
374	admin.	374	0.1108787			1		
393	admin.	393	0.1108787			1		

411	admin.	411 0.1108787	1
415	admin.	415 0.1108787	1
420	admin.	420 0.1108787	1
425	admin.	425 0.1108787	1
426	admin.	426 0.1108787	1
432	admin.	432 0.1108787	1
433	admin.	433 0.1108787	1
441	admin.	441 0.1108787	1
457	admin.	457 0.1108787	1
463	admin.	463 0.1108787	1
473	admin.	473 0.1108787	1
475	admin.	475 0.1108787	1
477	admin.	477 0.1108787	1
483	blue-collar	483 0.1109937	2
491	blue-collar	491 0.1109937	2
512	blue-collar	512 0.1109937	2
517	blue-collar	517 0.1109937	2
519	blue-collar	519 0.1109937	2
529	blue-collar	529 0.1109937	2
542	blue-collar	542 0.1109937	2
545	blue-collar	545 0.1109937	2
547	blue-collar	547 0.1109937	2
550	blue-collar	550 0.1109937	2
552	blue-collar	552 0.1109937	2
563	blue-collar	563 0.1109937	2
567	blue-collar	567 0.1109937	2
568	blue-collar	568 0.1109937	2
588	blue-collar	588 0.1109937	2
591	blue-collar	591 0.1109937	2
594	blue-collar	594 0.1109937	2
599	blue-collar	599 0.1109937	2
605	blue-collar	605 0.1109937	2
619	blue-collar	619 0.1109937	2
629	blue-collar	629 0.1109937	2
631	blue-collar	631 0.1109937	2
633	blue-collar	633 0.1109937	2
636	blue-collar	636 0.1109937	2
637	blue-collar	637 0.1109937	2
638	blue-collar	638 0.1109937	2
643	blue-collar	643 0.1109937	2
656	blue-collar	656 0.1109937	2
687	blue-collar	687 0.1109937	2
690	blue-collar	690 0.1109937	2

701	blue-collar	701 0.1109937	2
714	blue-collar	714 0.1109937	2
716	blue-collar	716 0.1109937	2
721	blue-collar	721 0.1109937	2
755	blue-collar	755 0.1109937	2
756	blue-collar	756 0.1109937	2
758	blue-collar	758 0.1109937	2
764	blue-collar	764 0.1109937	2
768	blue-collar	768 0.1109937	2
769	blue-collar	769 0.1109937	2
772	blue-collar	772 0.1109937	2
786	blue-collar	786 0.1109937	2
788	blue-collar	788 0.1109937	2
794	blue-collar	794 0.1109937	2
804	blue-collar	804 0.1109937	2
808	blue-collar	808 0.1109937	2
817	blue-collar	817 0.1109937	2
840	blue-collar	840 0.1109937	2
852	blue-collar	852 0.1109937	2
869	blue-collar	869 0.1109937	2
887	blue-collar	887 0.1109937	2
902	blue-collar	902 0.1109937	2
904	blue-collar	904 0.1109937	2
909	blue-collar	909 0.1109937	2
934	blue-collar	934 0.1109937	2
941	blue-collar	941 0.1109937	2
955	blue-collar	955 0.1109937	2
958	blue-collar	958 0.1109937	2
961	blue-collar	961 0.1109937	2
994	blue-collar	994 0.1109937	2
1006	blue-collar	1006 0.1109937	2
1015	blue-collar	1015 0.1109937	2
1045	blue-collar	1045 0.1109937	2
1053	blue-collar	1053 0.1109937	2
1059	blue-collar	1059 0.1109937	2
1066	blue-collar	1066 0.1109937	2
1076	blue-collar	1076 0.1109937	2
1084	blue-collar	1084 0.1109937	2
1088	blue-collar	1088 0.1109937	2
1092	blue-collar	1092 0.1109937	2
1097	blue-collar	1097 0.1109937	2
1126	blue-collar	1126 0.1109937	2
1141	blue-collar	1141 0.1109937	2

1144	blue-collar	1144	0.1109937	2
1149	blue-collar	1149	0.1109937	2
1164	blue-collar	1164	0.1109937	2
1189	blue-collar	1189	0.1109937	2
1200	blue-collar	1200	0.1109937	2
1204	blue-collar	1204	0.1109937	2
1222	blue-collar	1222	0.1109937	2
1225	blue-collar	1225	0.1109937	2
1230	blue-collar	1230	0.1109937	2
1233	blue-collar	1233	0.1109937	2
1242	blue-collar	1242	0.1109937	2
1245	blue-collar	1245	0.1109937	2
1252	blue-collar	1252	0.1109937	2
1262	blue-collar	1262	0.1109937	2
1263	blue-collar	1263	0.1109937	2
1267	blue-collar	1267	0.1109937	2
1270	blue-collar	1270	0.1109937	2
1278	blue-collar	1278	0.1109937	2
1292	blue-collar	1292	0.1109937	2
1296	blue-collar	1296	0.1109937	2
1300	blue-collar	1300	0.1109937	2
1321	blue-collar	1321	0.1109937	2
1325	blue-collar	1325	0.1109937	2
1332	blue-collar	1332	0.1109937	2
1337	blue-collar	1337	0.1109937	2
1340	blue-collar	1340	0.1109937	2
1343	blue-collar	1343	0.1109937	2
1358	blue-collar	1358	0.1109937	2
1366	blue-collar	1366	0.1109937	2
1371	blue-collar	1371	0.1109937	2
1373	blue-collar	1373	0.1109937	2
1398	blue-collar	1398	0.1109937	2
1425	entrepreneur	1425	0.1130952	3
1440	entrepreneur	1440	0.1130952	3
1444	entrepreneur	1444	0.1130952	3
1446	entrepreneur	1446	0.1130952	3
1454	entrepreneur	1454	0.1130952	3
1463	entrepreneur	1463	0.1130952	3
1466	entrepreneur	1466	0.1130952	3
1472	entrepreneur	1472	0.1130952	3
1476	entrepreneur	1476	0.1130952	3
1478	entrepreneur	1478	0.1130952	3
1501	entrepreneur	1501	0.1130952	3

1507	entrepreneur	1507	0.1130952	3
1512	entrepreneur	1512	0.1130952	3
1517	entrepreneur	1517	0.1130952	3
1518	entrepreneur	1518	0.1130952	3
1528	entrepreneur	1528	0.1130952	3
1532	entrepreneur	1532	0.1130952	3
1535	entrepreneur	1535	0.1130952	3
1561	entrepreneur	1561	0.1130952	3
1600	housemaid	1600	0.1071429	4
1603	housemaid	1603	0.1071429	4
1638	housemaid	1638	0.1071429	4
1647	housemaid	1647	0.1071429	4
1651	housemaid	1651	0.1071429	4
1658	housemaid	1658	0.1071429	4
1662	housemaid	1662	0.1071429	4
1664	housemaid	1664	0.1071429	4
1669	housemaid	1669	0.1071429	4
1676	housemaid	1676	0.1071429	4
1677	housemaid	1677	0.1071429	4
1699	housemaid	1699	0.1071429	4
1730	management	1730	0.1104231	5
1744	management	1744	0.1104231	5
1758	management	1758	0.1104231	5
1759	management	1759	0.1104231	5
1761	management	1761	0.1104231	5
1808	management	1808	0.1104231	5
1821	management	1821	0.1104231	5
1829	management	1829	0.1104231	5
1833	management	1833	0.1104231	5
1838	management	1838	0.1104231	5
1856	management	1856	0.1104231	5
1864	management	1864	0.1104231	5
1867	management	1867	0.1104231	5
1889	management	1889	0.1104231	5
1890	management	1890	0.1104231	5
1904	management	1904	0.1104231	5
1909	management	1909	0.1104231	5
1921	management	1921	0.1104231	5
1922	management	1922	0.1104231	5
1926	management	1926	0.1104231	5
1929	management	1929	0.1104231	5
1939	management	1939	0.1104231	5
1942	management	1942	0.1104231	5

1954	management	1954 0.1104231	5
1956	management	1956 0.1104231	5
1969	management	1969 0.1104231	5
1974	management	1974 0.1104231	5
1983	management	1983 0.1104231	5
1993	management	1993 0.1104231	5
2013	management	2013 0.1104231	5
2034	management	2034 0.1104231	5
2041	management	2041 0.1104231	5
2050	management	2050 0.1104231	5
2051	management	2051 0.1104231	5
2061	management	2061 0.1104231	5
2085	management	2085 0.1104231	5
2093	management	2093 0.1104231	5
2094	management	2094 0.1104231	5
2095	management	2095 0.1104231	5
2102	management	2102 0.1104231	5
2113	management	2113 0.1104231	5
2117	management	2117 0.1104231	5
2119	management	2119 0.1104231	5
2125	management	2125 0.1104231	5
2132	management	2132 0.1104231	5
2133	management	2133 0.1104231	5
2151	management	2151 0.1104231	5
2161	management	2161 0.1104231	5
2162	management	2162 0.1104231	5
2172	management	2172 0.1104231	5
2177	management	2177 0.1104231	5
2202	management	2202 0.1104231	5
2213	management	2213 0.1104231	5
2220	management	2220 0.1104231	5
2223	management	2223 0.1104231	5
2226	management	2226 0.1104231	5
2232	management	2232 0.1104231	5
2241	management	2241 0.1104231	5
2242	management	2242 0.1104231	5
2243	management	2243 0.1104231	5
2249	management	2249 0.1104231	5
2257	management	2257 0.1104231	5
2261	management	2261 0.1104231	5
2268	management	2268 0.1104231	5
2277	management	2277 0.1104231	5
2282	management	2282 0.1104231	5

2301	management	2301	0.1104231	5
2321	management	2321	0.1104231	5
2322	management	2322	0.1104231	5
2331	management	2331	0.1104231	5
2350	management	2350	0.1104231	5
2352	management	2352	0.1104231	5
2361	management	2361	0.1104231	5
2362	management	2362	0.1104231	5
2364	management	2364	0.1104231	5
2370	management	2370	0.1104231	5
2375	management	2375	0.1104231	5
2376	management	2376	0.1104231	5
2377	management	2377	0.1104231	5
2386	management	2386	0.1104231	5
2392	management	2392	0.1104231	5
2402	management	2402	0.1104231	5
2415	management	2415	0.1104231	5
2428	management	2428	0.1104231	5
2431	management	2431	0.1104231	5
2461	management	2461	0.1104231	5
2469	management	2469	0.1104231	5
2479	management	2479	0.1104231	5
2483	management	2483	0.1104231	5
2498	management	2498	0.1104231	5
2501	management	2501	0.1104231	5
2508	management	2508	0.1104231	5
2525	management	2525	0.1104231	5
2535	management	2535	0.1104231	5
2565	management	2565	0.1104231	5
2579	management	2579	0.1104231	5
2582	management	2582	0.1104231	5
2585	management	2585	0.1104231	5
2604	management	2604	0.1104231	5
2607	management	2607	0.1104231	5
2623	management	2623	0.1104231	5
2624	management	2624	0.1104231	5
2634	management	2634	0.1104231	5
2640	management	2640	0.1104231	5
2648	management	2648	0.1104231	5
2649	management	2649	0.1104231	5
2662	management	2662	0.1104231	5
2675	retired	2675	0.1086957	6
2686	retired	2686	0.1086957	6

2697	retired	2697	0.1086957	6
2726	retired	2726	0.1086957	6
2736	retired	2736	0.1086957	6
2749	retired	2749	0.1086957	6
2766	retired	2766	0.1086957	6
2779	retired	2779	0.1086957	6
2794	retired	2794	0.1086957	6
2803	retired	2803	0.1086957	6
2814	retired	2814	0.1086957	6
2818	retired	2818	0.1086957	6
2838	retired	2838	0.1086957	6
2843	retired	2843	0.1086957	6
2850	retired	2850	0.1086957	6
2862	retired	2862	0.1086957	6
2864	retired	2864	0.1086957	6
2868	retired	2868	0.1086957	6
2871	retired	2871	0.1086957	6
2872	retired	2872	0.1086957	6
2883	retired	2883	0.1086957	6
2885	retired	2885	0.1086957	6
2894	retired	2894	0.1086957	6
2895	retired	2895	0.1086957	6
2899	retired	2899	0.1086957	6
2925	self-employed	2925	0.1092896	7
2926	self-employed	2926	0.1092896	7
2934	self-employed	2934	0.1092896	7
2938	self-employed	2938	0.1092896	7
2939	self-employed	2939	0.1092896	7
2942	self-employed	2942	0.1092896	7
2944	self-employed	2944	0.1092896	7
2951	self-employed	2951	0.1092896	7
2964	self-employed	2964	0.1092896	7
2967	self-employed	2967	0.1092896	7
2970	self-employed	2970	0.1092896	7
2976	self-employed	2976	0.1092896	7
2983	self-employed	2983	0.1092896	7
2990	self-employed	2990	0.1092896	7
3014	self-employed	3014	0.1092896	7
3015	self-employed	3015	0.1092896	7
3025	self-employed	3025	0.1092896	7
3040	self-employed	3040	0.1092896	7
3069	self-employed	3069	0.1092896	7
3082	self-employed	3082	0.1092896	7

3097	services	3097	0.1103118	8
3112	services	3112	0.1103118	8
3116	services	3116	0.1103118	8
3117	services	3117	0.1103118	8
3119	services	3119	0.1103118	8
3125	services	3125	0.1103118	8
3162	services	3162	0.1103118	8
3167	services	3167	0.1103118	8
3169	services	3169	0.1103118	8
3179	services	3179	0.1103118	8
3180	services	3180	0.1103118	8
3182	services	3182	0.1103118	8
3192	services	3192	0.1103118	8
3193	services	3193	0.1103118	8
3199	services	3199	0.1103118	8
3201	services	3201	0.1103118	8
3211	services	3211	0.1103118	8
3227	services	3227	0.1103118	8
3234	services	3234	0.1103118	8
3251	services	3251	0.1103118	8
3256	services	3256	0.1103118	8
3261	services	3261	0.1103118	8
3288	services	3288	0.1103118	8
3295	services	3295	0.1103118	8
3303	services	3303	0.1103118	8
3316	services	3316	0.1103118	8
3318	services	3318	0.1103118	8
3323	services	3323	0.1103118	8
3329	services	3329	0.1103118	8
3363	services	3363	0.1103118	8
3377	services	3377	0.1103118	8
3385	services	3385	0.1103118	8
3409	services	3409	0.1103118	8
3424	services	3424	0.1103118	8
3434	services	3434	0.1103118	8
3436	services	3436	0.1103118	8
3440	services	3440	0.1103118	8
3444	services	3444	0.1103118	8
3450	services	3450	0.1103118	8
3460	services	3460	0.1103118	8
3461	services	3461	0.1103118	8
3463	services	3463	0.1103118	8
3478	services	3478	0.1103118	8

3479	services	3479	0.1103118	8
3481	services	3481	0.1103118	8
3482	services	3482	0.1103118	8
3519	student	3519	0.1071429	9
3525	student	3525	0.1071429	9
3531	student	3531	0.1071429	9
3536	student	3536	0.1071429	9
3539	student	3539	0.1071429	9
3552	student	3552	0.1071429	9
3553	student	3553	0.1071429	9
3572	student	3572	0.1071429	9
3577	student	3577	0.1071429	9
3595	technician	3595	0.1106771	10
3597	technician	3597	0.1106771	10
3606	technician	3606	0.1106771	10
3611	technician	3611	0.1106771	10
3623	technician	3623	0.1106771	10
3624	technician	3624	0.1106771	10
3635	technician	3635	0.1106771	10
3642	technician	3642	0.1106771	10
3661	technician	3661	0.1106771	10
3687	technician	3687	0.1106771	10
3692	technician	3692	0.1106771	10
3695	technician	3695	0.1106771	10
3706	technician	3706	0.1106771	10
3709	technician	3709	0.1106771	10
3757	technician	3757	0.1106771	10
3762	technician	3762	0.1106771	10
3767	technician	3767	0.1106771	10
3791	technician	3791	0.1106771	10
3796	technician	3796	0.1106771	10
3806	technician	3806	0.1106771	10
3827	technician	3827	0.1106771	10
3828	technician	3828	0.1106771	10
3831	technician	3831	0.1106771	10
3846	technician	3846	0.1106771	10
3848	technician	3848	0.1106771	10
3849	technician	3849	0.1106771	10
3854	technician	3854	0.1106771	10
3865	technician	3865	0.1106771	10
3867	technician	3867	0.1106771	10
3869	technician	3869	0.1106771	10
3876	technician	3876	0.1106771	10

3888	technician	3888	0.1106771	10
3890	technician	3890	0.1106771	10
3891	technician	3891	0.1106771	10
3893	technician	3893	0.1106771	10
3896	technician	3896	0.1106771	10
3902	technician	3902	0.1106771	10
3913	technician	3913	0.1106771	10
3918	technician	3918	0.1106771	10
3935	technician	3935	0.1106771	10
3939	technician	3939	0.1106771	10
3960	technician	3960	0.1106771	10
3965	technician	3965	0.1106771	10
3971	technician	3971	0.1106771	10
3975	technician	3975	0.1106771	10
3982	technician	3982	0.1106771	10
3986	technician	3986	0.1106771	10
3989	technician	3989	0.1106771	10
3990	technician	3990	0.1106771	10
4009	technician	4009	0.1106771	10
4024	technician	4024	0.1106771	10
4039	technician	4039	0.1106771	10
4050	technician	4050	0.1106771	10
4051	technician	4051	0.1106771	10
4055	technician	4055	0.1106771	10
4077	technician	4077	0.1106771	10
4081	technician	4081	0.1106771	10
4111	technician	4111	0.1106771	10
4128	technician	4128	0.1106771	10
4136	technician	4136	0.1106771	10
4146	technician	4146	0.1106771	10
4149	technician	4149	0.1106771	10
4153	technician	4153	0.1106771	10
4165	technician	4165	0.1106771	10
4166	technician	4166	0.1106771	10
4172	technician	4172	0.1106771	10
4199	technician	4199	0.1106771	10
4202	technician	4202	0.1106771	10
4209	technician	4209	0.1106771	10
4213	technician	4213	0.1106771	10
4219	technician	4219	0.1106771	10
4233	technician	4233	0.1106771	10
4236	technician	4236	0.1106771	10
4252	technician	4252	0.1106771	10

4254	technician	4254	0.1106771	10
4258	technician	4258	0.1106771	10
4266	technician	4266	0.1106771	10
4273	technician	4273	0.1106771	10
4283	technician	4283	0.1106771	10
4310	technician	4310	0.1106771	10
4333	technician	4333	0.1106771	10
4335	technician	4335	0.1106771	10
4348	technician	4348	0.1106771	10
4349	technician	4349	0.1106771	10
4351	technician	4351	0.1106771	10
4364	unemployed	4364	0.1093750	11
4366	unemployed	4366	0.1093750	11
4385	unemployed	4385	0.1093750	11
4389	unemployed	4389	0.1093750	11
4398	unemployed	4398	0.1093750	11
4403	unemployed	4403	0.1093750	11
4410	unemployed	4410	0.1093750	11
4415	unemployed	4415	0.1093750	11
4416	unemployed	4416	0.1093750	11
4417	unemployed	4417	0.1093750	11
4429	unemployed	4429	0.1093750	11
4435	unemployed	4435	0.1093750	11
4470	unemployed	4470	0.1093750	11
4474	unemployed	4474	0.1093750	11
4489	unknown	4489	0.1052632	12
4497	unknown	4497	0.1052632	12
4503	unknown	4503	0.1052632	12
4521	unknown	4521	0.1052632	12

```
# Cálculo manual del estimador estratificado
# estimacion_estrat <- datos_muestra_estrat %>%
#   group_by(job) %>%
#   summarise(media_h = mean(balance)) %>%
#   left_join(estratos_info, by = "job") %>%
#   summarise(media_global_st = sum(media_h * wh))

# --- Estratificado Manual (por Job) ---
# Requiere unir Nh (tamaño poblacional del estrato) para el cálculo del SE
datos_muestra_estrat_completa <- datos_muestra_estrat %>%
```

```

left_join(estratos_info %>% dplyr::select(job, Nh), by = "job")

diseno_estrat_manual <- svydesign(id = ~1, strata = ~job, data = datos_muestra_estrat_completo)

estimacion_estrat <- svymean(~balance, diseno_estrat_manual, deff = TRUE) # Estratificado
estimacion_estrat

```

```

      mean      SE  DEff
balance 1659.0  176.3 1.0106

```

```

media_real <- mean(bank_data$balance)
print(paste("Media Real:", round(media_real, 2)))

```

```
[1] "Media Real: 1422.66"
```

```
print(paste("Media Estratificada:", round(estimacion_estrat, 2)))
```

```
[1] "Media Estratificada: 1658.96"
```


Obtenemos una estimacion bastante buena.

```

# Comparar proporciones
comp_proporciones <- data.frame(
  Trabajo = estratos_info$job,
  Poblacion = estratos_info$wh,
  Muestra = as.vector(table(datos_muestra_estrat$job) / nrow(datos_muestra_estrat))
)

ggplot(comp_proporciones, aes(x = Trabajo)) +
  geom_bar(aes(y = Poblacion), stat = "identity", fill = "gray", alpha = 0.5) +
  geom_point(aes(y = Muestra), color = "red", size = 3) +
  coord_flip() +
  labs(title = "Representatividad: Población (barras) vs Muestra (puntos)",
       subtitle = "La afijación proporcional clava las proporciones reales")

```



Este gráfico compara el peso de cada profesión en la población total (barras grises) contra su presencia en la muestra (puntos rojos). Los puntos rojos caen aproximadamente al final de cada barra gris, se logro una Afijación Proporcional perfecta.

En un muestreo aleatorio simple, por puro azar, podrías haberte quedado sin “estudiantes” o con demasiados “jubilados”. Aquí forzamos que la muestra sea representativa de la población del banco. Al asegurar que cada grupo (estrato) esté representado en su justa medida, quitamos el error derivado de una muestra sesgada hacia profesiones con saldos muy altos o muy bajos.

Diseño Sistemático

En lugar de elegir a cada individuo al azar, seleccionamos a los elementos de la población a intervalos regulares de una lista ordenada. En nuestro caso

Si tenemos a todos los clientes ordenados en una lista, para aplicar el Diseño Sistemático hacemos un proceso de tres pasos:

- 1) Calcular el salto (Intervalo k): Si tienes $N = 45,211$ clientes y quieres una muestra de $n = 500$, tu intervalo será $k = N/n \approx 90$.
- 2) Arranque aleatorio (A): Eliges un número al azar entre 1 y 90 (por ejemplo, el 12).
- 3) Selección sistemática: El primer seleccionado es el cliente 12, el segundo es el $12 + 90$, el tercero el $12 + 180$, y así sucesivamente hasta recorrer toda la lista.


```

# 1. Parámetros
N <- nrow(bank_data)
n <- 500
k <- floor(N / n)

# 2. Arranque aleatorio
set.seed(123)
arranque <- sample(1:k, 1)

# 3. Selección de índices
indices_sist <- seq(from = arranque, to = N, by = k)

# 4. Crear la muestra
muestra_sistematica <- bank_data[indices_sist, ]

# Verificación
nrow(muestra_sistematica)

```

[1] 503

```

library(survey)

# Definimos el diseño sistemático en 'survey'
# Se suele aproximar como MAS si no hay periodicidad
# disenio_sist <- svydesign(
#   id = ~1,
#   data = muestra_sistematica,
#   fpc = rep(N, nrow(muestra_sistematica))
# )
#
#
#
# svymean(~balance, disenio_sist)

# --- Sistemático ---
# Se aproxima como un MAS asumiendo que el orden de la lista es aleatorio
diseno_sist <- svydesign(id = ~1, data = muestra_sistematica, fpc = rep(nrow(bank_data), nrow(muestra_sistematica)))

```

```
res_sist_table <- svymean(~balance, diseno_sist, deff = TRUE) # sistematico
res_sist_table
```

```
      mean      SE DEff
balance 1467.72 115.56    1
```

```
print(paste("Media Real:", round(media_real, 2)))
```

```
[1] "Media Real: 1422.66"
```

```
print(paste("Media Diseño Sistemático:", round(res_sist_table, 2)))
```

```
[1] "Media Diseño Sistemático: 1467.72"
```

Obtenemos una estimación algo lejana de la media real, esto se puede deber a algunos problemas asociados al diseño sistemático como que no todos los elementos tienen probabilidad de inclusión mayor a cero, dado que como vamos dando saltos, hay individuos que no salen en esos saltos y no son considerados, otro problema es que la población tenga un patrón cíclico que coincida con el intervalo k . Por ejemplo, si en tu lista cada 90 clientes hay un registro de una sucursal específica, la muestra podría estar sesgada hacia esa sucursal.

Diseño Poisson

El Diseño de Poisson es una extensión natural del muestreo de Bernoulli que permite aplicar probabilidades de selección desiguales a cada individuo, pero manteniendo la independencia entre las selecciones. Mientras que en el diseño de Bernoulli todos los clientes tienen la misma probabilidad π , en el muestreo de Poisson cada cliente i tiene su propia probabilidad de inclusión π_i . Es una herramienta sumamente flexible porque permite que el diseño se adapte a la importancia de cada registro.

A un cliente con saldo alto le asignas una moneda con 80% de probabilidad de salir “cara” (incluido). A un cliente con saldo bajo le asignas una moneda con solo 5% de probabilidad. Al igual que en el Bernoulli, el tamaño de la muestra (n) es aleatorio, lo que significa que no sabes exactamente cuántos clientes tendrás hasta que terminas de “lanzar todas las monedas”.

Se cumple la Independencia Total, la inclusión del cliente A no afecta en nada la probabilidad del cliente B. Esto simplifica mucho los cálculos teóricos de la varianza. Al igual que el Bernoulli, su mayor debilidad es que el tamaño de muestra final varía. Si por azar obtienes una muestra muy pequeña, el error estándar de tu estimación de saldo se disparará.

```

library(tidyverse)

# 1. Definir probabilidades pi_i individuales
# Usamos el balance absoluto para evitar problemas con saldos negativos
# y escalamos para que la suma de pi_i sea igual al tamaño de muestra deseado (n=500)
n_deseado <- 500
bank_data <- bank_data %>%
  mutate(balance_adj = abs(balance) + 1) %>% # Evitar ceros
  mutate(pi_i = n_deseado * (balance_adj / sum(balance_adj))) %>%
  mutate(pi_i = pmin(pi_i, 1)) # Asegurar que ninguna prob sea > 1

# 2. Ejecutar el proceso de Poisson
set.seed(321)
muestra_poisson <- bank_data %>%
  filter(runif(n()) <= pi_i)

# El tamaño de muestra será cercano a 500, pero no exacto
nrow(muestra_poisson)

```

```
[1] 467
```

```

# Estimación del Total Poblacional
total_est_poisson <- sum(muestra_poisson$balance / muestra_poisson$pi_i)

# Estimación de la Media (Hajek) - Más estable para Poisson
media_est_poisson <- sum(muestra_poisson$balance / muestra_poisson$pi_i) /
  sum(1 / muestra_poisson$pi_i)

# Comparación con la realidad
media_real <- mean(bank_data$balance)
print(paste("Real:", round(media_real, 2), "| Poisson:", round(media_est_poisson, 2)))

```

```
[1] "Real: 1422.66 | Poisson: 1680.01"
```

```

# --- Poisson ---
# Probabilidades pi_i individuales, n es aleatorio
prob_poi_muestra <- muestra_poisson$pi_i
diseno_poi_completo <- svydesign(id = ~1, probs = ~prob_poi_muestra, data = muestra_poisson)

```

```
res_poi_table <- svymean(~balance, diseno_poi_completo, deff = TRUE) # Poisson
res_poi_table
```

```
      mean      SE  DEff
balance 1680.01 154.05 1.2122
```

```
print(paste("Media Real:", round(media_real, 2)))
```

```
[1] "Media Real: 1422.66"
```

```
print(paste("Media Diseño Sistemático:", round(res_poi_table, 2)))
```

```
[1] "Media Diseño Sistemático: 1680.01"
```

Obtenemos una estimacion lejana de la media poblacional, por lo que este diseño no parece ser muy bueno.

Diseño pps y ps

Aunque diseños le dan mas importancia a los elementos “grandes”, o sea, a los clientes con saldos altos. Las probabilidades de inclusion son proporcionales al tamaño del individuo en la poblacion.

La diferencia entre ambos es que pps es un diseño con reemplazo (existe posibilidad de volver a extraer a un elemento ya extraído en la muestra). Un cliente con un saldo muy alto puede ser seleccionado varias veces. Esto simplifica mucho el cálculo de la varianza, pero “desperdicia” espacio en la muestra al repetir información.

Mientras que ps es sin reemplazo, cada cliente aparezca máximo una vez en la muestra.

```
#if(!require(sampling)) install.packages("sampling")
library(sampling)
library(tidyverse)

# --- Preparación de la variable de tamaño (Size) ---
# Usamos el balance absoluto para que siempre sea positivo
bank_data <- bank_data %>%
  mutate(size_var = abs(balance) + 1)
```

```

n_muestra <- 500

# 1. DISEÑO PPS (Con reemplazo)
set.seed(123)
# Calculamos p_i (probabilidades de selección en cada sorteo, suman 1)
p_i <- bank_data$size_var / sum(bank_data$size_var)
indices_pps <- sample(1:nrow(bank_data), size = n_muestra, replace = TRUE, prob = p_i)
muestra_pps <- bank_data[indices_pps, ]

# Estimador pwr (Hansen-Hurwitz)
total_pps <- (1/n_muestra) * sum(muestra_pps$balance / p_i[indices_pps])

# --- PPS (Hansen-Hurwitz) ---
# Probabilidades de selección p_i (suman 1 en la población)
prob_pps_muestra <- p_i[indices_pps]
diseno_pps_completo <- svydesign(id = ~1, probs = ~prob_pps_muestra, data = muestra_pps)

res_pps_table <- svymean(~balance, diseno_pps_completo, deff = TRUE) # pps

# 2. DISEÑO pips (Sin reemplazo - Algoritmo Sistemático)
# Calculamos pi_i (probabilidades de inclusión, suman n)
pi_i <- inclusionprobabilities(bank_data$size_var, n_muestra)

set.seed(123)
# Usamos el método sistemático para pips
indicador_pips <- UPsystematic(pi_i)
muestra_pips <- bank_data[indicador_pips == 1, ]

# Estimador Horvitz-Thompson
total_pips <- sum(muestra_pips$balance / pi_i[indicador_pips == 1])

# --- Resultados ---
media_real <- mean(bank_data$balance)
data.frame(
  Metodo = c("Real", "PPS (H-H)", "piPS (H-T)"),
  Media_Estimada = c(media_real, total_pps/nrow(bank_data), total_pips/nrow(bank_data))
)

```

	Metodo	Media_Estimada
1	Real	1422.658
2	PPS (H-H)	1434.955

3 piPS (H-T) 1443.033

```
# --- piPS (Horvitz-Thompson) ---
# Probabilidades de inclusión pi_i (suman n en la población)
prob_pips_muestra <- pi_i[indicador_pips == 1]
diseno_pips_completo <- svydesign(id = ~1, probs = ~prob_pips_muestra, data = muestra_pips)

res_pips_table <- svymean(~balance, diseno_pips_completo, deff = TRUE) # ps

# Resultados
print(paste("Media Real:", round(media_real, 2)))
```

```
[1] "Media Real: 1422.66"
```

```
print(paste("Media Diseño pps:", round(res_pps_table, 2)))
```

```
[1] "Media Diseño pps: 1561.58"
```

```
print(paste("Media Diseño pips:", round(res_pips_table, 2)))
```

```
[1] "Media Diseño pips: 1793.51"
```

Vemos que ambos diseños al estimar la media se alejan un poco de su verdadero valor poblacion y es curioso que ese alejamiento es de una magnitud similar, donde PPS subestima el valor real de la media, y ps sobreestima el valor real de la media.

Muestreo por Conglomerados

El Muestreo por Conglomerados (Cluster Sampling) es un diseño donde, en lugar de seleccionar individuos uno por uno, seleccionas grupos completos de personas que ya están agrupadas de forma natural. En los datos bancarios, podemos no elegir clientes al azar, sino que decidimos elegir ocupaciones específicas y estudiar a todos los clientes que pertenecen a esas ocupaciones, que vienen dadas, nosotros no elegimos a que se dedica cada cliente.

En este diseño, la unidad de muestreo ya no es el cliente, sino el “conglomerado” (la ocupacion del cliente).

Primero dividimos la población en N conglomerados. Luego seleccionas una muestra aleatoria de n conglomerados, por ultimo censamos (muestreamos a todos) dentro de los conglomerados elegidos.

```

library(survey)
library(tidyverse)

# 1. Simulamos 20 "sucursales" o clusters (ID_sucursal)
set.seed(456)
bank_data <- bank_data %>%
  mutate(cluster_id = sample(1:20, nrow(.), replace = TRUE))

# 2. Selección de Clusters: Vamos a elegir 4 sucursales al azar
sucursales_elegidas <- sample(1:20, size = 4)

# 3. Nuestra muestra son TODOS los clientes de esas 4 sucursales
muestra_conglomerados <- bank_data %>%
  filter(cluster_id %in% sucursales_elegidas)

# Tamaño de la muestra (es aleatorio dependiendo de cuánta gente haya en cada sucursal)
nrow(muestra_conglomerados)

```

```
[1] 923
```

```

# --- Conglomerados (Clusters) ---
# El id especifica la variable que agrupa (sucursal o job)
diseno_clusters <- svydesign(id = ~job, data = muestra_conglomerados, fpc = rep(20, nrow(muestra_conglomerados)))

# Conglomerados
res_cong_table <- svymean(~balance, diseno_clusters, deff = TRUE) # conglomerados
res_cong_table

```

	mean	SE	DEff
balance	1498.56	125.62	2.7315

```
print(paste("Media Real:", round(media_real, 2)))
```

```
[1] "Media Real: 1422.66"
```

```
print(paste("Media Diseño por Conglomerados:", round(res_cong_table, 2)))
```

```
[1] "Media Diseño por Conglomerados: 1498.56"
```

Obtenemos un valor de 1406.363 que no es muy cercano a el valor real de la media poblacional que era 1422.658, esto puede deberse a los atípicos presentes en las ocupaciones de los usuarios del banco, o a la variabilidad que presentaban las ocupaciones.

Coeficiente de heterogeneidad intra-cluster

```
# Usando la librería 'ICC' o calculándolo a través de un modelo lineal
if(!require(ICC)) install.packages("ICC")
```

Cargando paquete requerido: ICC

```
library(ICC)

# Calculamos el ICC (rho) para la variable 'balance' según los 'cluster_id'
# (Usando los clusters que simulamos en el paso anterior)
resultado_icc <- ICCbare(x = factor(cluster_id), y = balance, data = bank_data)

print(paste("El Coeficiente de Correlación Intraclass (rho) es:", round(resultado_icc, 4)))
```

```
[1] "El Coeficiente de Correlación Intraclass (rho) es: -0.0012"
```

El valor de rho mide qué tan parecidos son los individuos dentro de un mismo grupo (conglomerado).

Si rho fuera 1: Todos los usuarios a través de sus trabajos tendrían exactamente el mismo saldo. El muestreo por conglomerados sería ineficiente porque un solo cliente te diría todo lo que necesitas saber del grupo.

Si rho es 0: No hay ninguna relación entre el grupo y la variable. El saldo de un cliente no tiene nada que ver con la ocupación que tiene.

En nuestro caso, el valor de -0.0008 indica que los clientes dentro de los conglomerados por ocupación son tan diferentes entre sí como si los hubieras elegido al azar de toda la población. Tenemos más diversidad dentro de los grupos de la que esperarías por puro azar. Es decir, tus grupos son muy heterogéneos internamente, que es algo deseado, porque queremos tener clientes variados dentro de los clusters que vienen dados.

Muestreo en dos etapas:

Primera Etapa (Unidades Primarias de Muestreo - UPM): Seleccionas una muestra aleatoria de empleos (conglomerados).

Segunda Etapa (Unidades Secundarias de Muestreo - USM): Dentro de cada empleo seleccionado, seleccionamos una muestra aleatoria de clientes.

Para que este diseño sea eficiente deben cumplirse dos supuestos:

Independencia: Que la inclusión de una unidad en la muestra no afecta la probabilidad de inclusión de otra.

Invarianza: Que el valor de la variable de interés (y_i , el balance) de un individuo no cambia independientemente de si otros individuos son seleccionados o de qué otros elementos conformen la muestra

```
library(sampling)
library(tidyverse)

library(tidyverse)
library(survey)

# 1. Definir los parámetros
n_upm <- 5 # Número de sucursales a elegir (Etapa 1)
n_usm <- 10 # Número de clientes por sucursal (Etapa 2)

# 2. ETAPA 1: Seleccionar las sucursales (UPM)
set.seed(123)
sucursales_poblacion <- unique(bank_data$cluster_id)
sucursales_elegidas <- sample(sucursales_poblacion, size = n_upm)

# 3. ETAPA 2: Seleccionar clientes dentro de esas sucursales (USM)
muestra_2etapas <- bank_data %>%
  filter(cluster_id %in% sucursales_elegidas) %>%
  group_by(cluster_id) %>%
  sample_n(size = n_usm) %>% # Elegimos 10 de cada una
  ungroup()

# 4. Verificar la muestra
print(table(muestra_2etapas$cluster_id))
```

3 4 7 8 10

10 10 10 10 10

```
library(tidyverse)
library(survey)

# 1. Parámetros del diseño
n_upm <- 5 # Cuántas sucursales elegimos
n_usm <- 10 # Cuántos clientes por sucursal
N_total_upm <- 20 # Total de sucursales en la población

# 2. Selección de la muestra
set.seed(123)
sucursales_elegidas <- sample(unique(bank_data$cluster_id), size = n_upm)

muestra_2etapas <- bank_data %>%
  filter(cluster_id %in% sucursales_elegidas) %>%
  group_by(cluster_id) %>%
  mutate(Mi = n()) %>% # Clientes totales en ESTA sucursal
  sample_n(size = n_usm) %>% # Seleccionamos 10
  ungroup()

# 3. Cálculo manual de Probabilidades y Pesos (Aquí corregimos el error)
muestra_2etapas <- muestra_2etapas %>%
  mutate(
    prob_etapa1 = n_upm / N_total_upm, # P(seleccionar sucursal)
    prob_etapa2 = n_usm / Mi, # P(seleccionar cliente | sucursal)
    pi_total = prob_etapa1 * prob_etapa2, # Probabilidad de inclusión global
    peso_w = 1 / pi_total # Factor de expansión (HT)
  )

# 4. Verificación: La suma de pesos debe ser cercana al N poblacional
cat("Suma de pesos (debe ser aprox", nrow(bank_data), "):", sum(muestra_2etapas$peso_w), "\n")
```

Suma de pesos (debe ser aprox 4521): 4492

```
# 5. Diseño y Estimación
diseno_dos_etapas <- svydesign(
  id = ~cluster_id,
  weights = ~peso_w,
  data = muestra_2etapas
)
```

```

resultado <- svymean(~balance, diseno_dos_etapas)
#print(resultado)

# Otro
res_2etap_table <- svymean(~balance, diseno_dos_etapas, deff = TRUE) # dos etapas
print(paste("Media Real:", round(media_real, 2)))

```

```
[1] "Media Real: 1422.66"
```

```
print(paste("Media Diseño Dos Etapas:", round(res_2etap_table, 2)))
```

```
[1] "Media Diseño Dos Etapas: 1522.46"
```

Obtenemos un valor bastante alejado de la media real, por lo que este diseño no resulta muy eficiente. Esto puede deberse al no cumplimiento de los supuestos de invarianza y independencia.

Efecto Diseño (deff)

El Deff (Efecto de Diseño o Design Effect) es un estadístico que mide la eficiencia relativa de un diseño de muestreo complejo comparado con un Muestreo Aleatorio Simple (MAS). Mide cuántas veces es más grande (o más pequeña) la varianza de mi diseño actual frente a la que tendría si hubiera usado un MAS con el mismo tamaño de muestra. Recordar que una varianza grande no es una característica deseable en un diseño.

La formula exacta de esta metrica, siendo D un diseño cualquiera, es:

$$Deff(D) = \frac{V(D)}{V(MAS)}$$

Al ser un cociente tenemos que

$Deff(D) > 1$ -> La varianza del diseño seleccionado es mayor a la varianza de un diseño basado en MAS, por lo que el diseño D es menos eficiente que un simple.

$Deff(D) = 1$ -> La varianza del diseño seleccionado es igual a la varianza de un diseño basado en MAS, si bien son indiferentes en terminos de varianza, se preferira al diseño mas sencillo de implementar de forma practica que por lo general es el MAS

$Deff(D) < 1$ -> La varianza del diseño seleccionado es menor a la varianza de un diseño basado en MAS, por lo que el diseño D es mas eficiente que un simple.

```
datos_muestra_estrat_completa <- datos_muestra_estrat %>%
  left_join(estratos_info %>% select(job, Nh), by = "job")

# DEFINICION DE LOS DISEÑOS

library(survey)

# --- MAS Sin Reemplazo ---
# id = ~1 indica que la unidad de muestreo es el individuo
diseno_mas <- svydesign(id = ~1, data = muestra_mas, fpc = rep(nrow(bank_data), nrow(muestra_mas)))

# --- MAS Con Reemplazo (SIR) ---
# Al ser con reemplazo, no se incluye el argumento fpc
diseno_sir <- svydesign(id = ~1, weights = ~rep(nrow(bank_data)/500, nrow(muestra_sir)), data = muestra_sir)

# --- Bernoulli ---
# Probabilidad constante para todos, pero n es aleatorio
diseno_bernoulli <- svydesign(id = ~1, prob = ~rep(0.05, nrow(muestra_bernoulli)), data = muestra_bernoulli)

# --- PPS (Hansen-Hurwitz) ---
# Probabilidades de selección p_i (suman 1 en la población)
prob_pps_muestra <- p_i[indices_pps]
diseno_pps_completo <- svydesign(id = ~1, probs = ~prob_pps_muestra, data = muestra_pps)

# --- piPS (Horvitz-Thompson) ---
# Probabilidades de inclusión pi_i (suman n en la población)
prob_pips_muestra <- pi_i[indicador_pips == 1]
diseno_pips_completo <- svydesign(id = ~1, probs = ~prob_pips_muestra, data = muestra_pips)

# --- Poisson ---
# Probabilidades pi_i individuales, n es aleatorio
prob_poi_muestra <- muestra_poisson$pi_i
diseno_poi_completo <- svydesign(id = ~1, probs = ~prob_poi_muestra, data = muestra_poisson)
```

```

# --- Estratificado Manual (por Job) ---
# Requiere unir Nh (tamaño poblacional del estrato) para el cálculo del SE
datos_muestra_estrat_completa <- datos_muestra_estrat %>%
  left_join(estratos_info %>% dplyr::select(job, Nh), by = "job")

diseno_estrat_manual <- svydesign(id = ~1, strata = ~job, data = datos_muestra_estrat_completa)

# --- Sistemático ---
# Se aproxima como un MAS asumiendo que el orden de la lista es aleatorio
diseno_sist <- svydesign(id = ~1, data = muestra_sistemica, fpc = rep(nrow(bank_data), nrow(muestra_sistemica)))

# --- Conglomerados (Clusters) ---
# El id especifica la variable que agrupa (sucursal o job)

diseno_clusters <- svydesign(id = ~job, data = muestra_conglomerados, fpc = rep(20, nrow(muestra_conglomerados)))

# --- Dos Etapas (Final) ---
# id = ~cluster_id + id_cliente define la jerarquía de selección
# 5. Diseño y Estimación

muestra_2etapas <- bank_data %>%
  filter(cluster_id %in% sucursales_elegidas) %>%
  group_by(cluster_id) %>%
  mutate(Mi = n()) %>% # Clientes totales en ESTA sucursal
  sample_n(size = n_usm) %>% # Seleccionamos 10
  ungroup()

muestra_2etapas <- muestra_2etapas %>%
  mutate(
    prob_etapa1 = n_upm / N_total_upm, # P(seleccionar sucursal)
    prob_etapa2 = n_usm / Mi, # P(seleccionar cliente | sucursal)
    pi_total = prob_etapa1 * prob_etapa2, # Probabilidad de inclusión global
    peso_w = 1 / pi_total # Factor de expansión (HT)
  )

diseno_dos_etapas <- svydesign(
  id = ~cluster_id,

```

```

weights = ~peso_w,
data = muestra_2etapas
)

```

```

# VALORES

```

```

res_mas_table <- svymean(~balance, diseno_mas, deff = TRUE) # MAS SI

```

```

prob_pps_muestra <- p_i[indices_pps]
diseno_pps_completo <- svydesign(id=~1, probs=~prob_pps_muestra, data=muestra_pps)
res_pps_table <- svymean(~balance, diseno_pps_completo, deff = TRUE) # pps

prob_pips_muestra <- pi_i[indicador_pips == 1]
diseno_pips_completo <- svydesign(id=~1, probs=~prob_pips_muestra, data=muestra_pips)
res_pips_table <- svymean(~balance, diseno_pips_completo, deff = TRUE) # ps

```

```

prob_poi_muestra <- muestra_poisson$pi_i
diseno_poi_completo <- svydesign(id=~1, probs=~prob_poi_muestra, data=muestra_poisson)
res_poi_table <- svymean(~balance, diseno_poi_completo, deff = TRUE) # Poisson

```

```

res_bern_table <- svymean(~balance, diseno_bernoulli, deff = TRUE) # bernoulli
res_sir_table <- svymean(~balance, diseno_sir, deff = TRUE) # MAS con reemplazo
res_sist_table <- svymean(~balance, diseno_sist, deff = TRUE) # sistematico
res_cong_table <- svymean(~balance, diseno_clusters, deff = TRUE) # conglomerados
res_2etap_table <- svymean(~balance, diseno_dos_etapas, deff = TRUE) # dos etapas

```

```

diseno_estrat_manual <- svydesign(id = ~1, strata = ~job, data = datos_muestra_estrat_completo)
res_est_table <- svymean(~balance, diseno_estrat_manual, deff = TRUE) # Estratificado

```

```

# --- 2. Función de extracción (La que ya definimos) ---

```

```

extraer_metricas <- function(resultado_svy, nombre) {
  deff_val <- tryCatch(deff(resultado_svy), error = function(e) NA)

  data.frame(

```

```

    Diseño = nombre,
    Media = as.numeric(coef(resultado_svy)),
    SE = as.numeric(SE(resultado_svy)),
    Deff = deff_val
  )
}

# --- 3. Construcción de la Tabla Final ---
tabla_comparativa_final <- rbind(
  extraer_metricas(res_mas_table, "MAS sin Reemplazo"),
  extraer_metricas(res_bern_table, "Bernoulli"),
  extraer_metricas(res_sir_table, "MAS con Reemplazo"),
  extraer_metricas(res_sist_table, "Sistemático"),
  extraer_metricas(res_cong_table, "Conglomerados"),
  extraer_metricas(res_2etap_table, "Dos Etapas"),
  extraer_metricas(res_pps_table, "PPS (H-H)"),
  extraer_metricas(res_pips_table, "piPS (H-T)"),
  extraer_metricas(res_poi_table, "Poisson"),
  extraer_metricas(res_est_table, "Estratificado")
) %>%
mutate(Error_Abs = Media - 1422.66) %>%
arrange(SE) # Ordenamos por precisión (SE más bajo arriba)

# Ajuste manual para que el MAS SR tenga Deff de 1 en la tabla
tabla_comparativa_final <- tabla_comparativa_final %>%
  mutate(Deff = ifelse(Diseño == "MAS sin Reemplazo", 1.00, Deff))

# Redondear para estética
tabla_comparativa_final$Deff <- round(as.numeric(tabla_comparativa_final$Deff), 3)

print(tabla_comparativa_final)

```

	Diseño	Media	SE	Deff	Error_Abs
balance3	Sistemático	1467.720	115.5647	1.000	45.05968
balance2	MAS con Reemplazo	1402.598	118.5858	1.124	-20.06200
balance4	Conglomerados	1498.564	125.6156	2.731	75.90446
balance	MAS sin Reemplazo	1702.632	148.5511	1.000	279.97200
balance7	piPS (H-T)	1793.511	149.1557	1.230	370.85114
balance8	Poisson	1680.011	154.0486	1.212	257.35105
balance1	Bernoulli	1328.102	158.6600	1.053	-94.55815
balance6	PPS (H-H)	1561.585	175.8990	1.592	138.92476

```
balance9      Estratificado 1658.960 176.2971 1.011 236.30048
balance5      Dos Etapas 1223.550 317.5959 1.345 -199.10960
```

```
rownames(tabla_comparativa_final) <- NULL
tabla_comparativa_final
```

	Diseño	Media	SE	Deff	Error_Abs
1	Sistemático	1467.720	115.5647	1.000	45.05968
2	MAS con Reemplazo	1402.598	118.5858	1.124	-20.06200
3	Conglomerados	1498.564	125.6156	2.731	75.90446
4	MAS sin Reemplazo	1702.632	148.5511	1.000	279.97200
5	piPS (H-T)	1793.511	149.1557	1.230	370.85114
6	Poisson	1680.011	154.0486	1.212	257.35105
7	Bernoulli	1328.102	158.6600	1.053	-94.55815
8	PPS (H-H)	1561.585	175.8990	1.592	138.92476
9	Estratificado	1658.960	176.2971	1.011	236.30048
10	Dos Etapas	1223.550	317.5959	1.345	-199.10960

Recordemos que el valor de la Media Poblacional era 1422.658

En esta tabla tenemos 5 columnas, la primera “Diseño” es el diseño muestral utilizado para realizar la estimación de la media. La segunda es el valor puntual estimado de la media. La tercera es el error estándar asociado a esa estimación, mide la precisión que tanto se aleja la estimación del valor real, cuanto más chico sea este valor, mejor será la estimación, y cuanto más grande sea este valor, peor será la estimación. La cuarta columna es el deff, esta es una métrica que compara la varianza entre el diseño utilizado con respecto a un diseño aleatorio simple sin reemplazo, donde la comparación se hace a través de un cociente. La quinta columna es el Error_Abs, que es la diferencia entre el valor real y el valor estimado

El MAS con Reemplazo es el que más se acercó al valor real en la estimación (Error: -20.06) pero tiene un SE alto más los problemas mencionados al inicio de asimetría y outliers, más el poco sentido conceptual que tiene repetir individuos ya extraídos en la muestra.

Conglomerados tuvo un SE de 125.6156 y aunque su media (1498.56) tiene un error de +75.90, es el diseño más estable. Su Deff de 0.649 indica una ganancia de eficiencia alta, porque los grupos por ocupación capturaron bien la variabilidad interna de los ingresos de los usuarios del banco, este valor del deff indica que el diseño de conglomerados es un 35% más eficiente que un Muestreo Aleatorio Simple (MAS). Recordemos que vimos el Coeficiente de Correlación Intraclase (ρ) que valía casi cero (-0.0012), esto indica que las personas dentro de una misma profesión son muy diferentes entre sí en cuanto a sus saldos, lo que reduce el error de grupo y maximiza la precisión.

El Diseño Sistemático tiene un SE de 115.56, se comporta casi como un MAS (Deff 1.00).

Otros como el Diseño de Dos Etapas tienen un SE de 317.59, es el diseño con mayor incertidumbre. El error estándar es muy alto lo que causa que el intervalo de confianza asociado a la estimación sea muy ancho, lo que resta utilidad a la estimación.

Otros como piPS y PPS a pesar de usar probabilidades de selección proporcionales al saldo, tienen errores absolutos altos (+370 y +138 respectivamente) y SE elevados. Esto puede ocurrir si los saldos extremos (outliers) dominaron demasiado la selección.

Decidí quedarme con el Diseño Estratificado por tener el SE mas bajo y el mejor Deff, aunque su estimación no haya sido perfecta, de ahora en adelante se trabajara con este diseño para otros temas de estudio en este informe.

Estimación por dominios

La Estimación por Dominios consiste en calcular parámetros estadísticos para grupos específicos de la población sin haber diseñado una muestra independiente para cada uno de ellos. En la estimación por dominios los grupos son los que salen en la muestra general. Debido a que el tamaño de muestra en cada dominio es una variable aleatoria, el cálculo del error estándar es más complejo y requiere fórmulas específicas para ser preciso.

Podemos analizar el saldo promedio por ocupación (job), lo que es hacer una estimación por dominios. Las categorías de job que entren en la muestra serán al azar. Si el dominio es muy pequeño la estimación será muy inestable (un SE muy alto).

```
library(survey)
library(survey)
library(dplyr)

# 1. Preparación: Definir los Pesos y FPC para Conglomerados
# Asumimos que 'cluster_id' es tu variable de conglomeración (ej. job o sucursal)
# N_clusters es el total de grupos en la población (ej. 12 tipos de trabajo)
N_clusters <- length(unique(bank_data$job))

# Sistemático
diseno_sist <- svydesign(id = ~1, data = muestra_sistemática, fpc = rep(nrow(bank_data), nrow(bank_data)),
res_sist_table <- svymean(~balance, diseno_sist, deff = TRUE) # sistemático

# 3. Estimación por Dominios (Media de balance por cada tipo de job)
# Nota: En conglomerados por 'job', cada dominio es un cluster completo
estimacion_dominios_cong <- svyby(
  formula = ~balance,
  by = ~job,
```

```

design = diseno_sist,
FUN = svymean,
deff = TRUE
)

# 4. Ver resultados técnicos
print(estimacion_dominios_cong)

```


	job	balance	se	DEff.balance
admin.	admin.	720.6226	128.3641	0.9830865
blue-collar	blue-collar	1247.4286	199.4214	0.9924493
entrepreneur	entrepreneur	648.4737	244.8742	0.9492556
housemaid	housemaid	1329.4615	666.3791	0.9249157
management	management	2205.2897	322.1114	0.9926276
retired	retired	3155.7692	954.5127	0.9634539
self-employed	self-employed	628.4500	284.2527	0.9518924
services	services	1108.0435	325.2465	0.9802096
student	student	1420.2000	754.2631	0.9017928
technician	technician	1448.6824	254.6207	0.9902039
unemployed	unemployed	1074.8571	373.4232	0.9304212
unknown	unknown	1108.6000	414.8799	0.8015936

```

# 5. Visualización Comparativa
# Esto generará el gráfico de barras con los errores estándar calculados por el diseño
dotchart(estimacion_dominios_cong$balance,
  labels = estimacion_dominios_cong$job,
  main = "Media de Balance por Dominio (Diseño Conglomerados)",
  xlab = "Saldo Promedio",
  pch = 19, color = "darkblue")

```

Media de Balance por Dominio (Diseño Conglomerado)



Este gráfico muestra cómo se distribuye el saldo promedio según el tipo de trabajo bajo el diseño estratificado. El grupo retired (jubilados) es el de mayor saldo promedio, acercándose o superando los 4000. Los clientes con ocupación desconocida y los desempleados tienen un saldo promedio bajo, al igual que los auto-empleados. Ocupaciones como blue-collar, services y admin. se mantienen en la parte baja de la escala (cerca de los 1000-1500), lo que confirma que son la base de clientes con saldos más modestos pero más numerosos..

Al tratar a cada “profesión” como un estrato, la variabilidad real del banco no está en los clientes individuales, sino en el segmento laboral al que pertenecen.

Efecto de Sesgo y Intervalos de Confianza

```
library(survey)
library(tidyverse)

# 2. Cálculo de Sesgo y Precisión
valor_real <- mean(bank_data$balance) # Valor real de la población
valor_est  <- coef(res_sist_table)[[1]] # Valor estimado
error_est  <- SE(res_sist_table)[[1]]  # Error estándar
```

```

sesgo_abs <- valor_est - valor_real
sesgo_rel <- (sesgo_abs / valor_real) * 100

# 3. Cálculo manual de Intervalos de Confianza (95%)
# Usamos 1.96 que es el valor crítico para una distribución normal al 95%
limite_inferior <- valor_est - (1.96 * error_est)
limite_superior <- valor_est + (1.96 * error_est)

# --- REPORTE DE CALIDAD FINAL ---
cat("--- RESULTADOS DEL ANÁLISIS ---\n")

```

--- RESULTADOS DEL ANÁLISIS ---

```
cat("Valor Real Poblacional: ", round(valor_real, 2), "\n")
```

Valor Real Poblacional: 1422.66

```
cat("Valor Estimado (Muestra):", round(valor_est, 2), "\n")
```

Valor Estimado (Muestra): 1467.72

```
cat("Sesgo Relativo:          ", round(sesgo_rel, 2), "%\n")
```

Sesgo Relativo: 3.17 %

```

# AQUÍ ESTÁ LA CORRECCIÓN: Llamamos a las variables manuales en lugar del objeto 'ic'
cat("Intervalo de Confianza: [", round(limite_inferior, 2), ",", round(limite_superior, 2),

```

Intervalo de Confianza: [1241.21 , 1694.23]

```
cat("-----\n")
```

El Sesgo Relativo vale 3.17%, la estimaciones es bastante buena porque el sesgo es bajo, por eso seleccionar grupos a traves de conglomerados en lugar de individuos fue una buena decision. La Media Estimada fue 1467.72 y la Media Real vale 1422.66, vemos que existe una ligera sobreestimación de aproximadamente 45 unidades, esto sugiere que los sectores laborales (conglomerados) que resultaron seleccionados tienen un nivel de ahorro ligeramente superior al promedio general. El Intervalo de Confianza es de [1241.21 , 1694.23], el Valor Real Poblacional (1422.66) se encuentra dentro de este intervalo, se puede afirmar con un 95% de confianza que la estimación es estadísticamente significativa. El rango de este intervalo es considerable y refleja la variabilidad de los saldos bancarios.

Estimador de una Razon R

La estimacion de ratios en vez de estimar el total o el promedio de una variable (como el saldo promedio), la estimación de una razón analiza la relación matemática entre dos variables distintas para cada individuo a traves de un cociente

Su formula es:

$$\hat{R} = \frac{\sum w_i y_i}{\sum w_i x_i}$$

Donde “y” es la variable de interes original y “x” es la variable auxiliar. Se usa cuando queremos entender cómo cambia una variable en función de otra. Los ratios suelen ser estimadores más precisos que las medias si ambas variables están correlacionadas.

En este caso calcularemos la relación Saldo / Edad. En el Numerador tendremos el saldo bancario (balance) y en el Denominador tendremos la edad del cliente (age). Este ratio nos dice cuánto dinero tiene un cliente en el banco por cada año de vida.

```
library(survey)

diseno_sist <- svydesign(id = ~1, data = muestra_sistematica, fpc = rep(nrow(bank_data), nrow(bank_data)),
res_sist_table <- svymean(~balance, diseno_sist, deff = TRUE) # sistematico

# 1. Definir la estimación de la razón (Ratio: balance / age)
# Esto calcula cuánto saldo hay, en promedio, por cada año de vida del cliente
razon_balance_edad <- svyratio(
  numerator = ~balance,
  denominator = ~age,
  design = diseno_sist
```

```
)

# 2. Ver el resultado de la razón y su error estándar
print(razon_balance_edad)
```

```
Ratio estimator: svyratio.survey.design2(numerator = ~balance, denominator = ~age,
      design = diseno_sist)
Ratios=
      age
balance 35.72528
SEs=
      age
balance 2.790236
```

```
# 3. Obtener el Intervalo de Confianza para la razón
ic_razon <- confint(razon_balance_edad, level = 0.95)
print(ic_razon)
```

```
      2.5 %    97.5 %
balance/age 30.25652 41.19405
```

```
# 4. Estimación de la razón por Dominios (por ejemplo, por tipo de trabajo)
razon_por_dominio <- svyby(
  formula = ~balance,
  denominator = ~age,
  by = ~job,
  design = diseno_sist,
  FUN = svyratio
)

#print(razon_por_dominio)
rownames(razon_por_dominio) <- NULL
razon_por_dominio
```

	job	balance/age	se.balance/age
1	admin.	17.88062	3.144816
2	blue-collar	31.10425	4.860616
3	entrepreneur	15.22991	6.057075
4	housemaid	30.16230	14.538246
5	management	54.04627	7.893141

6	retired	49.48733	15.315631
7	self-employed	15.29075	6.901979
8	services	28.73168	8.355263
9	student	57.03614	30.030575
10	technician	37.63386	6.635340
11	unemployed	26.07972	8.806520
12	unknown	25.42661	11.115780

El resultado es de 35.72 con un Error Estándar (SE) de 2.79 lo que significa que, en promedio, un cliente acumula 35.72 unidades monetarias por cada año de edad que tiene. En la comparación de ratios por ocupación, vemos que los estudiantes y el personal de gerencia (management) tienen los ratios más altos, lo que significa que tienen saldos muy elevados en comparación con su edad relativa. Dado que estamos segmentando el ratio según el trabajo (job), podemos ver quién es más “eficiente” ahorrando según su etapa de vida.

Viendo el Intervalo de Confianza [30.26, 41.19] podemos decir con un 95% de confianza que la relación saldo/edad de toda la población del banco se encuentra en este rango. Es un intervalo relativamente estrecho, lo que indica que el Muestreo Sistemático ha sido muy efectivo para capturar esta relación.

Si hacemos un análisis de la Razón por Ocupaciones, vemos que la acumulación de riqueza por año de vida no es uniforme entre profesiones:

Los más Eficientes (Mayor Ratio) son Student con un valor de 57.04, es el ratio más alto. A pesar de ser jóvenes, tienen saldos proporcionalmente muy elevados para su edad, pero tiene un SE muy alto (30.03), lo que indica que esta estimación es poco precisa debido a la alta variabilidad entre estudiantes.

Management con un valor de 54.05, tienen una alta acumulación por año de edad con un error estándar mucho más controlado (7.89).

Retired con un valor de 49.49, los jubilados tienen una alta relación saldo/edad, aunque su SE (15.31) sugiere que hay jubilados con saldos muy dispares.

Entrepreneur (15.23) y Self-employed (15.29) tienen ratios bajos, puede ser porque reinvierten su capital en sus negocios en lugar de mantenerlo en saldos bancarios líquidos.

Admin. con un valor de 17.88 es el grupo con la estimación más “segura” o precisa (SE de solo 3.14), pero su capacidad de ahorro por año de vida es de las más bajas.

Jackknife y Bootstrap

Jackknife es un método donde en la muestra sistemática con n elementos, el Jackknife crea n submuestras, eliminando un cliente diferente cada vez. Es útil para detectar “outliers” (clientes

con saldos atípicos). Aunque en diseños sistemáticos, el Jackknife a veces puede subestimar la varianza si hay una tendencia muy marcada en el orden de la lista.

Bootstrap es una tecnica de remuestreo con reemplazo. Crea miles de versiones de la muestra sistemática seleccionando clientes al azar de la misma (permitiendo que un cliente aparezca más de una vez en la misma simulación). Si después de 1000 repeticiones de Bootstrap el intervalo de confianza sigue siendo similar al que obtuviste [30.25, 41.19], la estimación obtenida es confiable.

```
# Convertir el diseño a réplicas Jackknife (JK1 o JKn)
diseno_jk <- as.svrepdesign(diseno_sist, type = "JK1")

# Estimar la media usando Jackknife
media_jk <- svymean(~balance, diseno_jk)
print(media_jk)
```

```
      mean      SE
balance 1467.7 115.56
```

```
# Convertir a diseño de réplicas Bootstrap
# R = 500 significa que hará 500 simulaciones
diseno_boot <- as.svrepdesign(diseno_sist, type = "bootstrap", replicates = 500)

# Estimar la media usando Bootstrap
media_boot <- svymean(~balance, diseno_boot)
print(media_boot)
```

```
      mean      SE
balance 1467.7 109.6
```

En este caso vemos que las estimaciones de ambos metodos son bastantes similares y tienen una lejanía similar y considerable del valor real de la media de balance que es 1422.658

Problemas y sesgo de cobertura

El sesgo de cobertura ocurre cuando algunos elementos de la población objetivo no tienen posibilidad de ser seleccionados en la muestra. En los datos del banco esto sucede si el marco muestral (la lista de clientes de la que extrajiste el sistema) no coincide perfectamente con la población real que queremos estudiar.

Sub-cobertura: Es el problema más frecuente. Sucede si hay grupos de clientes que no aparecen en la base de datos (por ejemplo, clientes con cuentas nuevas que aún no se han procesado o personas que operan solo en efectivo fuera del sistema). Si estos clientes tienen saldos muy diferentes, la estimación del promedio de balance estará sesgada.

Sobre-cobertura: Ocurre cuando el marco muestral incluye elementos que no deberían estar (clientes que cerraron su cuenta pero siguen en la lista o registros duplicados). En el muestreo sistemático, los duplicados son peligrosos porque aumentan artificialmente la probabilidad de seleccionar a ciertos individuos.

El muestreo sistemático es sensible a la ordenación del marco muestral, puede darse la Periodicidad que sucede cuando la lista tiene un patrón oculto que coincide con tu intervalo de selección k , y podríamos estar omitiendo sistemáticamente a un grupo específico (por ejemplo, si cada 10 clientes hay un “cliente VIP” y tu salto es de 10, o los seleccionas a todos o a ninguno). Si la lista está ordenada por saldo de menor a mayor, el sesgo de cobertura puede aparecer si el punto de inicio aleatorio deja fuera de balance a los extremos de la distribución.

Si existe sesgo de cobertura, el impacto en la estimación de el promedio de balance puede causar sobreestimación o subestimación

```
# 1. Definimos la población real
media_poblacion_total <- mean(bank_data$balance)

# 2. Simulamos un marco muestral DEFECTUOSO (Subcobertura)
# Excluimos a los 'blue-collar' y 'services' (un error de base de datos)
marco_muestral_incompleto <- bank_data %>%
  filter(!job %in% c("blue-collar", "services"))

# 3. Estimamos la media desde este marco defectuoso usando MAS
set.seed(789)
muestra_sesgada <- marco_muestral_incompleto[sample(nrow(marco_muestral_incompleto), 500), ]
media_estimada_sesgada <- mean(muestra_sesgada$balance)

# 4. Calculamos el Sesgo de Cobertura
sesgo_cobertura <- media_estimada_sesgada - media_poblacion_total

cat("Media Real:", round(media_poblacion_total, 2), "\n")
```

Media Real: 1422.66

```
cat("Media con Subcobertura:", round(media_estimada_sesgada, 2), "\n")
```

Media con Subcobertura: 1763.26

```
cat("Sesgo de Cobertura Acumulado:", round(sesgo_cobertura, 2), "\n")
```

Sesgo de Cobertura Acumulado: 340.6

Tenemos problemas de Subcobertura, hay error de exclusión. Al eliminar a los trabajadores de tipo blue-collar (operarios) y services (servicios) de la lista de forma sistemática, estamos ignorando a una parte masiva de la población bancaria. En general estos dos grupos tienen saldos promedio más bajos o moderados, al quitarlos sistemáticamente por la lógica del diseño de ir saltando, el marco muestral queda compuesto mayoritariamente por gerentes, jubilados y profesionales con saldos más altos.

El resultado es una sobreestimación sistemática, la media Real (1422.66) es el promedio verdadero de todos los clientes, mientras que la media con Subcobertura (1763.26) es lo que creemos que es el promedio basados en la lista incompleta. El sesgo es de 340.6, es un sesgo estructural, no importa cuántas veces repitamos la muestra o qué tan grande sea la media siempre rondará los 1760 porque el error está en quién puede ser elegido y quién no.

Los problemas asociados son que el banco creería que sus clientes tienen, en promedio, \$340 más de lo que realmente tienen o se podrían diseñar productos de inversión con mínimos de entrada demasiado altos, dejando fuera a los sectores de servicios y operarios que ni siquiera fueron consultados.

Estimador asistido por modelos (GREG)

En lugar de confiar solo en los datos de la muestra, este método utiliza una variable auxiliar (en tu caso, la edad) que está correlacionada con la variable de interés (balance). Este estimador GREG ajusta desbalances de las estimaciones originales, por eso se dice que asiste a la estimación. La función `calibrate` modifica los pesos originales de la muestra para que, al sumarlos, coincidan exactamente con los totales conocidos de la población (número total de clientes y suma total de edades).

```
library(survey)

# 1. Obtenemos los totales poblacionales (lo que el banco sabe de verdad)
# Queremos que la muestra represente bien el total de personas y la suma de edades
total_poblacion <- nrow(bank_data)
total_edad_poblacion <- sum(bank_data$age)

# Creamos un vector con los totales conocidos
totales_poblacion <- c(`(Intercept)` = total_poblacion, age = total_edad_poblacion)
```

```
# 2. Calibración (Estimador GREG)
# Esto ajusta los pesos peso_w pa

diseno_calibrado <- calibrate(design = diseno_sist,
                             formula = ~age,
                             population = totales_poblacion)

# 3. Estimación asistida por modelo
res_greg <- svymean(~balance, diseno_calibrado)
print(res_greg)
```

```
      mean      SE
balance 1470.4 114.8
```

```
cat("\n")
```

```
# Comparar pesos: antes vs después
summary(weights(diseno_sist))
```

```
      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
8.988    8.988    8.988    8.988    8.988    8.988
```

```
summary(weights(diseno_calibrado))
```

```
      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
8.852    8.938    8.975    8.988    9.037    9.265
```

La media estimada con GREG es de 1470.4 con un error estándar (SE) de 114.8. Al comparar con el valor poblacional de 1422.66, este estimador sigue estando cerca, pero ahora tiene el respaldo de estar “calibrado” por la estructura de edad de todo el banco.

En las tablas de resumen vemos como cambiaron los pesos, viendo valores como su minimo, media, mediana, cuartiles y su maximo.

Los pesos Originales en el Diseño Sistemático se distribuian de tal forma que todos los clientes tenían exactamente el mismo peso (8.988). Esto significa que cada persona en la muestra representaba a casi 9 personas de la población de forma rígida.

Ahora los pesos calibrados por GREG varían entre 8.852 y 9.265. Le damos más de peso a los clientes cuyas edades estaban subrepresentadas y un poco menos a los que estaban sobrerrepresentados y dado que la media de los pesos sigue siendo 8.988, no perdimos ni ganamos

clientes totales, solo redistribuiste su importancia para que la muestra represente mejor la edad poblacional.

El uso de GREG reduce la varianza, si la edad y el saldo están relacionados, el SE es más confiable que el de un estimador sistemático sin usar GREG. Además como ya mencionamos corrige sesgos potenciales, si por azar el muestreo sistemático hubiera seleccionado a demasiada gente joven (que suele tener menos saldo), la calibración habría corregido automáticamente ese sesgo dándole más peso a los pocos mayores que entraron en la muestra.

Estimador Basado en Modelos

Este es un enfoque donde ya no dependemos de los pesos del diseño muestral (w_i), sino que confiamos plenamente en que un modelo matemático planteado describe la estructura de toda la población. En este enfoque, el “estimador” es la suma de los valores observados en la muestra más los valores predichos para los individuos que no fueron seleccionados. Además la variabilidad o incertidumbre ya no vienen de “qué pasaría si elijo otra muestra”, sino de “qué tan bien ajusta mi modelo matemático a los datos”.

El modelo matemático puede ser cualquiera de los algoritmos utilizados comúnmente en Machine Learning, como regresión lineal, árboles de decisión, redes neuronales. Cuanto más complejo el algoritmo, mejor será la estimación, pero menos interpretable será.

```
library(survey)
# 1. Ajustamos un modelo de regresión lineal simple (sin usar el diseño muestral)
# Usamos lm() directamente sobre la muestra
modelo_puro <- lm(balance ~ age, data = muestra_sistemática)

# 2. Identificamos quiénes NO están en la muestra (la población no observada)
# Esto es fundamental en el enfoque basado en modelos
indices_muestra <- as.numeric(rownames(muestra_sistemática))
poblacion_no_observada <- bank_data[-indices_muestra, ]

# 3. Predecimos el balance para todos los que NO fueron encuestados
predicciones_resto <- predict(modelo_puro, newdata = poblacion_no_observada)

# 4. El estimador basado en modelos es la media de (observados + predichos)
suma_total_estimada <- sum(muestra_sistemática$balance) + sum(predicciones_resto)
media_basada_modelo <- suma_total_estimada / nrow(bank_data)

cat("Media Basada en Modelos:", round(media_basada_modelo, 2), "\n")
```

Media Basada en Modelos: 1470.43

En este caso usamos un modelo de regresión lineal simple sin basarnos en un diseño muestral. Cuando el modelo es “correcto” (la relación entre edad y saldo es la misma para todos), la estimación es muy buena. En este caso vemos que la estimación de la media utilizando modelos, en específico un modelo de regresión lineal simple, fue de 1470.43, que se aleja del valor real considerablemente, esto puede deberse a que tenemos sesgo de selección o que el modelo simple de edad no logra capturar, o la relación edad-saldo porque es muy simplificador o porque esa relación no es lineal para toda la población.

Visualmente:


```
# 1. Crear un dataset de predicción para la línea de tendencia
edades_eje <- data.frame(age = seq(min(bank_data$age), max(bank_data$age), length.out = 100))
predicciones_linea <- predict(modelo_puro, newdata = edades_eje)

# 2. Graficar los datos observados y la "asistencia" del modelo
library(ggplot2)

ggplot() +
  # Puntos de la muestra sistemática
  geom_point(data = muestra_sistemática, aes(x = age, y = balance), alpha = 0.5, color = "steelblue") +
  # La línea del modelo (en la que se basa nuestra inferencia)
  geom_line(data = edades_eje, aes(x = age, y = predicciones_linea), color = "darkred", size = 2) +
  # Etiquetas y estilo
  labs(title = "Estimación Basada en Modelos: Balance vs Edad",
       subtitle = "La línea roja representa la estructura poblacional asumida",
       x = "Edad", y = "Balance") +
  theme_minimal()
```

Estimación Basada en Modelos: Balance vs Edad

La línea roja representa la estructura poblacional asumida



Vemos que el ajuste de la recta a los puntos no es muy bueno y que la relacion no parece ser muy lineal, esto es una de las causas de que la estimacion no sea muy precisa.

Post-estratificacion

La Post-estratificación es una técnica de ajuste que se usa después de haber recolectado los datos para corregir posibles desbalances entre la muestra y la población real. En la post-estratificación ajustas los pesos de los individuos para que la distribución de una variable (en este caso, el estado civil o marital) coincida exactamente con lo que el banco sabe que tiene en su base de datos total.

Comparamos el diseño sistemático original (res_antes) frente al diseño ajustado por estado civil (res_despues) para la estimacion del balance

```
library(survey)

# 1. Definir los Totales de Control (Data real de bank_data)
# Estos son los valores que el banco sabe que son "La Verdad"
pob_marital <- bank_data %>%
  group_by(marital) %>%
  summarise(Freq = n())

# 2. Aplicar la Post-estratificación al diseño de dos etapas
```

```

diseño_post <- postStratify(
  design = diseño_sist,
  strata = ~marital,
  population = pob_marital
)

# 3. Comparar estimaciones
res_antes <- svymean(~balance, diseño_sist)
res_despues <- svymean(~balance, diseño_post)

print(res_antes)

```

```

      mean      SE
balance 1467.7 115.56

```

```
print(res_despues)
```

```

      mean      SE
balance 1471.1 115.95

```

La media subió ligeramente unas 3.4 unidades de 1467.7 a 1471.1. Esto indica que en la muestra sistemática original, los grupos de estado civil que suelen tener un balance más alto (posiblemente los “casados” o “divorciados”) estaban levemente sub-representados. El proceso de post-estratificación les dio más “peso” a esos individuos para reflejar mejor el balance real de los usuarios del banco, lo que subió el promedio estimado.

El error estándar aumentó 0.39, de 115.56 a 115.95, la post-estratificación reduce el error si la variable (estado civil) explica bien el comportamiento del saldo. Vemos que el aumento casi imperceptible sugiere que el estado civil no es un predictor muy fuerte del saldo, o que la muestra sistemática ya era bastante buena y representativa en términos de esta variable.

De todas formas la Post-estratificación brinda corrección de sesgo de cobertura, si por azar el muestreo sistemático hubiera saltado a muchos “solteros” (que tienen menos ahorros), la post-estratificación corrige ese error.

Raking

Anteriormente usamos solo el estado civil y no fue muy significativo, pero podemos cruzarlo con la educación para ver si hay significatividad. Para esto usaremos una técnica llamada Raking.

El Raking (también conocido como Iterative Proportional Fitting o Ajuste Proporcional Iterativo) es una técnica de calibración que se usa cuando se necesita que la muestra sea representativa en varias dimensiones al mismo tiempo, pero no conoces el cruce total de la población. Raking solo requiere conocer los totales marginales (ej. cuántos casados hay por un lado, y cuánta gente con educación secundaria hay por otro). El algoritmo ajusta los pesos de forma iterativa hasta que la muestra coincide con todos los totales poblacionales que usamos.

El algoritmo de Raking está realizando un proceso iterativo:

Paso 1: Ajusta los pesos para que la distribución de marital en la muestra coincida con la del banco. Al hacer esto, la distribución de education se desajusta un poco.

Paso 2: Toma esos nuevos pesos y los ajusta para que la distribución de education coincida con la del banco. Esto desajusta un poco lo de marital.

Repetición: Repite estos pasos una y otra vez hasta que, por fin, ambas dimensiones coinciden perfectamente con los totales poblacionales.

```
library(survey)

# 1. Asegúrate de que las tablas tengan la columna 'Freq'
pob_marital <- bank_data %>%
  group_by(marital) %>%
  summarise(Freq = n())

pob_education <- bank_data %>%
  group_by(education) %>%
  summarise(Freq = n())

# 2. Aplicar el Raking con los nombres de argumentos correctos
diseno_raking <- rake(
  design = diseno_sist,
  sample.margins = list(~marital, ~education),    # Usa punto (.)
  population.margins = list(pob_marital, pob_education) # Usa punto (.)
)

# 3. Estimar la media para ver el resultado
res_raking <- svymean(~balance, diseno_raking)
print(res_raking)
```

	mean	SE
balance	1478	114.67

La estimación ha subido respecto a los modelos anteriores. Al forzar a la muestra a representar correctamente tanto el estado civil como el nivel educativo simultáneamente, el modelo detectó que los grupos con saldos más altos (por ejemplo, personas casadas con educación universitaria) estaban ligeramente sub-representados en tu muestra sistemática inicial. El ajuste por Raking infló el peso de esos perfiles específicos para que coincidan con la realidad del banco, lo que elevó el promedio global a 1478, aunque la estimación se alejó más de la media poblacional, esto puede ser porque no estamos considerando otra variable que sería relevante para el Raking

El Error Estándar (SE) bajó un poco en comparación con la post-estratificación simple. Al usar dos variables auxiliares (marital + education), el modelo tiene más información para explicar la variabilidad del saldo, ganamos más precisión (menos varianza).

Trimming

Cuando aplicamos Raking, el algoritmo estiró los pesos para que la muestra encajara con la población. Esto a veces crea pesos inflados (individuos que representan a demasiada gente). El problema de los pesos altos es que un cliente tiene un peso muy alto y un saldo inusual, afectando a la media y sube el error estándar.

El Trimming recorta los pesos poniendo un límite superior (upper) y un límite inferior (lower) a los pesos. En nuestro caso, ningún peso puede ser mayor a 5 ni menor a 15

```
library(survey)

# 1. Aplicar el recorte (Trimming)
# lower: límite inferior | upper: límite superior
# strict = TRUE: obliga a que los pesos sumen exactamente el N poblacional tras el recorte
diseno_trimmed <- trimWeights(
  diseno_raking,
  lower = 8,
  upper = 10.5,
  strict = TRUE
)

# 2. Comparar la distribución de pesos
summary(weights(diseno_raking))
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
8.051	8.650	9.030	8.988	9.163	10.036

```
summary(weights(diseno_trimmed))
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
8.051	8.650	9.030	8.988	9.163	10.036

```
# 3. Ver el impacto en la estimación del balance
res_antes <- svymean(~balance, diseno_raking)
res_despues <- svymean(~balance, diseno_trimmed)

print(res_antes)
```

```
      mean      SE
balance 1478 114.67
```

```
print(res_despues)
```

```
      mean      SE
balance 1478 114.67
```

Obtuvimos una estimación de la media con un error estándar asociado igual que antes, esto indica que los pesos asociados al diseño sistemático estaban bien calibrados y no fue necesario recortarlos. El diseño no requiere un recorte de pesos (Trimming) porque el factor de expansión se mantiene en un rango estrecho de 8.05 a 10.03. Esto indica que el Muestreo Sistemático inicial logró una cobertura equilibrada de las categorías de estado civil y educación. Ahora que la estimación (1478) está lejos de la real (1422), no es por los pesos, sino que la edad, la educación y el estado civil no explican el 100% del saldo. Hay clientes con saldos muy bajos por razones que no están en esas variables.

No Respuesta:

```
# Simulamos una columna de 'Respuesta' (1 = respondió, 0 = no respondió)
# Generalmente, los clientes con menos saldo responden menos (un sesgo común)
set.seed(123)
muestra_2etapas$responde <- rbinom(nrow(muestra_2etapas), 1, prob = 0.8)

# 1. Calculamos la Tasa de Respuesta por estrato o cluster
tasas_respuesta <- muestra_2etapas %>%
  group_by(cluster_id) %>%
  summarise(tasa_r = mean(responde))

# 2. Ajustamos los pesos originales dividiéndolos por la tasa de respuesta
```

```
muestra_respondientes <- muestra_2etapas %>%
  filter(responde == 1) %>%
  left_join(tasas_respuesta, by = "cluster_id") %>%
  mutate(peso_ajustado_nr = peso_w / tasa_r)

# Verificación: La suma de pesos ajustados debe acercarse a la población original
cat("Suma pesos ajustados:", sum(muestra_respondientes$peso_ajustado_nr))
```

Suma pesos ajustados: 4492

```
# Simulamos valores perdidos (NA) en el balance
muestra_respondientes$balance_con_na <- muestra_respondientes$balance
muestra_respondientes$balance_con_na[sample(1:nrow(muestra_respondientes), 5)] <- NA

# Usamos imputación simple por mediana dentro de grupos parecidos (ej. por trabajo)
muestra_imputada <- muestra_respondientes %>%
  group_by(job) %>%
  mutate(balance_final = ifelse(is.na(balance_con_na),
                                median(balance_con_na, na.rm = TRUE),
                                balance_con_na)) %>%
  ungroup()
```

```
# Media de los que respondieron (sin ajuste)
media_cruda <- mean(muestra_respondientes$balance)
# Media con pesos ajustados por no respuesta
media_corregida <- sum(muestra_respondientes$balance * muestra_respondientes$peso_ajustado_nr) /
  sum(muestra_respondientes$peso_ajustado_nr)

cat("Efecto del sesgo de no respuesta:", media_corregida - media_cruda)
```

Efecto del sesgo de no respuesta: 3.506728

“Mecanismos de Pérdida” (MCAR, MAR, MNAR)

```
# Creamos un modelo logístico para predecir quién responde
# Si las variables son significativas, estamos ante un caso MAR (corregible)
modelo_no_respuesta <- glm(responde ~ age + job + education,
                           data = muestra_2etapas,
                           family = binomial)
```

Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred

```
summary(modelo_no_respuesta)
```

Call:

```
glm(formula = responde ~ age + job + education, family = binomial,  
     data = muestra_2etapas)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	4.096e+01	8.365e+03	0.005	0.996
age	-7.676e-02	6.067e-02	-1.265	0.206
jobblue-collar	-3.666e+01	8.365e+03	-0.004	0.997
jobhousemaid	-1.663e+01	1.960e+04	-0.001	0.999
jobmanagement	-7.060e+01	1.069e+04	-0.007	0.995
jobself-employed	-1.725e+01	1.178e+04	-0.001	0.999
jobservices	-3.713e+01	8.365e+03	-0.004	0.996
jobtechnician	-3.609e+01	8.365e+03	-0.004	0.997
jobunemployed	-5.434e+01	9.596e+03	-0.006	0.995
educationsecondary	-2.389e-01	1.536e+00	-0.156	0.876
educationtertiary	3.521e+01	6.652e+03	0.005	0.996
educationunknown	-1.890e+01	5.915e+03	-0.003	0.997

(Dispersion parameter for binomial family taken to be 1)


Null deviance: 52.691 on 49 degrees of freedom
Residual deviance: 31.924 on 38 degrees of freedom
AIC: 55.924

Number of Fisher Scoring iterations: 19

```
ggplot(muestra_2etapas, aes(x = age, fill = as.factor(responde))) +  
  geom_density(alpha = 0.5) +  
  labs(title = "Análisis de No Respuesta por Edad",  
        subtitle = "Si las curvas son muy diferentes, hay un sesgo de selección",  
        fill = "¿Respondió?") +  
  theme_minimal()
```

Análisis de No Respuesta por Edad

Si las curvas son muy diferentes, hay un sesgo de selección



Muestras no probabilísticas

```
# 1. Creamos la muestra no probabilística (Sesgada)
# Los jóvenes (age < 30) tienen 5 veces más probabilidad de participar
muestra_no_prob <- bank_data %>%
  mutate(prob_participar = ifelse(age < 30, 0.5, 0.1)) %>%
  slice_sample(n = 500, weight_by = prob_participar)

# 2. Comparamos las medias
media_real <- mean(bank_data$balance)
media_no_prob <- mean(muestra_no_prob$balance)

cat("Media Real Poblacional: ", media_real, "\n")
```

Media Real Poblacional: 1422.658

```
cat("Media Muestra No Probabilística: ", media_no_prob, "\n")
```

Media Muestra No Probabilística: 1310.012

```
cat("Sesgo de Selección: ", media_no_prob - media_real, "\n")
```

Sesgo de Selección: -112.6458