

Series Proyecto Final

Diego Da Rosa , CI=5455734-2 , Junio 2025

1 Resumen Ejecutivo:

En este documento lo que hacemos es analizar la serie de tiempo del IMAE siguiendo una metodología de Descripción, Identificación, Estimación, Validación, Predicción. En cada uno de los pasos detallamos los pasos seguidos y los resultados obtenidos. El propósito de nuestro trabajo es poder identificar un modelo apropiado para realizar predicciones a futuro sobre la serie del IMAE. Realizamos una serie de técnicas con distintos fines como aplicar la transformación logarítmica a la serie, la identificación y filtrado de la tendencia y la estacionalidad con el fin de plantear un posible modelo. Con base en la FAC y la FACP de nuestra serie transformada, planteamos un posible modelo SARIMA que podría adaptarse a nuestra serie, observamos que la significación de los coeficientes asociados al modelo planteado se reducía al aplicar la transformación logarítmica, por lo que descartamos su uso. Luego verificamos los residuos de este modelo planteado, obteniendo que algunos supuestos sobre los residuos se cumplían y otros no, con base en esto consideramos reajustar los puntos atípicos que podía tener el modelo para volver a verificar el cumplimiento de los residuos, donde si bien pasaron a eliminarse los problemas de no cumplimiento de los supuestos sobre los residuos del modelo, obtuvimos nuevos problemas en relación con la significación de los coeficientes asociados a este modelo ajustado por considerar los valores atípicos, por lo que decidimos considerar otro modelo posible realizando de nuevo los pasos de verificación del cumplimiento de los residuos y ajuste de valores atípicos de este nuevo modelo considerado. Finalmente, realizamos una predicción a 8 meses a futuro y validamos el rendimiento predictivo de nuestro modelo considerando predicciones dentro y fuera de la muestra utilizando la técnica de partición de los datos en train-test, obtuvimos las respectivas métricas predictivas asociadas.

2 Antecedentes sobre la variable

En este documento lo que hacemos es analizar la serie de tiempo del IMAE (Indicador Mensual de Actividad Económica), que es un indicador económico sintético, construido a partir de otros indicadores individuales combinados derivados de distintos sectores de actividad económica, como Agropecuario, Minería, Manufactura, Energía, Salud, Finanzas, etc. El IMAE es un indicador de corto plazo reportado mensualmente. Se basa en estadísticas y métodos contables. El

IMAE es un índice de Laspeyres mensual con base 100 en el año 2016, indica la actividad económica con una frecuencia mensual a precios constantes de 2016. Para calcular el IMAE vemos el valor agregado a precios básicos de cada una de las actividades económicas agregando los impuestos netos de subsidios a los productos, utilizando las ponderaciones de las cuentas nacionales base 2016. La razón de usar indicadores mensuales es para ver el valor agregado de las industrias y de los impuestos netos de subsidios sobre los productos. La publicación del IMAE se hace a los 60 días de que termina el mes.

Fuentes: <https://www.bcu.gub.uy/Estadisticas-e-Indicadores/Documents/Metodolog%C3%ADa%20IMAE.pdf>


3 Metodología

PreProcesamiento de Datos: Los datos que tenemos los obtuvimos de la página del Banco Central Del Uruguay. Los datos van desde Enero de 2016 hasta Marzo de 2025 y son mensuales, mostrando el valor del IMAE para el primer día de cada mes. No hay valores nulos en nuestros datos. Convertimos los datos a tipo ts (time series) para poder operar mejor con ellos en el R.

Medidas de Resumen de la serie: El mínimo valor que toma la serie es 85.03 y se alcanza en Abril de 2020, el máximo valor que toma la serie es 116.73 y se alcanza en octubre de 2024. El primer cuartil vale 99.10, el tercero vale 107.21 y la mediana vale 102.36. La media vale 102.76. La varianza es 34.71 y el desvío estándar 5.89. El rango intercuartílico vale 8.10

3.1 Logaritmo


Aplicamos logaritmo a la serie por dos razones, la primera fue volver a la varianza más homogénea y la segunda para linealizar la tendencia. Al comparar la varianza de la serie original con la de la serie logaritmizada, vimos que se redujo de 34.71899 a 0.0033, en cuanto a la tendencia lo veremos más adelante, el gráfico de la serie original y de la serie logaritmizada son iguales. Luego realizamos la FAC y la FACP de la serie original y de la serie logaritmizada, ambas son iguales y en la FAC observamos que hay varios rezagos significativos al inicio y a partir del rezago 14 dejan de serlo, luego algunos como el rezago 24 y 36 si lo son, hay una convergencia lenta hacia el cero. En el caso de la FACP tenemos un patrón de rezagos significativos y no significativos desde el 0 hasta el 13 y luego los demás se mantienen dentro de la banda de confianza. Podemos plantear inicialmente que nuestra serie no es estacionaria basada en lo que vemos en la FAC y la FACP.



3.2 Tendencia

En esta sección intentamos identificar si nuestra serie presentaba una tendencia creciente o decreciente. Hicimos diferentes test para verificar la tendencia, y luego filtramos esa tendencia con una diferencia regular usando la función `diff` en R, luego hicimos los mismos test sobre la serie diferenciada regularmente para verificar que la tendencia se filtró.

Empezamos con la gráfica de la serie con la diferencia regular, además de ver la FAC y la FACP de la misma, vemos que la aplicación de la diferencia regular filtro la tendencia creciente que se observaba en el gráfico de la serie original.




Test de Dicky-Fuller: Utilizamos el test de Dicky-Fuller para testear la existencia de raíces unitarias regulares que nos indican tendencia estocástica en nuestra serie, lo que implica no estacionariedad. El contraste de hipótesis que se realiza es el siguiente: H_0) Existe raíz unitaria (serie no estacionaria) H_1) No Existe raíz unitaria (serie estacionaria). Para implementarlo en R usamos la función `ur.df`, con nuestra serie de datos original y marcando `type=trend` para


indicar que nuestros datos presentaban tendencia, seleccionando los rezagos con el criterio BIC, el problema que encontramos (que se repitió también para el criterio AIC) fue había autocorrelación en los residuos, específicamente en los rezagos 6 y 12, por eso decidimos seleccionar el número de rezagos manualmente poniendo 6, obteniendo así que la correlación de los residuos desaparecía. Al aplicar este test en nuestra serie original obtuvimos un valor t de -2.462 , los valores críticos asociados a distintos niveles de significación observados en τ_3 son: -3.99 al 1%, -3.43 al 5%, -3.13 al 10%. Notamos que nuestro valor t -2.462 es mayor a todos los valores τ_3 para todos los niveles de significación, por lo que no Rechazamos H_0 , existen raíces unitarias, por lo que la serie presenta tendencia estocástica y no es estacionaria. Otra forma de observar esto es que el valor del F asociado a ϕ_2 es 2.2091 que es menor para todos los valores a distintos niveles de significación del ϕ_2 , en el cual testeábamos raíz unitaria y tendencia, por lo que es un indicador de raíz unitaria en nuestra serie. También podíamos ver el F asociado al ϕ_3 que vale 3.1001 , el ϕ_3 me testea tendencia igual cero, hay raíz unitaria y puede existir constante, dado que 3.1001 es menor que todos los valores asociados a ϕ_3 para todos los niveles de significación, es un indicador de raíz unitaria en nuestra serie.

Si volvemos a hacer el test de dicky-fuller para la serie con la diferencia regular obtenemos que el valor t de -9.973 , los valores críticos asociados a distintos niveles de significación observados en τ_3 son: -3.99 al 1%, -3.43 al 5%, -3.13 al 10%. Notamos que nuestro valor -9.973 es menor a todos los valores τ_3 para todos los niveles de significación, por lo que rechazamos H_0 , existen raíces unitarias, por lo que la serie no presenta tendencia estocástica y es estacionaria. Otra forma de verlo es usar el valor del F asociado a ϕ_2 , que vale 33.1553 , que es mayor que todos los valores asociados a ϕ_2 para todos los niveles de significación, lo que indica que no hay raíz unitaria ni tendencia. Usando el valor F asociado a ϕ_3 , que vale 49.733 , que es mayor a todos los coeficientes de ϕ_3 para todos los niveles de significación, concluimos que no hay raíz unitaria ni tendencia.

Otra prueba que hice es un ajuste lineal a la serie original (imagen izquierda) para detectar tendencia. En el summary de esta prueba, vemos que el p valor es menor a 0.05 , por lo que hay una tendencia. También podemos verlo en la recta de regresión que tiene una pendiente positiva, lo que es indicio de una tendencia creciente en la serie. Cuando hacemos este ajuste de una recta de regresión a la serie con la diferencia regular (imagen derecha), el p valor que obtenemos es mayor a 0.05 , por lo que es un indicador de no tendencia. En el gráfico se ve que la recta se mantiene horizontal y la tendencia se ha filtrado. Es importante aclarar que esto NO es una prueba de tendencia determinística, solo es una forma de detectar un comportamiento creciente en la serie.




Otro test de tendencia que hice fue el análisis del espectro que nos sirve para detectar tendencia, la cual se da cuando la frecuencia cero explica gran parte de la varianza (área debajo del espectro), que es lo que ocurre en nuestra serie original (imagen izquierda). Cuando hacemos el análisis del espectro para la serie diferenciada regularmente (imagen derecha), vemos que la frecuencia cero explica muy poco la varianza, lo que es un indicador de que filtramos la tendencia.




3.3 Estacionalidad

Lo que hice fue aplicar la diferencia estacional usando la función `diff` a la serie que ya tenía la diferencia regular, pero que presentaba estacionalidad, y comparar con distintos test para ver como la estacionalidad se filtró.


Primero si comparamos el espectro de la serie con la diferencia regular (imagen izquierda) y de la serie con las diferencias regular y estacional (imagen derecha) vemos que los picos en la frecuencia 2 y en la frecuencia 4 que tomaban valores muy altos e indicaban posible estacionalidad, desaparecieron cuando aplicamos la diferencia estacional, y ahora el espectro se mueve en valores entre 0.5 y 10. Se sigue manteniendo ese comportamiento de picos, y aunque sean variaciones que están entre valores bajos, podemos decir que logramos filtrar bastante la estacionalidad, pero aún queda una parte.



Otra forma de verlo es con la FAC de la serie a la que le aplicamos la diferencia regular en la cual vemos rezagos significativos en 6, 12, 18, 24, 30, 36 y así en un patrón de 6 en 6, lo que es un fuerte indicador de estacionalidad (imagen izquierda). Estos rezagos y el patrón que siguen, desaparece cuando hacemos la FAC y la FACP de la serie con diferencia regular y estacional (imagen derecha).



Otra forma de detectar la estacionalidad es con el gráfico ggmonthplot, para la serie que tenía solo la diferencia regular (imagen izquierda) detectamos que las líneas negras que son los valores de la serie por mes y año muestran un patrón. Observamos valores bajos en meses como Enero, valores altos para los meses de Mayo, Octubre, Noviembre y Diciembre y valores intermedios para los demás meses, esto en todos los años, por lo que nuestro modelo presenta un comportamiento estacional. Además, las medias mensuales (líneas azules) son distintas, lo que indica que el comportamiento promedio depende del mes. Este patrón se repite cada 12 meses para todos los años. Para la serie con diferencia regular y estacional, estos patrones se eliminan y las medias coinciden bastante entre sí.



Luego de estos procesos, para verificar que las diferencias que hicimos nos dieron una serie estacionaria, usamos test de KPSS, que testea las siguientes hipótesis: H_0) La serie es estacionaria , H_1) La serie NO es estacionaria.

Cuando lo hicimos para nuestra serie original, obtuvimos un p valor menor a 0.05, por lo que rechazamos H_0 , rechazamos la estacionariedad de la serie. Cuando lo hicimos para la serie con la diferencia regular, obtuvimos un p valor de 0.10, que es mayor a 0.05, por lo que no rechazamos H_0 , o sea que nuestra serie diferenciada presenta estacionariedad. Lo mismo para la serie con diferencia regular y estacional.

4 Elección de Modelo Posible:

Dada la FAC y FACP de nuestra serie logaritmizada, con una diferenciada regular y estacional, un posible modelo inicial podría ser un SARIMA(0,1,2,0,1,1) Con respecto a la parte regular del SARIMA elegimos $q=2$ porque hay dos rezagos significativos en la FAC, los demás rezagos son no significativos. Como no hay significancia en los primeros rezagos descartamos un AR ($p=0$) y usamos $d=1$ para aplicar una diferencia regular. Con respecto a la parte estacional del SARIMA, el rezago 12 es muy significativo y un poco el rezago 24, esto es evidencia de autocorrelación estacional. El patrón cae después del rezago 12, que ocurre en un MA estacional de orden 1, es decir $Q = 1$, no encontramos patrones asociados a un AR estacional, por lo que $P=0$, y como aplicamos una diferencia estacional, pusimos $D=1$.

Planteamos nuestro modelo y revisamos la significancia de los coeficientes, en este momento surgió un problema derivado de que al especificar que la serie fuera con logaritmos, los coeficientes asociados al modelo seleccionado no son significativos y al no usar logaritmo, si lo son. Decidimos descartar el uso del logaritmo en nuestra serie y usar la serie original para que los coeficientes si nos quedaran significativos. El coeficiente asociado a $ma1$ y $ma2$ son significativos (*), el coeficiente asociado a $sma1$ es muy significativo (***)

En los residuos, se cumplieron la Incorrelación y la homoscedasticidad, pero no se cumplió la normalidad, para solucionar esto ajustamos el modelo considerando los outliers. Lo que hicimos fue usar la función `tso` del paquete `tsoutliers` que detecta el tipo, el tiempo y la magnitud del outlier, además especificamos que se consideraran outliers del tipo "AO", "TC", estas consideraciones se almacenan en la variable `xreg` los efectos de estos, además de re-estimar nuestro modelo SARIMA incluyendo esos elementos.


4.1 Diagnóstico y Re-Diagnóstico:

Vamos a mostrar el diagnóstico de los residuos que hicimos para el modelo original y el re-diagnóstico que hicimos para el modelo ajustado por los outliers, para ver que mejoro:

4.2 Incorrelación de los residuos:


Para ambos modelos, el seleccionado (imagen izquierda) y el ajustado por los outliers (imagen derecha), graficamos la FAC y la FACP de los residuos donde vemos que todos los rezagos se encuentran dentro del intervalo de confianza, no son significativos, lo que es un indicador gráfico de incorrelación de los residuos. En el caso del rezago 3 en la FAC y FACP del modelo ajustado por los outliers, que nos quedó significativo, no lo consideramos porque el test nos dio significativo. Luego hicimos el test de Ljung-Box que testea la hipótesis: H_0) Residuos Incorrelacionados , H_1) Residuos Correlacionados. Para el modelo seleccionado obtuvimos un p valor de 0.8198 y para el ajustado por outliers de 0.7384, ambos mayores a 0.05, por lo que no rechazamos H_0 , los residuos se encuentran

incorrelacionados.



4.3 Normalidad de los residuos

Luego la siguiente prueba fue la normalidad de los residuos, para ambos modelos hicimos un qqplot y observamos que en el caso del modelo seleccionado (imagen izquierda), el ajuste de la recta del qqplot no era tan buena como en el caso del mismo modelo incorporando los outliers (imagen derecha).




Usamos dos test estadísticos, el de Shapiro y el de Jarque-Bera, en ambos estamos testeando (de distintas formas) las hipótesis: H_0) Residuos Distribuyen Normal, H_1) Residuos No Distribuyen Normal.

Para el modelo elegido, el test de Shapiro nos dio un p valor de 0.004268 que es menor a un nivel de significación alfa de 0.05, por lo que rechazamos H_0 , o sea, rechazamos a hipótesis de normalidad. El test de Jarque-Bera el cual se divide en tres: Jarque-Bera Test Global, donde el p valor obtenido fue menor a 0.05, rechazamos la hipótesis nula, que los residuos no provienen de una distribución normal. Los otros dos son Test de Asimetría (Skewness) donde H_0 es que la asimetría es 0, y H_1 es que la asimetría es distinta de 0. En nuestro caso nos dio un p valor de 0.2303, por lo que no rechazamos la H_0 de este test. El otro es Test de Curtosis, donde H_0 es que la curtosis es 3 (que sucede en una distribución normal) y H_1 que no es 3, en nuestro caso el p valor fue menor a 0.05, por lo que rechazamos H_0 en este test. Para el caso del modelo ajustado por los outliers, el test de Shapiro nos dio 0.2866 por lo que no rechazamos H_0 . El test de JarqueBera (global, simetría y curtosis), obtuvimos p valores mayores a 0.05, por lo que no rechazamos H_0 . Podemos decir que solucionamos los problemas de normalidad, ajustando los outliers al modelo.

4.4 Homoscedasticidad de los residuos:


Para verificar que se cumple la Homoscedasticidad (varianza constante) de los residuos obtuvimos los residuos al cuadrado, y les aplicamos el test de Ljung-Box, donde en este caso estamos contrastando H_0) Residuos Homoscedasticos vs H_1) Residuos Heteroscedasticos. Al hacer un test para nuestro modelo seleccionado obtuvimos un p valor de 0.6093 por lo que no rechazamos H_0 , al hacerlo para el modelo ajustado por outliers nos pasó lo mismo con un p valor de 0.7384

Otra forma de detectarlo es con la FAC y la FACP de esos residuos al cuadrado donde en ambos modelos se cumple que la mayoría de los rezagos son no significativos, tanto para el modelo seleccionado (imagen izquierda) como para el modelo con los ajustados por los outliers (imagen derecha) lo que indica posible homoscedasticidad.



5 Outliers:

Realizamos un gráfico donde vemos la serie original contra la serie con los outliers ajustados, junto con un gráfico de los efectos de los outliers.



Para dar un poco de contexto, este outlier ocurre en Abril de 2020, que fue el punto donde inicio la emergencia sanitaria de Covid-19, lo que tuvo un efecto importante en la economía, y por lo tanto en el IMAE. Podemos observar en el gráfico que este outlier tuvo un efecto del tipo TC (Transitory Change), esto nos indica que la pandemia tuvo un efecto bastante fuerte en la serie del IMAE, pero vemos que fue desapareciendo poco a poco a lo largo de los años el efecto de


este outlier, lo que coincide con que la economía se fue estabilizando con el paso de los años, hasta volver al valor en el que se encontraba en aproximadamente 2022, como se ve en el gráfico para el caso del IMAE.

Al nuevo modelo que propusimos le calculamos los outliers y los incorporamos a este nuevo modelo, luego al plantear la significación de los coeficientes de este nuevo modelo ajustado por los outliers, vimos que hay dos elementos que no son significativos, que son $ma2$ y $sma1$. Lo que hicimos fue entrenar un nuevo modelo, bajando el valor MA de la parte no estacionaria (regular) del SARIMA de 2 a 1, usando un $SARIMA(0,1,1)(0,1,1)$. Con este nuevo modelo planteado verificamos si se cumplían los residuos, obteniendo de nuevo que si se cumplía la incorrelación y la homoscedasticidad, pero no se cumplía la normalidad, volvimos a ajustar ese modelo por sus Outliers y ahí pasaron a cumplirse todos los supuestos de normalidad, además de que a diferencia del anterior, todos sus coeficientes ($ma1$, $sma1$, etc) eran significativos.

Comparamos varios criterios de selección como AIC, AICc, BIC en ambos modelos y en todos obtengamos que el modelo2 era más significativo, por lo que continuamos el trabajo con este modelo.

5.1 Predicción:

Los datos del IMAE van desde el 01/01/2016 hasta el 01/03/2025. Vamos a predecir h 10 meses adelante, hasta el 01/01/2026. Primero definimos un horizonte de predicción con valor 10, para predecir los siguientes 10 meses, luego con la matriz `outoutliers.effects` generamos una matriz de los efectos (regresores) en la serie generados por los outliers detectados usando `tso`, esto lo almacenamos en la variable `newxreg1`. Estamos viendo estos efectos de los outliers para los datos observados y para los futuros h pasos. Como solo te interesan los valores para la predicción futura, seleccionamos desde $t+1$ hasta $t+h$. Queremos los valores para la predicción futura, por eso vamos desde $t+1$ hasta $t+h$, en `newxreg1` almacenamos la matriz con los valores esperados de los outliers en esos períodos futuros. Hacemos la predicción del modelo ajustado por los outliers que teníamos, para hacer esta predicción usamos la función `forecast` y consideramos los efectos futuros de los outliers como variables explicativas para la predicción en el parámetro `xreg` de la función, pasándole `newxreg1`.



Ahora si queremos conocer la tasa de crecimiento interanual para los valores de 2025, la lógica que seguiremos es utilizando los valores predichos para 2025, los compararemos con su correspondiente valor de 2024 a través de la siguiente fórmula:

$$\text{Tasa de crecimiento interanual} = \left(\frac{V_t}{V_{t-12}} - 1 \right) \times 100$$

En este caso lo que hicimos fue ir aplicando esa fórmula para los valores predichos que van desde abril de 2025 hasta diciembre de 2026 con los valores reales ocurridos en ese mismo periodo pero desde abril de 2024 hasta diciembre de 2025.

fecha <db>	valores_reales_periodo_anterior <db>	predicho <db>	tasa_interanual_porcentaje <db>
2025.250	109.550	108.8157	-0.67032396
2025.333	114.388	113.7329	-0.57269366
2025.417	109.847	112.2053	2.14685580
2025.500	106.304	108.4833	2.05002822
2025.583	108.016	108.6379	0.57576899
2025.667	107.479	107.7783	0.27849622
2025.750	112.285	110.7898	-1.33159618
2025.833	116.734	116.8307	0.08280331
2025.917	115.539	119.2311	3.19551093
2026.000	109.956	111.7885	1.66657692

Luego para Tasa promedio anual de crecimiento IMAE 2025 respecto a 2024 la fórmula es:


$$\text{Tasa de crecimiento anual promedio} = \left(\frac{\bar{V}_{2025}}{\bar{V}_{2024}} - 1 \right) \times 100$$

y al aplicar obtenemos el valor de 0.64%. El crecimiento del IMAE para 2025 sera de 0.64%.

5.2 Validación de las Predicciones:

Dividimos la serie de datos en dos conjuntos, el conjunto de train (entrenamiento) y el conjunto de test (testeo). El conjunto de train se usa para ajustar el modelo, el conjunto de test se usa para evaluar el rendimiento predictivo del modelo. Al particionar así, conocemos lo que ha ocurrido, pero el modelo no lo conoce, por lo que al predecir dentro de la muestra, veremos que tan bien lo ha hecho. Nuestra serie del IMAE tiene 111 observaciones, vamos a usar 99 observaciones para el conjunto de entrenamiento, que será lo que ocurrió desde 01/01/2016 hasta 01/03/2024. Luego usaremos 12 observaciones para evaluar el rendimiento de nuestro modelo dentro de la muestra, donde el modelo hará una predicción de lo que ocurrió desde el 01/03/2024 hasta el 01/03/2025, donde nosotros ya sabemos lo que ocurrió y podremos comparar el rendimiento de nuestro modelo.

Vemos que la predicción dentro de la muestra es similar a lo que ocurrió realmente, con pequeñas variaciones. En su mayoría lo que ocurrió se mantiene dentro de la banda de confianza de las predicciones dentro de la muestra, aunque al inicio está bordeando la banda de confianza, parece que el modelo tuvo un peor rendimiento al inicio.



Podemos comparar ambos valores, reales vs predichos dentro de la muestra con la siguiente tabla:

fecha	real	predicho
2024.250	109.550	104.4183
2024.333	114.388	109.2351
2024.417	109.847	108.0034
2024.500	106.304	104.2455
2024.583	108.016	104.1334
2024.667	107.479	103.2114
2024.750	112.285	105.9581
2024.833	116.734	112.2185
2024.917	115.539	115.1016
2025.000	109.956	107.3678

O podemos evaluar la calidad de la predicción con distintas métricas:

	ME	RMSE	MAE	MPE	MAPE
Training set	-0.1296099	2.246784	1.590856	-0.1514662	1.583786
Test set	4.1565036	4.585286	4.156504	3.7614851	3.761485
	MASE	ACF1	Theil's U		
Training set	0.4051202	0.03052456	NA		
Test set	1.0584765	0.37450672	1.168529		

ME es el promedio de los errores, casi sin sesgo, pero sobreestima un poco. RMSE es la raíz cuadrada del error cuadrático medio, el modelo es más preciso en test. MAE es el promedio del valor absoluto del error, en test y train son muy similares. MPE es el promedio de los errores porcentuales, casi sin sesgo porcentual. MAPE es el promedio del valor absoluto de errores porcentuales, es muy bajo, indica un buen ajuste. MASE es el Error absoluto medio escalado que es un MAE comparado con el MAE de un modelo random walk, con los valores vemos que es mejor que ese modelo. ACF1 es la autocorrelación del primer rezago en residuos, hay algo de autocorrelación en test. Theil's U Compara el modelo con naive, el modelo es mejor que una predicción naive. Un naive es un modelo que predice lo mismo que el último valor.

6 Conclusiones Finales:

Luego de haber seguido la metodología que usamos en el informe, el modelo que obtuve, si bien no es perfecto, considero que está bien seleccionado y que tiene una capacidad predictiva buena, basándome en los parámetros de error predictivo que vimos. Considero que los test para detectar la tendencia y la estacionalidad fueron claves para mejorar a nuestro modelo, junto con la consideración de outliers que podían afectar el rendimiento del mismo. Se observó que la aplicación del logaritmo no fue muy eficiente, y me pareció relevante destacar que el trabajar con series de tiempo no es una actividad automática, sino que se debe iterar una y otra vez las técnicas que usamos, verificando el rendimiento de lo que planteamos y el cumplimiento de determinados supuestos, para ir obteniendo mejores resultados, es un proceso de aprendizaje y mejoramiento continuo.

7 Anexo

Salida de R sobre las Medidas de Resumen

```
[1] "Resumen del objeto time series:"  
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.  
 85.03  99.10 102.36 102.76 107.21 116.73  
[1] "Momento donde se dio el mínimo, 2020.25"  
[1] "Momento donde se dio el máximo: 2024.83333333333"  
[1] "La varianza es: 34.7189940851761"  
[1] "La desviación estándar es: 5.89228258700956"  
[1] "El rango intercuartílico es: 8.10599999999999"
```

Salida de R sobre comparacion de varianzas en serie y serie logaritmica Salida de R sobre las Medidas de Resumen

```
[1] "La varianza de la serie original es:"  
[1] 34.71899  
[1] "La varianza de la serie logaritmizada es:"  
[1] 0.003320585
```

Salida de R sobre Test de Dicky-Fuller para nuestra serie original

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

Test regression trend

Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)

Residuals:
    Min       1Q   Median       3Q      Max
-10.5109  -1.9118   0.2532   1.9475   8.8023

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  23.75890    9.68605   2.453  0.0160 *
z.lag.1      -0.24257    0.09853  -2.462  0.0156 *
tt           0.02310    0.01350   1.710  0.0905 .
z.diff.lag1   0.12770    0.12580   1.015  0.3126
z.diff.lag2  -0.21714    0.12386  -1.753  0.0828 .
z.diff.lag3  -0.08017    0.11353  -0.706  0.4818
z.diff.lag4  -0.26699    0.10924  -2.444  0.0164 *
z.diff.lag5  -0.01066    0.10114  -0.105  0.9163
z.diff.lag6   0.26104    0.09982   2.615  0.0104 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.379 on 95 degrees of freedom
Multiple R-squared:  0.455,    Adjusted R-squared:  0.4091
F-statistic: 9.912 on 8 and 95 DF,  p-value: 6.198e-10

Value of test-statistic is: -2.462 2.2091 3.1001

Critical values for test statistics:
    1pct    5pct   10pct
tau3  -3.99  -3.43  -3.13
phi2   6.22   4.75   4.07
phi3   8.43   6.49   5.47
```

Salida de R sobre ajuste de modelo lineal de nuestra serie original

```
call:
lm(formula = im_ts ~ time(im_ts))

Residuals:
    Min       1Q   Median       3Q      Max
-17.3973  -2.4160  -0.5336   3.0934  11.3662

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -1967.0143    376.1056  -5.230 8.27e-07 ***
time(im_ts)   1.0243     0.1861   5.503 2.50e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 5.236 on 109 degrees of freedom
Multiple R-squared:  0.2174,    Adjusted R-squared:  0.2103
F-statistic: 30.29 on 1 and 109 DF,  p-value: 2.497e-07
```

Salida de R sobre Test de Dicky-Fuller para nuestra serie diferenciada regularmente:

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

Test regression trend

Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)

Residuals:
    Min       1Q   Median       3Q      Max
-8.7793 -2.6800 -0.3871  2.9859 12.0004

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.132668   0.802791   0.165   0.869
z.lag.1     -1.204619   0.120785  -9.973 < 2e-16 ***
tt          -0.000176   0.012609  -0.014   0.989
z.diff.lag   0.372732   0.091452   4.076 8.99e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.085 on 104 degrees of freedom
Multiple R-squared:  0.5162,    Adjusted R-squared:  0.5022
F-statistic: 36.99 on 3 and 104 DF,  p-value: 2.381e-16

Value of test-statistic is: -9.9732 33.1553 49.733

Critical values for test statistics:
      1pct   5pct 10pct
tau3  -3.99 -3.43 -3.13
phi2   6.22  4.75  4.07
phi3   8.43  6.49  5.47
```

Salida de R sobre ajuste de modelo lineal de nuestra serie diferenciada regularmente:

```
call:
lm(formula = im_ts_diff ~ time(im_ts_diff))

Residuals:
    Min       1Q   Median       3Q      Max
-9.9588 -3.2286 -0.1229  2.5545 11.8161

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  28.71956   316.87820   0.091   0.928
time(im_ts_diff) -0.01416    0.15682  -0.090   0.928

Residual standard error: 4.352 on 108 degrees of freedom
Multiple R-squared:  7.552e-05, Adjusted R-squared: -0.009183
F-statistic: 0.008157 on 1 and 108 DF,  p-value: 0.9282
```

Salida de R sobre test de KPSS para serie original (primero) y serie diferenciada (abajo)

```

Aviso: p-value smaller than printed p-value
      KPSS Test for Level Stationarity

data: im_ts
KPSS Level = 0.94481, Truncation lag parameter = 4, p-value =
0.01

Aviso: p-value greater than printed p-value
      KPSS Test for Level Stationarity

data: Flim_ts_diff
KPSS Level = 0.063726, Truncation lag parameter = 3, p-value =
0.1

```

Salida de R sobre la significacion de los coeficientes del modelo seleccionado:

```

z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
ma1  -0.21368    0.10200  -2.0949  0.03618 *
ma2  -0.21248    0.10809  -1.9658  0.04932 *
sma1 -0.99996    0.17406  -5.7450 9.193e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Salida de R sobre test de Box-Ljung para incorrelacion de los residuos del modelo seleccionado.

```

Box-Ljung test

data: residuos
X-squared = 17.648, df = 24, p-value = 0.8198

```

Salida de R sobre test Shapiro-Wilk y Jarque-Bera para normalidad de los residuos del modelo seleccionado.


```

Shapiro-Wilk normality test
data: residuos
W = 0.96392, p-value = 0.004268

Jarque Bera Test
data: residuos
X-squared = 23.597, df = 2, p-value = 7.517e-06

Skewness
data: residuos
statistic = 0.2789, p-value = 0.2303

Kurtosis
data: residuos
statistic = 5.1888, p-value = 2.511e-06

```

Salida de R sobre test Homoscedasticidad de los residuos del modelo seleccionado.

```

Box-Ljung test
data: residuos2
X-squared = 20.07, df = 24, p-value = 0.6928

```

Salida de R sobre los outliers detectados para ajustar el modelo seleccionado

```

call:
lm(list(method = "ML"))

Coefficients:
      ma1      ma2      sma1      LS51      TC52
-0.5740 -0.0764 -0.9983 -7.3259 -10.2673
s.e.    0.1158  0.1277  1.1159  1.7847  2.0795

sigma^2 estimated as 3.669: log likelihood = -216.22, aic = 444.45

outliers:

```

Salida de R sobre la significacion del modelo seleccionado ajustado por los outliers

```

z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
ma1  -0.573976  0.115784 -4.9573 7.148e-07 ***
ma2  -0.076446  0.127743 -0.5984  0.5495
sma1  -0.998340  1.115864 -0.8947  0.3710
LS51  -7.325860  1.784675 -4.1049 4.045e-05 ***
TC52 -10.267330  2.079542 -4.9373 7.921e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Salida de R sobre la significacion del modelo alternativo ajustado por sus outliers

```

z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
ma1  -0.24786   0.12218 -2.0286  0.0425 *
sma1 -0.99989   0.17149 -5.8306 5.521e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
ma1  -0.620803  0.088326 -7.0286 2.087e-12 ***
sma1  -0.943750  0.465672 -2.0266  0.0427 *
LS51  -7.164275  1.808824 -3.9607 7.472e-05 ***
TC52 -10.499569  2.044675 -5.1351 2.820e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Salida de R sobre comparacion de AIC, AICc y BIC entre modelo seleccionado y ajustado por sus outliers con nuevo modelo elegido y ajustado por sus outliers

	df <dbl>	AIC <dbl>
modelo1_nuevo	6	444.4496
modelo2_nuevo	5	442.8062
	df <dbl>	AICc <dbl>
modelo1_nuevo	6	445.3727
modelo2_nuevo	5	443.4584
	df <dbl>	BIC <dbl>
modelo1_nuevo	6	459.9594
modelo2_nuevo	5	455.7310

Salida de R sobre test de Box-Ljung para incorrelacion de los residuos del nuevo modelo seleccionado y ajustado por sus outliers

```
Box-Ljung test

data:  residuos_nuevo
X-squared = 19.252, df = 24, p-value = 0.7384
```

Salida de R sobre test Shapiro-Wilk y Jarque-Bera para normalidad de los residuos del nuevo modelo seleccionado y ajustado por sus outliers

```
shapiro-wilk normality test

data:  residuos_nuevo
W = 0.98571, p-value = 0.2866


Jarque Bera Test

data:  residuos_nuevo
X-squared = 0.9905, df = 2, p-value = 0.6094


Skewness

data:  residuos_nuevo
statistic = 0.219, p-value = 0.3462


Kurtosis

data:  residuos_nuevo
statistic = 2.8506, p-value = 0.748
```

Salida de R sobre test Homoscedasticidad de los residuos del nuevo modelo seleccionado y ajustado por sus outliers

```
Box-Ljung test

data:  residuos2
X-squared = 20.07, df = 24, p-value = 0.6928
```